

Rapport de projet de fin d'année

FILIERE : SMART ICT

Système d'optimisation de portefeuille pilote par apprentissage automatique

*Allocation d'actifs sous contraintes réalistes,
et évaluation honnête de ce qu'elle apporte*



Réalisé par :


Souhail BOURHIM • Zakarya EL WALI • Yasmine BOUAJINE

Encadré par :

M. Abdelmouttalib MAQIL

EURAFRIC Information

*Projet réalisé à distance pour EURAFRIC Information,
du 18 juin au 1^{er} août 2026*



AGENCE NATIONALE DE RÉGLEMENTATION DES TÉLÉCOMMUNICATIONS

INSTITUT NATIONAL DES POSTES ET TÉLÉCOMMUNICATIONS

Promotion : 2025/2026

*À mes parents,
pour leur patience et leur soutien sans faille.*

*À ma famille et à mes amis,
qui ont accompagné ce parcours.*

*À celles et ceux qui m'ont appris
qu'un résultat que l'on ne sait pas remettre en question
n'est pas encore un résultat.*

Remerciements

Je tiens à exprimer ma reconnaissance à **M. Abdelmoultalib MAQIL**, mon encadrant au sein d'EURAFRIC Information, pour la qualité de son suivi tout au long de ces six semaines. Ses exigences — rattacher chaque composant au problème qu'il traite, livrer une chaîne complète avant de la raffiner, et savoir défendre chaque décision de conception sans notes — ont façonné ce travail bien au-delà de sa dimension technique. Sa manière d'accueillir un résultat négatif comme un résultat à part entière est, rétrospectivement, ce qui a rendu ce projet intéressant.

Je remercie **EURAFRIC Information** d'avoir proposé un sujet à la fois ouvert et exigeant, et d'avoir rendu possible un encadrement à distance qui n'a rien perdu en exigence ; ainsi que l'ensemble des collaborateurs qui ont pris le temps de répondre à nos questions.

Mes remerciements vont également au corps professoral et à l'administration de l'**Institut National des Postes et Télécommunications**, et en particulier à la filière **Smart ICT**, pour la formation reçue et pour le cadre donné à ce projet de fin d'année.

Je remercie enfin mes camarades **Zakarya EL WALI** et **Yasmine BOUAJINE**, avec qui ce projet a été mené, pour la qualité des échanges et pour la rigueur qu'ils ont apportée aux relectures — plusieurs des vérifications décrites dans ce rapport sont nées d'une objection formulée par l'un ou l'autre.

Que ma famille et mes proches trouvent ici l'expression de ma gratitude pour leur soutien constant.

Résumé

Ce projet de fin d'année, réalisé à distance pour EURAFRIC Information, porte sur l'allocation d'un capital entre plusieurs actifs financiers : comment répartir une somme entre quatre valeurs de la Bourse de Casablanca et cinq fonds indiciels internationaux de manière à obtenir le meilleur rendement possible pour un risque maîtrisé.

La théorie classique répond à cette question depuis 1952, mais échoue en pratique pour quatre raisons structurelles : les quantités qu'elle estime sont bruitées, le comportement des marchés change au cours du temps, la diversification disparaît précisément pendant les crises, et les performances mesurées sur le passé sont systématiquement optimistes. Le travail construit une chaîne complète qui traite ces quatre problèmes : préparation et validation des données en trois couches, moteur de simulation temporelle dont l'absence de vision du futur est vérifiée par des tests, puis quatre familles de modèles ajoutées une à une — rétrécissement de la matrice de covariance, détection non supervisée de régimes de marché par modèle de Markov caché, prédiction de rendement par ensembles d'arbres, et optimisation tenant compte des coûts de transaction. L'évaluation est traitée comme un objet d'ingénierie à part entière : sélection strictement antérieure (l'entraînement précède toujours la validation, purge et embargo à la frontière), segment de test gelé, et **comparaisons pairées** par bootstrap à blocs — le test de la *différence* entre deux stratégies, que des intervalles marginaux ne fournissent pas.

Les résultats sont rapportés selon leur force probante. Sur cinq fenêtres de crise externes, le détecteur de régime est plus souvent dans son état « baissier » qu'en dehors des fenêtres ; cette association est présentée comme exploratoire, car cinq événements et une définition de l'état par le rendement ne permettent pas une conclusion confirmatoire. Le système complet présente un écart observé de 6,2 % de ratio de Sharpe net sur le portefeuille visé et de -1,6 % sur l'univers international. **Ces chiffres intègrent une exposition de change USD/MAD non couverte** — les actifs BVC sont libellés en dirhams et les ETF en dollars — : il s'agit d'une exposition économique matérielle portée par tous les résultats de portefeuille, non d'une réserve de forme. Sur l'instantané publié, aucun des 1 188 ajustements — quatre stratégies évaluées, 297 dates de rééquilibrage — n'a utilisé de repli d'estimateur : chaque résultat rapporté provient du modèle que son étiquette désigne, mesure reproductible et versionnée plutôt qu'hypothèse. Après correction White/SPA pour les 240 configurations atteignables, sous validation strictement antérieure, les huit comparaisons pairées menées sur la fenêtre de test gelée ont toutes un intervalle contenant zéro : **aucune surperformance n'est établie**, ni pour les modèles de signal contre la stratégie à régimes, ni contre l'équipondéré. Ce n'est pas davantage une preuve d'équivalence, faute de test dédié. Cinq pistes indépendantes ont été explorées et fermées, établissant notamment que précision de prédiction et performance de portefeuille sont deux objectifs distincts. Enfin, le plafond de position imposé comme règle métier s'est révélé le régulariseur le plus efficace du système. Le livrable comprend un tableau de bord de recherche à deux pages et une interface REST de consultation, trois cartes de modèle générées depuis les artefacts et un monitoring prêt mais non actif, couverts par plus de 580 tests automatisés.

Mots-clés : optimisation de portefeuille, apprentissage automatique, modèle de Markov caché,

matrice de covariance, backtesting, validation hors échantillon, Bourse de Casablanca, gestion du risque.

Abstract

This final-year project, carried out remotely for EURAFRIC Information, addresses capital allocation across financial assets : how to split a sum between four Casablanca Stock Exchange equities and five international index funds so as to obtain the best possible return for a controlled level of risk.

Classical theory has answered this question since 1952, but fails in practice for four structural reasons : the quantities it estimates are noisy, market behaviour changes over time, diversification vanishes precisely during crises, and performance measured on past data is systematically optimistic. This work builds a complete pipeline addressing all four : a three-layer data preparation and validation stack, a walk-forward simulation engine whose inability to see the future is enforced by tests rather than asserted, and four model families added one at a time — covariance shrinkage, unsupervised market-regime detection via a hidden Markov model, return prediction with tree ensembles, and transaction-cost-aware optimisation. Evaluation is treated as an engineering artefact in its own right : strictly forward-only selection (training always precedes validation, with a purge and an embargo at the boundary), a frozen test segment, and **paired** block-bootstrap comparisons — a test of the *difference* between two strategies, which marginal intervals do not provide.

Results are reported by strength of evidence. Across five external crisis windows, the regime detector is more often in its “bear” state than outside those windows ; this association is reported as exploratory because five events and a return-based state definition cannot support a confirmatory conclusion. The full system has an observed 6.2% net-Sharpe difference on the target portfolio and a -1.6% difference on the international universe. **These figures embed an unhedged USD/MAD currency exposure** — BVC assets are MAD-denominated and the ETFs USD — a material economic exposure carried by every portfolio result, not a formality. On the released snapshot none of the 1 188 fits — four evaluated strategies, 297 rebalance dates — used an estimator fallback : every reported result was produced by the model its label names, a reproducible versioned measurement rather than an assumption. After White/SPA correction across the 240 reachable configurations and under forward-only selection, all eight paired comparisons on the frozen test window have intervals containing zero : **no outperformance is established**, for either signal model against either the regime strategy or equal weighting. Nor is this evidence of equivalence, absent a dedicated test. Five independent avenues for improvement were explored and closed, establishing among other things that prediction accuracy and portfolio performance are distinct objectives. Finally, the position cap imposed as a business rule turned out to be the system’s most effective regulariser. Deliverables include a two-page research dashboard and a read-only REST interface, three artefact-generated model cards, and monitoring that is ready but deliberately not live, covered by more than 580 automated tests.

Keywords : portfolio optimisation, machine learning, hidden Markov model, covariance estimation, backtesting, out-of-sample validation, Casablanca Stock Exchange, risk management.

ملخص

يتناول هذا المشروع، المنجز عن بُعد لفائدة شركة EURAFRIC Information، مسألة توزيع رأس المال بين عدة أصول مالية: كيف يُوزَع مبلغ من المال بين أربع شركات مدرجة في بورصة الدار البيضاء وخمسة صناديق مؤشرات دولية، بحيث يُحصَل أفضل عائد ممكن مع التحكم في المخاطر.

تُجيب النظرية الكلاسيكية عن هذا السؤال منذ سنة 1952، غير أنها تفشل عملياً لأربعة أسباب بنيوية: المقادير التي تقدّرها مشوّشة، وسلوك الأسواق يتغيّر عبر الزمن، ويحتفي أثر التنوع في أوقات الأزمات بالذات، كما أن الأداء المقاس على بيانات الماضي متفائل بشكل منهجي. يبني هذا العمل سلسلة معالجة كاملة تعالج هذه المشكلات الأربع: ثلاث طبقات لتحضير البيانات والتحقق منها، ومحرك محاكاة زمنية تُثبت استحالة اطلاعه على المستقبل باختبارات آلية لا بمجرد الادعاء، ثم أربع عائلات من النماذج تُضاف واحدة تلو الأخرى: تقليص مصفوفة التغير، والكشف غير المراقب عن أنظمة السوق بواسطة نموذج ماركوف الخفي، والتنبؤ بالعوائد بواسطة تجميعات الأشجار، والتحسين الذي يأخذ تكاليف المعاملات بعين الاعتبار. ويُعامل التقييم بوصفه موضوعاً هندسياً قائماً بذاته: اختيار أممي صارم (يسبق التدريبُ التحققَ دائماً، مع تنقية وفترة حظر عند الحد)، وقطاع اختبار مُجمّد، ومقارنات (paired) مزدوجة بإعادة المعاينة بالكلل — أي اختبار الفرق بين استراتيجيتين، وهو ما لا توفره الفترات الهامشية.

تُعرض النتائج بحسب قوة الدليل. فقد تعرّف كاشف الأنظمة على الأزمات الخمس المدروسة جميعها، بأكثر من ثلاثة أضعاف معدله الأساسي ودون إنذارات دائمة؛ وتُعرض هذه العلاقة بوصفها استكشافية لا تأكيدية لأن عدد الأزمات خمسة فقط. ويتفوق النظام الكامل على أفضل مقارنة كلاسيكية بنسبة 6,2 بالمائة من نسبة شارب الصافية على المحفظة المستهدفة، بينما يقل عنها بنسبة 1,6 بالمائة على الكون الدولي. وفي ظل الاختيار الأممي الصارم، احتوت جميع المقارنات المزدوجة الثماني على نافذة الاختبار المجددة على الصفر داخل فترات ثقتها: لم تثبت أي أفضلية في الأداء، لا لنماذج الإشارة في مواجهة استراتيجية الأنظمة ولا في مواجهة التوزيع المتساوي. وهذا ليس دليلاً على التكافؤ أيضاً، في غياب اختبار مخصص لذلك. كما استُكشفت خمسة مسارات مستقلة للتحسين وأُغلقت، مما أثبت بوجه خاص أن دقة التنبؤ وأداء المحفظة هدفان متمليزان. وأخيراً تبين أن سقف الوزن المفروض بوصفه قاعدة مهنية هو أنجع أداة تنظيم في النظام. وتشمل المخرجات لوحة قيادة من صفحتين وواجهة برمجية REST، يغطيها أكثر من 580 اختباراً آلياً.

الكلمات المفتاحية: تحسين المحفظة، التعلم الآلي، نموذج ماركوف الخفي، مصفوفة التغير، الاختبار الرجعي، التحقق خارج العينة، بورصة الدار البيضاء، إدارة المخاطر.

Liste des acronymes

Acronyme	Signification
API	<i>Application Programming Interface</i> — interface de programmation applicative
BAM	Bank Al-Maghrib — banque centrale du Royaume du Maroc
BVC	Bourse des Valeurs de Casablanca
DCC	<i>Dynamic Conditional Correlation</i> — corrélation conditionnelle dynamique (Engle, 2002)
DSR	<i>Deflated Sharpe Ratio</i> — ratio de Sharpe déflaté
DVC	<i>Data Version Control</i> — outil de versionnement des données et des pipelines
EM	<i>Expectation-Maximization</i> — algorithme d'estimation employé par le modèle de Markov caché
ETF	<i>Exchange-Traded Fund</i> — fonds indiciel coté
EWMA	<i>Exponentially Weighted Moving Average</i> — moyenne mobile à pondération exponentielle
FRED	<i>Federal Reserve Economic Data</i> — base de données macroéconomiques de la Réserve fédérale de Saint-Louis
GARCH	<i>Generalized Autoregressive Conditional Heteroskedasticity</i> — modèle de volatilité variable dans le temps
HMM	<i>Hidden Markov Model</i> — modèle de Markov caché
IC	<i>Information Coefficient</i> — coefficient d'information
INPT	Institut National des Postes et Télécommunications
MAD	Dirham marocain (code ISO 4217)
ML	<i>Machine Learning</i> — apprentissage automatique
MPT	<i>Modern Portfolio Theory</i> — théorie moderne du portefeuille (Markowitz, 1952)
OOS	<i>Out-Of-Sample</i> — hors échantillon
PFA	Projet de Fin d'Année
REST	<i>Representational State Transfer</i> — style d'architecture des interfaces web
RF	<i>Random Forest</i> — forêt aléatoire
SLSQP	<i>Sequential Least Squares Programming</i> — algorithme d'optimisation sous contraintes
USD	Dollar américain (code ISO 4217)
VIX	<i>Volatility Index</i> — indice de volatilité implicite du marché américain
XGB	<i>eXtreme Gradient Boosting</i> — bibliothèque de <i>gradient boosting</i> d'arbres

Glossaire

Actif Objet dans lequel on peut placer de l'argent : action d'entreprise, obligation d'État, fonds indiciel.

Allocation Répartition d'un capital entre plusieurs actifs. Synonyme usuel : *poïds* du portefeuille.

Backtest Simulation d'une stratégie sur des données passées, en rejouant le temps tel qu'il s'est écoulé.

Biais de survivance / de vision du futur Toute situation où une décision passée est influencée par une information qui n'était pas disponible à ce moment-là. C'est l'erreur la plus grave possible dans ce domaine : elle produit des performances impossibles à reproduire en conditions réelles.

Bootstrap à blocs Méthode d'estimation de l'incertitude consistant à reconstituer des milliers d'historiques fictifs en retirant au sort des blocs de journées consécutives, afin de préserver la structure temporelle des rendements.

Coefficient d'information Corrélation de rang entre rendements prédits et rendements réalisés : mesure la capacité d'un signal à *classer* les actifs, sans exiger que ses prédictions soient justes en niveau.

Corrélation Mesure du degré auquel deux actifs évoluent ensemble. Comprise entre -1 (mouvements opposés) et $+1$ (mouvements identiques).

Covariance (matrice de) Tableau décrivant conjointement la volatilité de chaque actif et la corrélation de chaque paire. C'est la description du risque d'un portefeuille, et la quantité la plus difficile à estimer.

Drawdown (perte maximale) Baisse maximale subie entre un sommet et le creux qui le suit. Répond à la question « combien aurais-je pu perdre au pire moment ? ».

Équipondération (1/N) Stratégie consistant à placer la même somme sur chaque actif. Sans paramètre à estimer, donc sans erreur d'estimation : c'est la référence de comparaison honnête.

Fonds indiciel (ETF) Fonds coté en bourse répliquant un indice de marché ; en acheter une part revient à détenir une fraction de tout l'indice.

Hors échantillon Se dit d'une performance mesurée sur des données qui n'ont servi ni à entraîner ni à sélectionner le modèle évalué.

Modèle de Markov caché Modèle statistique supposant que les observations sont engendrées par un état non observable qui change au cours du temps ; l'état est inféré à partir de ce qu'il produit.

Point de base Un centième de point de pourcentage (0,01 %). Unité usuelle des coûts de transaction.

Ratio de Calmar Rendement annualisé divisé par la perte maximale. Mesure le rendement obtenu par unité de *pire* perte, là où le ratio de Sharpe divise par la volatilité moyenne.

Ratio de Sharpe Rendement obtenu par unité de risque, le risque étant mesuré par la volatilité. Principal indicateur de comparaison entre stratégies — et, comme le montre le chapitre 5, un indicateur dont le choix n'est pas neutre.

Régime de marché Période durant laquelle le marché se comporte de manière homogène (par exemple : hausse régulière et faible volatilité, ou baisse et forte volatilité). Les régimes ne sont pas observables directement.

Rendement logarithmique Rendement calculé comme $\ln(P_t/P_{t-1})$. Se somme dans le temps, contrairement au rendement en pourcentage — d'où son usage systématique dans ce projet.

Rétrécissement (*shrinkage*) Technique consistant à rapprocher une estimation bruitée d'une cible simple et stable. On accepte un biais volontaire en échange d'une forte réduction de variance.

Sharpe déflaté Probabilité qu'une performance mesurée soit réellement positive après correction du nombre de stratégies essayées et de la non-normalité des rendements.

Turnover (rotation) Proportion du portefeuille effectivement échangée lors d'un rééquilibrage. Détermine directement les coûts de transaction supportés.

Sélection strictement antérieure Découpage de validation dans lequel l'entraînement précède toujours la fenêtre de validation, séparé d'elle par une purge et un embargo. À la différence de la validation croisée purgée en blocs, aucune date postérieure à la validation ne peut entrer dans l'entraînement : c'est la seule forme qui simule une décision d'allocation séquentielle.

Test pairé Comparaison de deux stratégies sur les *mêmes* dates, en rééchantillonnant les deux séries avec les mêmes blocs. Teste la *différence*, ce que deux intervalles de confiance marginaux ne font pas : ils peuvent se chevaucher alors que la différence est systématiquement positive.

Validation croisée purgée Variante de la validation croisée adaptée aux séries temporelles : les observations d'entraînement dont l'horizon chevauche le bloc de test sont retirées (*purge*), et une bande de journées suivant ce bloc est écartée (*embargo*).

Volatilité Ampleur des variations d'un actif, mesurée par l'écart-type de ses rendements. Mesure usuelle — et imparfaite — du risque.

Table des matières

Remerciements	iii
Résumé	v
Abstract	vii
ملخص	ix
Liste des acronymes	xi
Glossaire	xiii
1 Contexte : l'entreprise, le stage et le sujet	1
Ce que ce chapitre explique	1
1.1 L'organisme d'accueil : EURAFRIC Information	1
1.1.1 Activité et positionnement	1
1.1.2 Quelques repères	1
1.1.3 Pourquoi ce sujet dans cette entreprise	1
1.2 Le cadre du stage	2
1.3 Le sujet tel qu'il a été formulé	3
1.4 Objectifs et périmètre	4
1.5 Déroulement du travail	4
1.6 Guide de lecture	5
Synthèse du chapitre	5
2 Problématique : de l'allocation d'actifs à ses quatre échecs	7
Ce que ce chapitre explique	7
2.1 Le problème, en une phrase	7
2.2 Un portefeuille, un rendement, un risque	7
2.2.1 Le vocabulaire minimal	7
2.2.2 Une image	8
2.3 La diversification, et pourquoi elle fonctionne	8

2.4	Markowitz (1952) : formaliser l'intuition	9
2.5	Les quatre échecs de la théorie classique	9
2.5.1	P1 — L'estimation est bruitée	11
2.5.2	P2 — Le monde ne reste pas immobile	11
2.5.3	P3 — La diversification disparaît quand elle devient nécessaire	11
2.5.4	P4 — Se tromper soi-même : le surapprentissage	12
2.6	Ce que le Machine Learning peut — et ne peut pas — apporter	13
2.7	Les contraintes réalistes de gestion	14
2.8	Problématique retenue	14
2.9	État de l'art	15
	Synthèse du chapitre	16
3	Architecture : la chaîne de données et les garde-fous	17
	Ce que ce chapitre explique	17
3.1	Trois couches, une seule direction	17
3.2	Deux univers, et un manque assumé	18
3.3	Le dividende manquant : un défaut trouvé tardivement	19
3.4	Le moteur de backtest, frontière de confiance	20
3.5	Rendre les règles exécutables	20
3.6	Reproduire, ordonnancer, tracer : trois outils, trois questions	21
3.6.1	DVC — « ce résultat correspond-il encore à ces données ? »	21
3.6.2	Dagster — « qu'est-ce qui doit se réexécuter, et quand ? »	21
3.6.3	MLflow — « d'où vient ce chiffre ? »	23
3.7	Ce que l'exploitation a appris	23
3.8	La pile technique	24
	Synthèse du chapitre	25
4	Modélisation et protocole d'évaluation	27
	Ce que ce chapitre explique	27
4.1	Les références classiques	27
4.2	Premier échelon : mieux estimer le risque (P1)	28
4.3	Deuxième échelon : reconnaître le régime de marché (P2, P3)	29
4.4	Troisième échelon : prédire les rendements	30
4.5	Quatrième échelon : payer le prix des transactions	31
4.6	Le protocole d'évaluation (P4)	31
4.6.1	Rejouer le temps	31
4.6.2	Choisir les hyperparamètres sans tricher	31
4.6.3	Deux objectifs, deux instruments	32
4.6.4	Un verdict rendu une seule fois, avec sa marge d'erreur	33

4.7 La discipline expérimentale	34
Synthèse du chapitre	34
5 Résultats, validation et produit livré	35
Comment lire ce chapitre	35
5.1 Le résultat principal	35
5.1.1 Une réserve sur le choix de la mesure	37
5.2 Ce chiffre est-il réel ? La validation hors échantillon	37
5.2.1 Corriger pour l'ampleur de la recherche	39
5.3 Comportement en crise : une lecture métier descriptive (P3)	40
5.4 La détection de régime : une analyse exploratoire (P2)	41
5.5 La contrainte fait plus que les modèles (P1)	43
5.6 Ce qui ne fonctionne pas : cinq pistes fermées	44
5.7 L'étiquette correspond-elle au modèle ? (P4)	45
5.7.1 Sensibilité aux coûts de transaction	46
5.8 Gouvernance, explicabilité et monitoring	46
5.9 Le produit livré	47
5.9.1 Page « Résultats de recherche » — destinée aux décideurs	47
5.9.2 Page « Explorateur de stratégies » — destinée à l'analyse	47
5.9.3 L'interface REST	47
Synthèse du chapitre	51
Conclusion générale	53

Table des figures

1.1	Déroulement du stage	5
2.1	La frontière efficiente	10
2.2	Les quatre problèmes P1–P4	10
2.3	Volatilité et régimes de marché	12
2.4	Rupture de la diversification en crise	13
3.1	Le pipeline DVC	22
3.2	Catalogue des actifs Dagster	23
3.3	Suivi d’expérience MLflow	24
4.1	Sortie du détecteur de régime	29
4.2	Backtest à fenêtre glissante	32
4.3	Protocole de sélection	33
5.1	Évolution des portefeuilles	36
5.2	Intervalles de confiance	38
5.3	Comportement en crise	41
5.4	Détection non supervisée des crises	42
5.5	Effet du plafond par actif	43
5.6	Tableau de bord — page décideur	48
5.7		49
5.8	Tableau de bord — explorateur de stratégies	50
5.9		52

Liste des tableaux

1.1	Repères sur EURAFRIC Information	2
1.2	Cadre du stage	2
1.3	Périmètre du projet	4
3.1	Les trois couches de données	18
3.2	Les deux univers de test	18
3.3	Pile technique	25
5.1	Performance comparée, hors échantillon	36
5.2	Comparaisons pairées	38
5.3	Correction pour tests multiples	39
5.4	Diagnostic de la détection	42
5.5	Les cinq pistes testées	44
5.6	Intégrité des modèles	45
5.7	Sensibilité aux coûts	46

Chapitre 1

Contexte : l'entreprise, le stage et le sujet

Ce que ce chapitre explique

Ce chapitre situe le travail : l'entreprise qui l'a commandé, le cadre universitaire dans lequel il s'inscrit, le sujet tel qu'il a été formulé, et la manière dont il a été conduit en six semaines et demie. Il se termine par un guide de lecture, car les chapitres suivants ne s'adressent pas tous au même lecteur.

1.1 L'organisme d'accueil : EURAFRIC Information

1.1.1 Activité et positionnement

EURAFRIC Information est une entreprise de services informatiques marocaine, créée en **octobre 2008** et implantée sur le campus BMCE Bank, Bouskoura Green City, à Casablanca. Elle conçoit et exploite des systèmes d'information pour des acteurs de la **banque, de la finance, de l'assurance et du crédit à la consommation**, et se présente comme un centre de services informatiques mutualisés au service de plusieurs entités clientes.

Son expertise couvre le développement applicatif, les réseaux et télécommunications, les systèmes et bases de données, ainsi que la cybersécurité. L'entreprise exploite ses propres centres de données et opère, en outre, comme prestataire de services de confiance au sens de la loi marocaine 43-20 relative aux services de confiance pour les transactions électroniques.

1.1.2 Quelques repères

Les éléments du tableau 1.1 sont ceux publiés par l'entreprise sur son site institutionnel ; ils sont reproduits à titre de repères et non vérifiés indépendamment.

1.1.3 Pourquoi ce sujet dans cette entreprise

Le rapprochement entre une société de services informatiques et un sujet de finance quantitative n'a rien d'incongru dès lors que l'on regarde sa clientèle. Une banque, une compagnie d'assurance ou un organisme de crédit ne se contente pas d'exécuter des opérations : il place des fonds propres, gère des réserves techniques, et doit répondre à des exigences de contrôle du risque.

TAB. 1.1: Repères sur l'organisme d'accueil, d'après ses publications institutionnelles.

Élément	Valeur
Création	Octobre 2008
Implantation	Campus BMCE Bank, Bouskoura Green City, Casablanca
Effectif	Environ 350 collaborateurs, majoritairement ingénieurs
Secteurs servis	Banque, finance, assurance, crédit à la consommation
Infrastructure	2 centres de données, plus de 3 000 serveurs, plus de 10 000 utilisateurs connectés
Activité projet	Plus de 300 projets par an
Certifications	Conception et exploitation de centre de données TIER III, ISO 22301 (continuité d'activité), accréditation prestataire de services de confiance (loi 43-20)
Distinction	<i>Top Employer Maroc</i> , cinq années consécutives jusqu'en 2024

Les outils d'aide à l'allocation d'actifs relèvent donc directement du système d'information de ces métiers.

Deux caractéristiques du marché marocain rendent en outre le sujet particulièrement intéressant à traiter localement. La Bourse de Casablanca est un marché de taille modeste, peu liquide sur certaines valeurs, et dont l'historique public gratuit est court — trois contraintes qui invalident l'application mécanique de méthodes calibrées sur les marchés américains. Et la conjonction d'actifs marocains libellés en dirham et d'actifs internationaux libellés en dollar pose une question d'allocation qui n'a pas d'équivalent direct dans la littérature standard.

1.2 Le cadre du stage

Ce travail constitue le **Projet de Fin d'Année (PFA)** de l'année universitaire 2025–2026, réalisé dans le cadre de la formation **Smart ICT** de l'Institut National des Postes et Télécommunications (INPT).

TAB. 1.2: Cadre administratif et humain du projet.

Période	Du 18 juin au 1 ^{er} août 2026, soit 44 jours (environ six semaines et demie)
Établissement	INPT — filière Smart ICT, année 2025–2026
Organisme commanditaire	EURAFRIC Information, Bouskoura
Modalité	À distance, avec une journée sur site
Encadrement	M. Abdelmoultalib MAQIL (EURAFRIC Information)
Équipe	Souhail BOURHIM, Zakarya EL WALI, Yasmine BOUAJINE

Le projet s'est déroulé **à distance** : l'équipe ne s'est rendue sur le site de Bouskoura qu'une seule fois, le suivi s'effectuant ensuite par points d'étape réguliers. Cette modalité a une conséquence directe sur la manière de travailler, et elle explique une partie des choix décrits au chapitre 3 : un encadrant qui ne voit pas l'écran par dessus l'épaule juge sur ce qui est livré et sur ce qui est écrit. Un livrable par phase, des chiffres reconstituables depuis les sources et des règles vérifiées par des tests plutôt que par la confiance ne sont pas seulement de bonnes pratiques ici : ce sont les conditions du travail à distance.

L'encadrement a été assuré côté entreprise. Sa méthode a façonné le projet autant que le sujet lui-même, et mérite d'être explicitée, car elle explique plusieurs partis pris qui pourraient sinon

surprendre :

- **Traçabilité** — tout composant doit indiquer à quel problème identifié il répond ; un composant qu'on ne sait pas rattacher à un problème est retiré, si sophistiqué soit-il.
- **Produit minimal d'abord** — une chaîne complète de bout en bout avec des modèles simples vaut mieux qu'une moitié de chaîne avec des modèles élaborés.
- **Défendabilité** — chaque membre de l'équipe doit pouvoir justifier n'importe quelle décision de conception sans notes.
- **Honnêteté sur les limites** — les manques de données et les questions ouvertes se déclarent d'eux-mêmes plutôt que d'être découverts par le lecteur.

1.3 Le sujet tel qu'il a été formulé

L'énoncé remis par l'entreprise est le suivant :

Dans le cadre de ce challenge, les étudiants travailleront sur une problématique centrale de la finance quantitative : comment allouer intelligemment un capital entre plusieurs actifs financiers afin de maximiser le rendement tout en maîtrisant le risque. Ils concevront et implémenteront un système d'optimisation de portefeuille piloté par le Machine Learning, capable d'analyser des séries temporelles financières, d'apprendre les corrélations dynamiques entre actifs et de proposer automatiquement des stratégies d'allocation robustes, sous des contraintes réalistes de gestion. Le prototype devra être évalué dans un cadre rigoureux de backtesting sur des données hors échantillon, avec une attention particulière portée à la robustesse, au risque de surapprentissage et à la pertinence financière des résultats.

Cet énoncé est plus prescriptif qu'il n'y paraît. Quatre de ses expressions fixent en réalité l'architecture du travail, et chacune est traitée dans un chapitre précis de ce rapport :

- « *apprendre les corrélations dynamiques* » — les corrélations entre actifs ne sont pas constantes ; les estimer comme si elles l'étaient est le premier des quatre problèmes exposés au chapitre 2.
- « *sous des contraintes réalistes de gestion* » — cette incise a été traitée comme une *contrainte* et non comme un indicateur : interdiction de vente à découvert, plafond par actif et coûts de transaction s'appliquent à l'intérieur de l'optimisation, pas seulement au moment de rendre compte. Le chapitre 5 montre que cette décision, prise pour réalisme, s'est révélée le levier de performance le plus efficace du projet.
- « *données hors échantillon* » et « *risque de surapprentissage* » — l'évaluation devient un objet d'ingénierie à part entière, décrit au chapitre 4.
- « *pertinence financière des résultats* » — un gain moyen ne suffit pas ; le comportement en période de crise est examiné séparément.

L'énoncé demande un système « capable de proposer automatiquement des stratégies d'allocation robustes ». Il ne demande pas de démontrer que le Machine Learning bat les méthodes classiques. Cette nuance est décisive : elle autorise — et même impose — de rapporter un résultat négatif lorsque c'est ce que les données montrent. Le chapitre 5 en contient

plusieurs.

1.4 Objectifs et périmètre

L'objectif retenu est la livraison d'une **chaîne complète, documentée et reproductible**, sous la forme d'un **prototype de recherche** : collecte et validation des données, modèles d'allocation, évaluation rigoureuse, et deux surfaces de consultation (une application web et une interface de programmation). Il ne constitue ni un conseil d'investissement, ni un outil de production, ni un dispositif d'exécution d'ordres.

Le périmètre a été délimité explicitement dès le cadrage, et tenu.

TAB. 1.3: Ce qui est dans le périmètre, et ce qui en a été écarté délibérément.

Dans le périmètre	Hors périmètre (assumé)
Chaîne de données de bout en bout, versionnée et ordonnancée	Flux de données en temps réel
Modèles d'allocation classiques et ML, sous contraintes de gestion	Passage d'ordres et exécution réelle
Évaluation hors échantillon avec intervalles de confiance	Déploiement sur une infrastructure d'hébergement
Tableau de bord de recherche et explorateur de stratégies, interface REST	Couverture du risque de change dirham/dollar

L'exclusion du temps réel et de l'exécution d'ordres n'est pas une facilité : elle concentre l'effort sur la question que l'énoncé pose réellement, qui est celle de la *qualité de la décision d'allocation*, non celle de son acheminement vers un marché.

1.5 Déroulement du travail

Le projet a été conduit en phases successives, chacune close par un livrable remis à l'encadrant (figure 1.1). Deux observations sur ce déroulement méritent d'être faites, parce qu'elles ne se lisent pas sur un planning prévisionnel.

Onze jours avant la première ligne de code. Le cadrage — comprendre le domaine, identifier les quatre problèmes structurels, inventorier les sources de données disponibles pour le marché marocain et constater leurs limites — a occupé la première semaine et demie. C'est ce travail préalable qui a permis d'écarter très tôt des pistes coûteuses, et de découvrir avant de s'engager que l'historique gratuit de la Bourse de Casablanca ne remonte pas au-delà de 2021 — contrainte qui a directement produit la conception à double univers décrite au chapitre 3.

Une activité très inégale, et c'est normal. L'histogramme montre des journées à quinze contributions et des semaines quasi vides. Les creux correspondent aux phases d'exécution longue — certaines évaluations demandent plusieurs heures de calcul — et aux périodes de rédaction des livrables. Le volume de contributions mesure l'activité de développement, pas l'avancement du projet ; c'est précisément pour cela qu'il est présenté à côté des phases et non à leur place.




FIG. 1.1: Déroulement réel du projet. Les bandes du haut sont les phases ; l’histogramme du bas est l’activité de développement *réellement enregistrée* dans l’historique de versionnement, jour par jour. Les onze premiers jours ne comportent aucun code.

1.6 Guide de lecture

Les chapitres qui suivent ne visent pas le même lecteur, et peuvent être lus séparément.

- Le **chapitre 2** expose le problème financier et ses quatre échecs structurels. Il ne suppose *aucune* connaissance en finance : toute notion y est définie à son premier emploi. C’est le chapitre à lire en premier pour un lecteur non spécialiste.
- Le **chapitre 3** décrit la chaîne de données et les garde-fous qui empêchent les erreurs de mesure. Il intéressera un lecteur d’ingénierie logicielle ou de données.
- Le **chapitre 4** présente les modèles et, surtout, le protocole d’évaluation. Il ne contient volontairement aucun résultat, afin que la méthode puisse être jugée indépendamment de ses conclusions.
- Le **chapitre 5** donne les résultats, chacun assorti de sa marge d’erreur, et distingue explicitement ce que le projet démontre, ce qu’il observe sans le démontrer, et ce qu’il réfute. Il présente également le produit livré.

Synthèse du chapitre

- Le projet a été réalisé **à distance** pour **EURAFRIC Information**, entreprise de services informatiques créée en 2008 à Bouskoura, dont les clients relèvent de la banque, de la finance et de l’assurance — secteurs pour lesquels l’aide à l’allocation d’actifs est un besoin métier direct.
- Il s’agit du **PFA** de la filière Smart ICT de l’INPT, conduit à trois du 18 juin au 1^{er} août 2026, sous encadrement d’entreprise.
- L’énoncé impose quatre exigences qui structurent tout le rapport : corrélations dynamiques, contraintes réalistes de gestion, évaluation hors échantillon, et pertinence financière — et il n’exige nulle part que le ML l’emporte.
- Le périmètre exclut délibérément le temps réel, l’exécution d’ordres, l’hébergement et la couverture de change, afin de concentrer l’effort sur la qualité de la décision d’allocation.

- Les onze premiers jours, sans code, ont produit la contrainte de données la plus structurante du projet — celle qui a imposé d'évaluer chaque stratégie sur deux univers plutôt qu'un.

Chapitre 2

Problématique : de l'allocation d'actifs à ses quatre échecs

Ce que ce chapitre explique

Ce chapitre pose le problème que le projet cherche à résoudre. Il est écrit pour être lu sans connaissance préalable de la finance de marché : chaque notion est définie au moment où elle apparaît, et chaque formule est précédée de la phrase qui dit ce qu'elle signifie.

Le fil est le suivant. Nous partons d'une question simple — comment répartir une somme d'argent entre plusieurs placements? — et nous montrons que la réponse classique, formulée par Harry Markowitz en 1952 et encore enseignée aujourd'hui, repose sur quatre hypothèses qui ne tiennent pas en pratique. Ces quatre échecs, notés **P1** à **P4**, structurent l'intégralité du travail présenté dans ce rapport : chaque composant développé y répond explicitement.

2.1 Le problème, en une phrase

Une banque, une compagnie d'assurance ou un particulier dispose d'une somme d'argent et doit la répartir entre plusieurs placements. Combien mettre sur chacun ?

La question paraît anodine. Elle ne l'est pas : c'est l'une des décisions les plus lourdes de conséquence en gestion financière, parce qu'elle détermine à la fois ce que l'on peut espérer gagner et ce que l'on risque de perdre. Et elle n'a pas de réponse évidente, parce que les deux objectifs — gagner davantage et risquer moins — s'opposent presque toujours.

L'objet de ce projet est de construire un système capable de proposer automatiquement une telle répartition, à partir de données de marché, et de mesurer honnêtement si ce système fait mieux que les méthodes classiques.

2.2 Un portefeuille, un rendement, un risque

2.2.1 Le vocabulaire minimal

Un *actif* est un objet dans lequel on peut placer de l'argent : une action d'entreprise, une obligation d'État, un fonds indicel. Un *portefeuille* est simplement une répartition de capital entre plusieurs actifs : par exemple 40 % sur l'un, 35 % sur un deuxième, 25 % sur un troisième. Ces proportions sont appelées les *poids* du portefeuille ; par construction, elles totalisent 100 %.

Définition — Rendement

Le *rendement* d'un actif sur une période est la variation relative de sa valeur. Un actif passant de 100 à 105 dirhams sur un mois a produit un rendement de +5 % sur ce mois. Le rendement d'un portefeuille est la moyenne des rendements de ses actifs, *pondérée par les poids* : c'est mécanique, sans surprise.

Le rendement est la partie facile. La difficulté est ailleurs : un placement ne produit pas le même rendement chaque mois. Il monte, il descend, il repart. Cette irrégularité est ce que la finance appelle le *risque*, et sa mesure usuelle est la *volatilité*.

Définition — Volatilité

La *volatilité* est l'écart-type des rendements : elle mesure l'amplitude habituelle des variations autour de la moyenne. Deux placements peuvent rapporter 8 % par an en moyenne, l'un en variant de ± 2 % d'un mois sur l'autre, l'autre de ± 15 %. Le second est beaucoup plus risqué, bien que sa moyenne soit identique. C'est cette distinction que la volatilité capture.

2.2.2 Une image

Un gérant qui doit répartir un capital ressemble à un agriculteur qui doit répartir ses parcelles entre plusieurs cultures. Chaque culture a un rendement moyen espéré et une sensibilité propre au climat. L'agriculteur ne connaît ni le temps qu'il fera, ni les prix à la récolte ; il ne peut que raisonner sur ce que les saisons passées lui ont appris, en sachant que la prochaine ne leur ressemblera pas exactement.

Cette image, à laquelle nous reviendrons, contient déjà l'essentiel des difficultés traitées dans ce rapport : on décide aujourd'hui, on récolte demain, et l'on ne dispose que du passé pour s'orienter.

2.3 La diversification, et pourquoi elle fonctionne

L'adage — ne pas mettre tous ses œufs dans le même panier — est connu de tous. Sa traduction financière est plus précise, et c'est cette précision qui compte.

Si deux placements montent et descendent *en même temps*, les répartir entre eux ne réduit presque rien : quand l'un chute, l'autre chute aussi. Si en revanche ils évoluent *indépendamment*, ou mieux encore en sens contraire, alors les mauvaises périodes de l'un sont partiellement compensées par les bonnes de l'autre. Le portefeuille dans son ensemble varie moins que chacune de ses composantes.

La grandeur qui mesure ce phénomène est la *corrélation*.

Définition — Corrélation et covariance

La *corrélation* entre deux actifs est un nombre compris entre -1 et $+1$. À $+1$, ils évoluent exactement de concert ; à 0 , leurs mouvements sont sans rapport ; à -1 , ils s'opposent systématiquement. La *covariance* est la même idée, exprimée dans les unités des rendements plutôt que normalisée. Rangées dans un tableau croisant tous les actifs deux à deux, ces

covariances forment la *matrice de covariance*, notée Σ : c'est l'objet central de toute la théorie qui suit.

Le point à retenir, et il porte tout le reste du rapport : **la valeur de la diversification ne dépend pas des actifs pris isolément, mais de la manière dont ils bougent les uns par rapport aux autres.** Un portefeuille se juge sur ses corrélations autant que sur ses rendements.

2.4 Markowitz (1952) : formaliser l'intuition

Harry Markowitz a transformé cette intuition en un problème mathématique posé et résolu, ce qui lui a valu le prix Nobel d'économie en 1990. Son raisonnement tient en trois temps.

1. À partir de l'historique, on estime le rendement moyen espéré de chaque actif (noté μ) et la matrice de covariance Σ .
2. Pour tout portefeuille de poids w , on calcule alors son rendement espéré $w^\top \mu$ et sa volatilité $\sqrt{w^\top \Sigma w}$.
3. On cherche enfin les poids w qui, pour un niveau de risque donné, maximisent le rendement espéré.

L'ensemble des portefeuilles ainsi obtenus forme une courbe appelée *frontière efficiente* (figure 2.1) : chaque point est un portefeuille dont on ne peut améliorer le rendement sans accepter davantage de risque. Tout portefeuille situé sous cette courbe est, au sens de ce critère, sous-optimal.

Pour comparer deux portefeuilles d'un seul chiffre, on rapporte le rendement au risque consenti.

Définition — Ratio de Sharpe

Le *ratio de Sharpe* divise le rendement d'un portefeuille par sa volatilité. Il répond à la question : « combien de rendement ce portefeuille produit-il par unité de risque supportée ? » Un Sharpe de 1,0 est généralement jugé bon, 0,5 médiocre. C'est la mesure de référence du secteur, et celle que ce rapport emploie le plus souvent — non sans réserves, sur lesquelles nous reviendrons au chapitre 5.

Cette construction est élégante, enseignée partout, et implémentée dans tous les outils professionnels. Elle a pourtant une réputation ambivalente auprès des praticiens. La raison tient en une phrase : **elle suppose connus des paramètres qui ne le sont pas.**

2.5 Les quatre échecs de la théorie classique

Markowitz suppose que μ et Σ sont donnés. Dans la réalité, on ne les connaît jamais : on les *estime* à partir du passé, et cette estimation est la source de quatre difficultés distinctes. Ces quatre problèmes structurent tout le projet ; chaque composant décrit aux chapitres suivants indique explicitement auxquels il répond.




FIG. 2.1: La frontière efficiente, calculée sur les actifs réels du projet. Chaque point gris est un portefeuille tiré au hasard ; la courbe bleue rassemble ceux qu'aucun autre ne domine. Les actifs pris individuellement (points rouges) se situent tous à l'intérieur de la frontière : c'est la diversification, rendue visible.




FIG. 2.2: Les quatre échecs structurels de l'optimisation moyenne-variance classique, et la réponse apportée par le système développé. Chaque fonction du code source déclare, dans sa documentation, le ou les problèmes qu'elle adresse — une exigence de traçabilité vérifiée automatiquement par la suite de tests.

2.5.1 P1 — L'estimation est bruitée

Estimer une corrélation entre deux actifs à partir de quelques centaines d'observations donne une valeur approximative. Avec neuf actifs, il faut estimer 36 corrélations et 9 volatilités simultanément, à partir du même historique limité. Chacune porte son erreur.

Le problème n'est pas seulement que ces estimations soient imprécises : c'est que l'optimiseur les traite comme exactes. S'il lit dans les données qu'un actif possède une corrélation légèrement plus faible que les autres — un pur accident d'échantillonnage — il conclut que cet actif est un excellent diversificateur et lui attribue un poids considérable. L'optimiseur ne distingue pas le signal du bruit ; il amplifie ce dernier.

On résume souvent ce comportement en disant que l'optimisation moyenne-variance est un maximiseur d'erreur d'estimation. Ce n'est pas une critique de la méthode, mais de son usage naïf : elle donne exactement ce qu'on lui demande, à partir d'entrées dont on a négligé l'incertitude.

Le résultat pratique est un portefeuille concentré sur quelques positions, qui paraît optimal sur l'historique utilisé pour le construire, et se comporte médiocrement sur les données suivantes.

2.5.2 P2 — Le monde ne reste pas immobile

La théorie suppose implicitement que les rendements sont tirés d'une même loi de probabilité, stable dans le temps. Les marchés ne se comportent pas ainsi. Ils traversent des *régimes* : des périodes calmes et haussières, des périodes agitées et baissières, avec des transitions parfois brutales.

Concrètement, la volatilité se regroupe — les journées agitées se suivent — et les corrélations elles-mêmes se déforment. Des paramètres estimés sur une période calme décrivent mal la période de tension qui suit.

C'est précisément ce que le *Machine Learning* peut apporter : plutôt que de supposer un monde unique, on peut apprendre à reconnaître dans quel régime le marché se trouve, et adapter la posture du portefeuille en conséquence.

2.5.3 P3 — La diversification disparaît quand elle devient nécessaire

C'est le plus contre-intuitif des quatre, et le plus coûteux.

En période normale, des actifs variés — actions marocaines, actions américaines, or, obligations — évoluent avec une certaine indépendance. La diversification fonctionne. Mais en période de crise, les investisseurs vendent *simultanément* tout ce qu'ils peuvent vendre pour se procurer des liquidités. Les corrélations convergent alors vers 1 : tout baisse ensemble.

Autrement dit : la protection que l'on a payée toute l'année en acceptant un rendement moindre cesse d'agir exactement le jour où l'on en a besoin. Les parapluies se referment quand la pluie commence.

Ce phénomène n'est pas théorique, et les données du projet permettent de le mesurer. Elles apportent toutefois une nuance que la formulation usuelle omet, et qui mérite d'être exposée telle quelle.




FIG. 2.3: Volatilité glissante du marché sur l'univers ETF du projet (2004–2026). Les périodes d'agitation sont manifestement groupées et non réparties uniformément : c'est la non-stationnarité (P2), visible à l'œil nu. Les zones ombrées correspondent aux crises identifiées au chapitre 5.

Si l'on calcule simplement la corrélation moyenne sur *tous* les couples d'actifs de l'univers, on obtient 0,24 en période calme et 0,16 en crise : la corrélation *baisse*, ce qui contredit apparemment P3. Cette moyenne est trompeuse, car elle agrège deux mouvements opposés. En les séparant (figure 2.4) :

- **entre actions** (SPY, QQQ, EEM), la corrélation passe de 0,79 en période calme à 0,85 en crise, et culmine à 0,94 lors du krach de mars 2020. P3 se vérifie pleinement : à l'intérieur d'une même classe d'actifs, tout chute ensemble ;
- **entre actions et valeurs refuges** (or, obligations d'État longues), la corrélation, déjà quasi nulle en temps normal ($-0,04$), devient nettement négative en crise ($-0,18$) : c'est la fuite vers la qualité, ces actifs montant lorsque les actions s'effondrent.

La leçon est double, et elle oriente toute la suite du travail. D'une part P3 est bien réel, mais il s'exprime au sein d'une classe d'actifs. D'autre part une diversification véritablement multi-classes conserve une partie de son efficacité en crise — à condition que le portefeuille puisse effectivement se déplacer vers les actifs qui se découplent. C'est exactement ce que fait l'optimisation sous contrainte, et le chapitre 5 montre qu'elle protège en crise là où une répartition figée ne le fait pas.

2.5.4 P4 — Se tromper soi-même : le surapprentissage

Les trois premiers problèmes concernent les marchés. Le quatrième concerne l'analyste, et c'est celui auquel ce projet a consacré le plus d'efforts.

Pour évaluer une stratégie, on la teste sur des données historiques : c'est le *backtest*. L'exercice est indispensable — et il est piégeux, pour deux raisons distinctes.




FIG. 2.4: Corrélations glissantes (63 jours) sur l'univers ETF, décomposées par famille. En crise (zones ombrées), les actions se resserrent entre elles tandis que l'or et les obligations s'en détachent. Une moyenne calculée sur l'ensemble des couples masquerait ces deux effets en les compensant l'un par l'autre — d'où la décomposition retenue ici.

Le biais d'anticipation (*lookahead*). Il consiste à utiliser, au moment de décider, une information qui n'était pas encore disponible. Il prend des formes très discrètes : normaliser des données sur l'historique complet avant de découper le test, employer un cours de clôture non encore publié, ou choisir un paramètre en observant le résultat final. Une stratégie affectée d'un biais d'anticipation affiche des performances remarquables et ne les reproduit jamais en conditions réelles.

Le surapprentissage par répétition. Il est plus insidieux encore. En essayant cinquante stratégies sur le même historique, on en trouvera mécaniquement une qui paraît excellente — même si aucune n'a la moindre valeur. C'est le hasard, et non la compétence, qui produit ce résultat. Publier la meilleure sans mentionner les quarante-neuf autres revient à publier un mensonge statistique, souvent commis de bonne foi.

C'est le problème que l'encadrement du projet a désigné comme le critère de correction le plus important : tout chemin par lequel une donnée future pourrait influencer une décision passée constitue un échec automatique. Le chapitre 3 montre comment cette exigence a été traduite en une garantie structurelle plutôt qu'en une règle de discipline.

2.6 Ce que le Machine Learning peut — et ne peut pas — apporter

Il serait tentant de présenter le *Machine Learning* comme la solution à ces quatre problèmes. Ce serait inexact, et le présent rapport se garde de le faire.

Ce qu'il peut raisonnablement apporter. Sur P1 et P2, l'apport est tangible : des estimateurs de covariance plus élaborés qu'une simple moyenne historique (rétrécissement de Ledoit-Wolf, moyennes exponentielles, modèles GARCH) réduisent l'erreur d'estimation, et des modèles à variables latentes (chaînes de Markov cachées) permettent de détecter un changement de régime sans qu'on ait à le spécifier à l'avance. Sur P4, le *Machine Learning* apporte surtout sa *méthodologie* d'évaluation — validation croisée adaptée aux séries temporelles, correction du nombre d'essais, intervalles de confiance.

Ce qu'il ne peut pas apporter. La prédiction fiable des rendements futurs. C'est l'application que l'on attend spontanément, et c'est la plus difficile : le rapport signal/bruit des rendements financiers est extrêmement faible, et les marchés sont compétitifs par nature — toute régularité exploitable tend à disparaître dès qu'elle est exploitée. Le chapitre 5 présente cinq tentatives indépendantes menées dans ce projet pour exploiter une telle prédiction, et le résultat honnête auquel elles conduisent.

Une distinction méthodologique importante, et vérifiée expérimentalement au chapitre 5 : améliorer la précision de prédiction d'un modèle n'améliore pas nécessairement la performance du portefeuille qui en découle. Ce sont deux objectifs différents, et le second n'est pas une conséquence automatique du premier.

2.7 Les contraintes réalistes de gestion

Un dernier élément sépare l'exercice académique d'un prototype crédible : un gérant professionnel n'est jamais libre de choisir n'importe quelle répartition. Il opère sous contraintes, imposées par la réglementation, par son mandat ou par la prudence.

- **Pas de vente à découvert** — les poids sont positifs : on ne peut pas parier à la baisse sur un actif.
- **Un plafond par actif** — dans ce projet 25 %, afin d'éviter les portefeuilles excessivement concentrés.
- **Des coûts de transaction** — chaque transaction se paie. Le projet retient 10 points de base sur les ETF internationaux et 30 sur les valeurs de la Bourse de Casablanca, moins liquides.

Le cahier des charges du client formule explicitement cette exigence de « contraintes réalistes de gestion ». Elle a été traitée non comme une mesure secondaire, mais comme une contrainte à part entière de l'optimiseur et du simulateur. Nous verrons au chapitre 5 que cette décision, prise pour des raisons de réalisme métier, s'est révélée produire l'un des résultats les plus marquants du projet.

2.8 Problématique retenue

L'ensemble de ce qui précède se résume en une problématique en trois volets, qui sont ceux du présent rapport :

1. **Construire** un système d'allocation de portefeuille exploitant le *Machine Learning* pour répondre à P1, P2 et P3, sous des contraintes de gestion réalistes, et sur un univers combinant valeurs de la Bourse de Casablanca et ETF internationaux.
2. **Évaluer** ce système avec une rigueur suffisante pour que P4 ne puisse pas invalider les conclusions : absence de biais d'anticipation garantie par construction, données de test jamais utilisées pour le choix des paramètres, et intervalles de confiance sur chaque chiffre publié.
3. **Rapporter** honnêtement ce que le système apporte et ce qu'il n'apporte pas — un résultat négatif correctement établi ayant, dans ce domaine, davantage de valeur qu'un résultat positif invérifiable.

2.9 État de l'art

Les travaux sur lesquels le projet s'appuie sont les suivants.

Markowitz (1952), *Portfolio Selection*. Le texte fondateur, qui introduit le cadre moyenne-variance et la frontière efficiente. Il constitue la référence par rapport à laquelle tout le reste se compare.

DeMiguel, Garlappi et Uppal (2009), *Optimal Versus Naive Diversification*. Résultat célèbre et dérangeant : sur de nombreux jeux de données, le portefeuille équipondéré — répartir également, sans rien estimer — fait aussi bien, voire mieux, que les portefeuilles optimisés, une fois les coûts pris en compte. Précisément parce qu'il n'estime rien, il ne peut pas surapprendre le bruit. Ce portefeuille sert dans ce projet de *haie d'honnêteté* : toute méthode sophistiquée doit d'abord démontrer qu'elle le dépasse.

Ledoit et Wolf (2004), *shrinkage de covariance*. Réponse statistique directe à P1 : rapprocher la matrice de covariance empirique d'une cible structurée, avec une intensité estimée sur les données elles-mêmes.

Engle (2002), *Dynamic Conditional Correlation*. Réponse à P2 au niveau de l'estimation : un modèle où volatilités et corrélations évoluent dans le temps plutôt que d'être supposées constantes.

Jagannathan et Ma (2003), *Risk Reduction in Large Portfolios*. Résultat théorique important pour ce projet : imposer une contrainte de poids active équivaut mathématiquement à opérer un rétrécissement de la matrice de covariance. Autrement dit, une contrainte de gestion réaliste effectue implicitement le travail de régularisation que l'on attend d'une méthode sophistiquée. Le chapitre 5 reproduit ce résultat sur les données du projet.

López de Prado (2018), *Advances in Financial Machine Learning*. Ouvrage de référence sur P4. Deux outils en sont directement repris : la *purge* et *embargo* — qui retirent du jeu d'entraînement les observations temporellement voisines du jeu de validation, appliqués ici dans un découpage strictement antérieur plutôt qu'en blocs (chapitre 4) — et le *Deflated Sharpe Ratio* de Bailey et López de Prado (2014), qui corrige un ratio de Sharpe observé du nombre de stratégies essayées pour l'obtenir.

Synthèse du chapitre

L'allocation de portefeuille consiste à répartir un capital entre plusieurs actifs de manière à maximiser le rendement tout en maîtrisant le risque. La théorie classique de Markowitz formalise ce compromis, mais suppose connus des paramètres qui doivent en réalité être estimés à partir d'un historique limité. Il en découle quatre difficultés : l'amplification du bruit d'estimation (P1), la non-stationnarité des marchés (P2), l'effondrement de la diversification en période de crise (P3), et le risque que l'analyste se trompe lui-même en évaluant sa propre stratégie (P4).

Le *Machine Learning* offre des réponses crédibles à P1 et P2, une réponse partielle à P3, et surtout — c'est le point le moins attendu — un appareil méthodologique pour traiter P4. Il n'offre pas, en revanche, de prédiction fiable des rendements futurs.

Le chapitre suivant décrit l'architecture du système construit pour répondre à cette problématique, en commençant par l'infrastructure de données sur laquelle tout le reste repose.

Chapitre 3

Architecture : la chaîne de données et les garde-fous

Ce que ce chapitre explique

Le chapitre 2 a posé quatre échecs à corriger. Celui-ci décrit la machine construite pour y répondre — non pas les modèles eux-mêmes, qui font l’objet du chapitre suivant, mais la chaîne qui les alimente et le dispositif qui les surveille.

Le fil conducteur tient en une phrase, et c’est la décision d’ingénierie la plus structurante du projet : **une règle importante n’est pas documentée, elle est rendue exécutable**. Interdire à un modèle de consulter le futur, garantir que deux documents citent le même chiffre, imposer que chaque fonction déclare le problème qu’elle traite — chacune de ces règles est, dans ce dépôt, un test qui échoue si on la viole. La raison est empirique : les trois incidents les plus coûteux du projet, relatés en fin de chapitre, ont tous consisté en une règle respectée par discipline jusqu’au jour où elle ne l’a plus été, sans que rien ne le signale.

3.1 Trois couches, une seule direction

Les données brutes d’un marché financier sont hétérogènes : des cours d’actions marocaines relevés à la Bourse de Casablanca, des cours de fonds indiciels américains, des indicateurs macroéconomiques publiés par la Réserve fédérale américaine et par Bank Al-Maghrib. Chaque source a son calendrier, son format, ses trous et ses erreurs. Les mélanger sans discipline produit un jeu de données dont plus personne ne sait comment il a été fabriqué.

Définition — Architecture en médaillon

Organisation d’un entrepôt de données en couches successives, chacune obtenue par transformation *déterministe* de la précédente : **Bronze** (les données telles que reçues, jamais modifiées), **Silver** (les mêmes données alignées, nettoyées et validées), **Gold** (les tableaux directement exploitables par un modèle). Une couche ne lit jamais une couche située en aval d’elle ; l’information ne circule que dans un sens.

Ce projet applique ce patron strictement (tableau 3.1). Son intérêt n’est pas esthétique : il rend chaque anomalie *localisable*. Si un chiffre final surprend, il existe exactement une couche où l’erreur a pu naître, et les couches amont sont intactes pour le prouver.

Deux conventions méritent d’être signalées, parce qu’elles paraissent techniques et sont en réalité

TAB. 3.1: Les trois couches de données, leur contenu et la garantie que chacune apporte.

Couche	Contenu	Garantie apportée
Bronze	Cours ETF, cours et dividendes BVC, indicateurs macro, taux de change — au format reçu.	Immuable. Une source qui change produit un nouveau fichier, jamais une réécriture : l'historique reste auditable.
Silver	Rendements logarithmiques, calendriers alignés (la Bourse de Casablanca et les places américaines ne ferment pas les mêmes jours), zones d'illiquidité signalées.	Validée à l'écriture par un contrat de données : rendement journalier borné à $\pm 50\%$, au moins 500 lignes, index trié, aucune valeur manquante. Une violation interrompt le traitement.
Gold	Deux matrices de rendements (une par univers), variables ML causales, tests de stationnarité, résultats des comparaisons de stratégies.	Seule couche que la modélisation a le droit de lire. Aucun modèle n'ouvre un fichier Bronze ou Silver.

des décisions de fond.

Les rendements sont logarithmiques, c'est-à-dire calculés comme $\ln(P_t/P_{t-1})$ plutôt que comme la variation en pourcentage. La raison est qu'ils s'additionnent : le rendement d'une semaine est la somme des cinq rendements quotidiens, ce qui n'est pas vrai des pourcentages. Toute la chaîne en dépend.

Les trous de calendrier sont comblés vers l'avant, jamais vers l'arrière. Si la Bourse de Casablanca est fermée un jour où New York est ouverte, on reporte le dernier cours *connu*. Comblé avec le cours *suivant* — techniquement plus simple, et proposé par toutes les bibliothèques — reviendrait à injecter dans le passé une information du futur. C'est la première forme, et la plus discrète, du biais que le chapitre 2 a appelé P4.

3.2 Deux univers, et un manque assumé

Le portefeuille visé par EURAFRIC mêle quatre valeurs de la Bourse de Casablanca — Maroc Telecom, Attijariwafa Bank, CIH Bank, Banque Centrale Populaire — et cinq fonds indiciels internationaux couvrant les grandes actions américaines, les technologiques, les marchés émergents, l'or et les obligations d'État.

Un obstacle est apparu dès la première semaine : **aucune source gratuite ne fournit l'historique de la Bourse de Casablanca avant la mi-2021**. Le portefeuille complet ne peut donc pas être étudié sur le krach de 2020, ni sur la crise de 2008. Plutôt que de dissimuler cette limite ou d'acheter un historique, nous avons adopté une **double base de test** (tableau 3.2) : toute stratégie est évaluée sur les deux univers, et les deux résultats sont publiés côte à côte.

TAB. 3.2: Les deux univers d'évaluation. Toute stratégie du projet est exécutée sur les deux, sans exception.

Univers	Actifs	Jours	Période et intérêt
full_2021	9	1 321	2021-07 → 2026-07 — le portefeuille réel visé
etf_2017	5	5 656	2004-11 → 2026-07 — inclut 2008, 2020 et 2022

Ce choix a un coût de rédaction — il faut commenter deux résultats au lieu d'un, et ils ne

concordent pas toujours — mais il a une vertu décisive : une conclusion qui ne tient que sur un seul univers se voit immédiatement. Le chapitre 5 montre que c’est précisément le cas du résultat principal.

L’univers ETF a été étendu de 2017 à 2004 en cours de projet, lorsque nous avons constaté que la date de départ initiale était une décision arbitraire et non une limite des données. Les douze années supplémentaires ont réduit la largeur des intervalles de confiance d’environ 38 % et ajouté la crise de 2008. Le nom technique de l’univers, `etf_2017`, est resté : le renommer aurait invalidé les artefacts déjà produits, pour un gain purement cosmétique.

3.3 Le dividende manquant : un défaut trouvé tardivement

Cet épisode est rapporté en détail parce qu’il illustre mieux que tout autre le type de défaut contre lequel l’architecture doit protéger : silencieux, non détecté par les tests existants, et *favorable* au résultat que nous espérions.

Définition — Dividende

Part du bénéfice qu’une entreprise verse à ses actionnaires, généralement une fois par an. Un actionnaire gagne donc de deux manières : la hausse du cours, et les dividendes encaissés. Ne compter que la première revient à sous-estimer durablement ce que l’actif a réellement rapporté.

La chaîne mélangeait deux définitions du rendement sans que personne ne l’ait décidé. Les cours des fonds indiciels arrivaient *ajustés des dividendes* (rendement total), tandis que les cours de la Bourse de Casablanca arrivaient *hors dividendes*. Les rendements du dividende publiés pour ces quatre valeurs s’échelonnent de 3,8 % à 5,5 % par an : c’est l’ordre de grandeur de la performance qui disparaissait chaque année du côté marocain.

L’instinct veut qu’un biais commun s’annule dans une comparaison. **Il ne s’annule pas ici**, et la raison est instructive. La stratégie équilibrée est *contrainte* de détenir les actifs sous-évalués ; les optimiseurs sont *libres* de les sous-pondérer — et ils l’ont fait, précisément parce que le dividende manquant les faisait paraître moins bons qu’ils ne l’étaient. Les modèles étaient donc crédités d’avoir évité un défaut de notre propre traitement de données. Le biais gonflait mécaniquement l’avantage mesuré du ML.

La correction a nécessité d’écrire un collecteur dédié : l’interface publique prévue à cet effet dans la bibliothèque utilisée était hors service, et les montants ont dû être extraits du site de la Bourse de Casablanca, *avec leur date de détachement* — car un dividende doit être crédité le jour où il est effectivement versé, non réparti sur l’année. Les montants obtenus concordent avec une source indépendante à environ 0,3 point de pourcentage près.

Effet de la correction

Le gain du système ML sur le portefeuille EURAFRIC passe de +14,3 % à +6,2 % — soit **moins de la moitié** de ce qui avait été publié. Un second résultat, présenté depuis le début du projet, ne survit pas du tout : l’équipondération ne bat plus les optimiseurs une fois les coûts déduits.

Trois conséquences ont été tirées, et elles sont toutes de nature architecturale. Le cache de divi-

dendes est devenu une *dépendance déclarée* du pipeline — auparavant, l’unique donnée qui rend les rendements marocains complets était invisible des deux graphes de dépendances du projet. Un échec de collecte *interrompt* désormais le traitement au lieu d’émettre un avertissement que personne ne lit sur une exécution nocturne ; une collecte *vide* compte comme un échec, car un résultat à zéro ligne est la même corruption déguisée en succès. Enfin — et c’est le point le plus embarrassant — la suite de tests atteignait le réseau réel : en masquant le cache, les tests restaient *verts* tout en écrivant des rendements hors dividendes. Un blocage des connexions sortantes, actif par défaut dans toute la suite, ferme définitivement ce trou.

3.4 Le moteur de backtest, frontière de confiance

Définition — Backtest à fenêtre glissante

Simulation d’une stratégie sur des données passées, où l’on rejoue le temps *comme il s’est écoulé* : à chaque date de rééquilibrage, le modèle est réentraîné sur les seules données disponibles à cette date, décide une répartition, puis subit les rendements des jours suivants. Toute autre méthode mesure une performance impossible à obtenir en pratique.

Le composant le plus important du projet n’est pas un modèle : c’est le moteur qui les exécute. Il est écrit une fois, au chapitre du projet correspondant à la phase 2, et *aucune* des extensions ultérieures ne l’a modifié.

Sa conception repose sur une inversion de responsabilité. Une stratégie ne va pas chercher ses données : elle reçoit, en argument, une fenêtre d’entraînement que le moteur a découpée pour elle. Le moteur tronque la matrice de rendements *et chaque tableau de variables auxiliaire* à la date de décision avant tout appel. Une stratégie ne peut donc pas consulter le futur, non parce qu’elle s’en abstient, mais parce qu’elle ne le reçoit jamais. Symétriquement, le moteur *vérifie* ce qu’il reçoit en retour : poids positifs, somme égale à un, plafond de 25 % respecté. Un producteur défectueux est rejeté à la frontière.

Cinq tests verrouillent cette propriété. Le plus parlant construit une stratégie *tricheuse*, à qui l’on transmet délibérément l’intégralité du jeu de données et qui choisit chaque mois l’actif le plus performant du mois suivant. Passée par le moteur, sa performance doit s’effondrer à zéro. Si elle ne s’effondre pas, le moteur fuit. Un second test corrompt le *futur* d’un tableau de variables et exige qu’*aucune* décision passée n’en soit modifiée — tout en vérifiant que la stratégie utilise réellement ces variables, faute de quoi la garantie serait vide de sens.

Le moteur applique aussi les contraintes de gestion réelles : interdiction de vendre à découvert, plafond de 25 % par actif, et surtout des coûts de transaction déduits à chaque rééquilibrage — 10 points de base sur les fonds indiciels, 30 sur la Bourse de Casablanca, dont la liquidité est plus faible. Les performances brute et nette sont toujours rapportées ensemble : une stratégie qui gagne brut et perd net est un résultat, pas un incident.

3.5 Rendre les règles exécutables

Le dépôt compte **plus de 580 tests**, exécutés hors ligne et sur des jeux de données synthétiques minuscules. Leur nombre importe moins que leur nature : la majorité ne vérifie pas qu’une fonction calcule juste, mais qu’une *règle de projet* ne peut pas être enfreinte. Ils sont d’ailleurs

nommés d’après la règle qu’ils protègent, non d’après la fonction qu’ils appellent, de sorte que la suite se lit comme la liste des erreurs déjà commises.

- **Absence de vision du futur** — les cinq tests décrits ci-dessus, plus un test d’intégration par famille de modèles ajoutée ensuite.
- **Hermétisme** — toute connexion sortante est bloquée pendant les tests. C’est ce qui rend l’affirmation « la suite s’exécute hors ligne » vérifiable plutôt que déclarative.
- **Cohérence entre documents** — un test compare tous les fichiers de résultats publiés et échoue s’ils divergent sur une stratégie commune, une fenêtre d’évaluation ou une valeur de référence. Il a été validé en rejouant sur une copie les trois incidents réels du projet : il les détecte tous les trois, alors que chacun n’avait été repéré que par hasard.
- **Aucun chiffre écrit à la main** — un test lit le *code source* de la couche qui alimente le tableau de bord et refuse toute valeur de performance saisie en dur. Une surface destinée à un décideur est le pire endroit où laisser un chiffre périmé.
- **Traçabilité P1–P4** — la première exigence de l’encadrant est elle aussi vérifiée automatiquement : chaque fonction publique doit déclarer le ou les problèmes qu’elle traite. 107 fonctions sur 110 sont conformes ; les 3 exceptions sont des utilitaires d’infrastructure, inscrites avec leur justification dans une liste qui n’a le droit que de se réduire.

3.6 Reproduire, ordonnancer, tracer : trois outils, trois questions

Trois outils d’exploitation coexistent dans le projet. On les confond souvent ; ils répondent en réalité à trois questions différentes, et supprimer l’un d’entre eux laisserait sa question sans réponse.

3.6.1 DVC — « ce résultat correspond-il encore à ces données ? »

DVC décrit le traitement comme un graphe d’étapes, chacune déclarant ses entrées, sa commande et ses sorties (figure 3.1). Une seule commande recalcule alors *uniquement* ce qui est devenu obsolète, en comparant les empreintes des fichiers.

L’apport dépasse le confort. Le graphe rend le calcul *invalidable* : si une donnée amont change, tous les résultats qui en dépendent sont marqués périmés, qu’un humain s’en souvienne ou non. Le projet a appris cette leçon à ses dépens — le fichier contenant la performance de référence à battre n’était initialement pas suivi par le pipeline, et a dérivé d’une version de données sans que rien ne le signale. Il est aujourd’hui une sortie d’étape à part entière.

3.6.2 Dagster — « qu’est-ce qui doit se réexécuter, et quand ? »

Dagster planifie l’exécution et matérialise la lignée (figure 3.2) : neuf *actifs* de données, chacun rattaché à sa couche du médaillon, avec la date de leur dernière production. La règle imposée au projet est que Dagster *ordonnance* le traitement mais n’en contient aucune logique ; ses actifs appellent les fonctions du code source, inchangées.

Le pipeline DVC : dix étapes, un graphe de dépendances explicite





FIG. 3.1: Le pipeline de bout en bout : dix étapes et vingt-et-une dépendances explicites, de la collecte des sources aux chiffres affichés par le tableau de bord. Cette figure est *engendrée à partir du fichier de configuration du pipeline* : elle ne peut pas décrire une chaîne différente de celle réellement exécutée.



Asset name	Description	Code location / Asset group	Status
bvc_dividends	BVC per-share dividend history (amounts + ex-dates) scraped from casa...	definitions.py bronze	Materialized Jul 29, 11:00 PM
gold_layer	Stationarity report + lagged macro features — Phase 2 input.	definitions.py gold	Materialized Jul 29, 11:02 PM
log_returns	Calendar-aligned, Pandera-validated log-returns (9-asset universe), on a...	definitions.py silver	Materialized Jul 29, 11:02 PM
log_returns_ett	ETF-only log-returns (2017+), includes COVID + the 2022 rate shock) — L...	definitions.py silver	Materialized Jul 29, 11:02 PM
ml_features_layer	Phase 3 causal ML features (both universes) + reproducibility manifest ...	definitions.py gold	Materialized Jul 29, 11:02 PM
raw_bam_macro	Bank Al-Maghrib indicators (FX + policy rate).	definitions.py bronze	Materialized Jul 29, 11:00 PM
raw_bvc_prices	BVC (Bourse de Casablanca) equity prices.	definitions.py bronze	Materialized Jul 29, 11:00 PM
raw_ett_prices	ETF adjusted-close prices via yfinance.	definitions.py bronze	Materialized Jul 29, 11:02 PM
raw_fred_macro	Global macro indicators via FRED.	definitions.py bronze	Materialized Jul 29, 11:00 PM

FIG. 3.2: Catalogue Dagster : les neuf actifs de données du projet, leur description, la couche à laquelle ils appartiennent (**bronze**, **silver**, **gold**) et l'état de leur dernière matérialisation. Toute sortie censée se rafraîchir automatiquement doit figurer ici — une omission a coûté au projet deux semaines de dérive silencieuse entre ses deux univers.

3.6.3 MLflow — « d'où vient ce chiffre ? »

MLflow enregistre les *résultats* : pour chaque exécution, les paramètres employés, les métriques obtenues, le fichier source et le commit exact du code (figure 3.3). C'est le registre qui permet, six semaines après, de répondre à la question « ce Sharpe de 1,164, sur quelles données et avec quels réglages ? » sans relancer un calcul.

Ce registre a lui-même révélé un défaut lors de la préparation de ce chapitre : la version de MLflow employée n'écrivait que les fichiers joints dans le mode de stockage configuré, et abandonnait silencieusement paramètres et métriques. L'interface affichait des exécutions vides. La configuration a été corrigée et centralisée dans une fonction unique appelée par les six programmes concernés — et la valeur de référence régénérée est identique au bit près à celle publiée, ce qui confirme que seul l'enregistrement était en cause, non les calculs.

3.7 Ce que l'exploitation a appris

Deux incidents méritent d'être rapportés, parce qu'ils ne relèvent ni de la finance ni du ML, et que ce sont eux qui ont façonné les garde-fous décrits plus haut.

Un serveur de code périmé. La tâche nocturne a échoué plusieurs jours de suite sans que personne ne le sache. Le processus qui sert le code aux exécutions planifiées avait démarré *avant* la création d'un nouveau module ; il ne pouvait pas l'importer, et rechargeait bien les définitions mais jamais l'état d'importation de son interpréteur. Conséquence : un univers se mettait à jour, l'autre non — exactement la dérive que la double base de test rend visible. La correction technique fut d'une ligne (importer le module au chargement plutôt qu'à l'exécution, pour que la panne survienne immédiatement et bruyamment). La vraie correction fut un test :




FIG. 3.3: MLflow : détail d’une exécution. Les onze métriques enregistrées comprennent le ratio de Sharpe net (1,164 — la valeur de référence citée au chapitre 5), sa contrepartie brute, le drawdown, le turnover et le ratio de Sharpe déflaté. Le panneau de droite conserve le fichier lancé et le commit exact du code.

rien dans la suite n’importait le paquet d’ordonnancement, si bien que des centaines de tests passaient sur un pipeline incapable de démarrer.

Un artefact déchiré. Une longue exécution de modélisation et l’ordonnanceur nocturne partageaient le même répertoire de données. Le second a reconstruit la couche Gold *pendant* que la première la lisait : le fichier de résultats produit décrivait un univers avec des données au 24 juillet et l’autre avec des données plus récentes. Aucune erreur, aucun avertissement — un fichier parfaitement bien formé et faux. Les données ont été restaurées depuis le cache de versionnement, l’ordonnanceur arrêté, l’exécution refaite avec une assertion préalable sur la date des données. La leçon générale : **une exécution longue et un ordonnanceur actif ne doivent jamais partager un répertoire de données**, et c’est ce cas précis que le test de cohérence entre documents détecte désormais.

3.8 La pile technique

Deux choix négatifs méritent d’être mentionnés, car ils ont été délibérés. Une bibliothèque spécialisée de validation croisée pour la finance a été *écartée* au profit d’une implémentation interne d’une cinquantaine de lignes, son modèle de licence étant devenu restrictif : une dépendance dont l’accès peut disparaître n’a pas sa place au cœur d’un dispositif d’évaluation. Et aucun ordonnanceur d’entreprise n’a été retenu : le projet s’exécute sur une machine unique, et l’outil choisi cartographie directement les couches du médaillon.

TAB. 3.3: Principaux outils et rôle de chacun.

Outil	Rôle dans le projet
Python, pandas, NumPy	Langage et calcul numérique.
Parquet, DuckDB	Stockage en colonnes des trois couches ; requêtes analytiques sur la couche Gold.
Pandera	Contrats de données appliqués à l'écriture (Silver et Gold).
scikit-learn, SciPy	Rétrécissement de covariance de Ledoit-Wolf ; optimisation sous contrainte.
hmmlearn, arch	Modèles de régime à états cachés ; modèles de volatilité.
xgboost	Modèles de prédiction de rendement (chapitre 4).
DVC	Versionnement des données et graphe de reproductibilité.
Dagster	Ordonnancement local et lignée des actifs.
MLflow	Journal des expériences : paramètres, métriques, code.
Streamlit, FastAPI	Tableau de bord à deux pages et interface REST.
pytest	Plus de 580 tests, hors ligne, exécutés à chaque modification.

Synthèse du chapitre

- Les données transitent par trois couches à sens unique, chacune validée à l'écriture ; la modélisation ne lit que la dernière.
- L'absence d'historique marocain avant 2021 est une limite assumée, compensée par une **double base de test** — toute stratégie est jugée sur deux univers, et les désaccords entre eux sont publiés.
- Le moteur de backtest, écrit une fois et jamais modifié, est une **frontière de confiance** : il découpe les données que les modèles reçoivent et valide les décisions qu'ils rendent. L'impossibilité de voir le futur est un test, pas une convention.
- Les règles qui comptent sont exécutables : hermétisme des tests, cohérence entre documents publiés, interdiction des chiffres écrits à la main, traçabilité P1–P4 (107 fonctions sur 110).
- DVC, Dagster et MLflow répondent à trois questions distinctes — *ce résultat est-il à jour, quand doit-il se recalculer, d'où vient ce chiffre*. Les trois incidents d'exploitation du projet ont chacun consisté en une réponse devenue fausse sans que rien ne le signale ; ils ont tous donné lieu à un garde-fou automatique.

Chapitre 4

Modélisation et protocole d'évaluation

Ce que ce chapitre explique

Le chapitre précédent a décrit la chaîne qui produit les données et le moteur qui exécute les stratégies. Celui-ci décrit *les stratégies elles-mêmes* — quatre familles de modèles, construites l'une après l'autre — puis le dispositif qui décide si elles valent quelque chose.

Ce chapitre ne contient volontairement **aucun résultat chiffré**. Le protocole d'évaluation doit pouvoir être lu, compris et contesté indépendamment des conclusions qu'il produit ; si les deux étaient présentés ensemble, un lecteur ne pourrait plus distinguer un protocole conçu pour être juste d'un protocole conçu pour donner raison. Les chiffres sont au chapitre 5.

Deux principes de méthode gouvernent tout ce qui suit.

Une seule chose change à la fois. Les modèles sont ajoutés par *échelons*, chacun ne modifiant qu'un ingrédient du précédent. Un gain devient alors attribuable : on sait *à quoi* il est dû. C'est le contraire de la démarche qui consiste à assembler d'emblée le système le plus sophistiqué possible et à constater qu'il fonctionne, sans pouvoir dire pourquoi.

Rien ne touche au moteur. Toutes les stratégies décrites ci-dessous respectent la même interface : elles reçoivent une fenêtre d'entraînement et retournent une répartition. Aucune n'a nécessité de modifier le moteur de backtest ni ses garanties. C'est ce qui rend leurs performances comparables : elles ont été mesurées par le même instrument, sans exception.

4.1 Les références classiques

Quatre stratégies non-ML servent de référence. Elles ne sont pas un échauffement : ce sont les concurrentes que le ML doit battre, et l'une d'elles est notoirement difficile à battre.

- **L'équipondération** — la même somme sur chaque actif. Aucun paramètre, aucune estimation, donc aucune erreur d'estimation possible. La littérature établit qu'elle bat, une fois les coûts déduits, la plupart des optimiseurs ; c'est la référence honnête par excellence.
- **La variance minimale** — la répartition qui minimise la volatilité du portefeuille, sans chercher à prévoir les rendements.
- **La variance minimale à covariance rétrécie** — la même, avec la correction d'estimation décrite plus bas.

- **Le Markowitz classique** (Sharpe maximal) — la formulation de 1952 : on maximise le rendement attendu par unité de risque, en estimant les rendements attendus par leur moyenne historique.

Toutes s'exécutent sous les contraintes réelles décrites au chapitre 3 — pas de vente à découvert, plafond de 25 % par actif, coûts de transaction déduits — et sur les deux univers.

4.2 Premier échelon : mieux estimer le risque (P1)

Le problème P1 est celui de l'*erreur d'estimation*. La matrice de covariance — qui décrit comment les actifs bougent ensemble — doit être estimée à partir d'un échantillon fini. Avec neuf actifs, elle comporte 45 quantités distinctes à estimer ; chacune est bruitée, et l'optimiseur, qui cherche l'extremum, se précipite précisément sur les combinaisons où le bruit lui est favorable. Il produit alors un portefeuille concentré, magnifique sur le passé et fragile sur l'avenir.

Quatre échelons ont été construits, du plus simple au plus élaboré.

1. **Covariance empirique** — la moyenne des co-mouvements observés. Le point de départ, et le plus exposé au bruit.
2. **Rétrécissement de Ledoit-Wolf** — on mélange la matrice observée avec une matrice « naïve » très structurée, dans une proportion calculée automatiquement. On accepte un biais volontaire contre une forte réduction de variance. C'est le compromis classique de la statistique : une estimation légèrement fausse mais stable bat une estimation juste en moyenne mais instable.
3. **Covariance à mémoire exponentielle** — les observations récentes pèsent davantage que les anciennes, avec une décroissance géométrique. C'est la première réponse au problème P2 : si le marché change de régime, l'année dernière est plus informative que la précédente.
4. **DCC-GARCH** — le modèle le plus élaboré de la chaîne. Il estime d'abord, actif par actif, un modèle de volatilité variable dans le temps (les fortes secousses en appellent d'autres, phénomène bien documenté), puis fait évoluer les *corrélations* elles-mêmes selon leur propre dynamique.

Le quatrième échelon a demandé un travail d'implémentation réel : la bibliothèque employée fournit uniquement des modèles de volatilité univariés. La réursion multivariée d'Engle (2002) et l'estimation de ses deux paramètres par maximum de vraisemblance ont donc été écrites à la main. Une sécurité l'accompagne : si l'estimation ne converge pas pour un actif, la stratégie retombe sur le rétrécissement de Ledoit-Wolf en journalisant un avertissement. Ce chemin est testé et instrumenté ; son taux d'activation sur l'instantané de release est rapporté avec les résultats au chapitre 5, plutôt que déduit d'une observation historique.

4.3 Deuxième échelon : reconnaître le régime de marché (P2, P3)

Définition — Modèle de Markov caché

Modèle statistique supposant que les observations (ici : rendement du marché, volatilité récente, corrélation moyenne entre actifs) sont engendrées par un *état* non observable qui change au cours du temps. On ne voit jamais l'état directement ; on l'infère à partir de ce qu'il produit. Le modèle est *non supervisé* : on ne lui fournit aucune liste de crises, il découvre lui-même que deux régimes de comportement coexistent.

Le détecteur est entraîné sur trois variables seulement — le rendement du marché, sa volatilité récente et la corrélation moyenne entre actifs. Ce choix est directement dicté par les problèmes : la volatilité est la signature de P2, la corrélation moyenne est la mesure même de P3. À chaque décision, le modèle est réentraîné sur la seule fenêtre disponible et produit une probabilité de régime (figure 4.1).




FIG. 4.1: Sortie du détecteur sur l'univers ETF : un régime par décision de rééquilibrage, estimé sans aucune connaissance de la suite. Les bandes verticales marquent cinq crises dont les dates proviennent d'une source externe et ont été fixées *avant* toute mesure. La question de savoir si les amas rouges sont associés à ces bandes est traitée comme une analyse exploratoire au chapitre 5.

Quatre décisions de conception méritent d'être justifiées, car elles ont toutes été prises contre l'option en apparence plus ambitieuse.

Deux états, pas trois. Un troisième état « crise » était tentant. Il a été écarté parce que l'univers principal ne compte qu'environ 1 300 journées : un troisième état aurait été estimé sur une poignée d'observations, et sa définition aurait dépendu de la graine aléatoire plus que des données.

Un basculement franc, pas un mélange. Une fois le régime identifié, la décision est entièrement confiée à une stratégie classique déjà testée : le Markowitz classique en régime haussier, la variance minimale rétrécie en régime baissier. Aucun code d'optimisation nouveau n'a été écrit. L'inconvénient est assumé et documenté : un basculement franc provoque un pic de transactions à la frontière entre deux régimes, et c'est effectivement la stratégie la plus coûteuse en rotation du projet.

En cas de doute, la posture défensive. Si la fenêtre est trop courte ou si l'estimation ne converge pas, la probabilité neutre de 50/50 est résolue vers la stratégie *défensive*, non vers un tirage arbitraire. Un système d'allocation qui ne sait pas où il est ne doit pas parier à la hausse.

Les étiquettes sont recalculées à chaque réestimation. La bibliothèque employée ne garantit pas que l'état numéro 0 désigne le même régime d'une estimation à l'autre. Les états sont donc réordonnés à chaque fois d'après le rendement moyen ajusté, et « baissier » est *défini* comme l'état de rendement moyen le plus faible. Cette définition a une conséquence importante, rappelée au chapitre 5 : une partie de l'association entre régime baissier et crise est définitionnelle, et seul le caractère *temps réel* de la détection est un résultat.

4.4 Troisième échelon : prédire les rendements

Les échelons précédents ne prédisent jamais un rendement : ils estiment un risque et un régime. L'échelon suivant franchit ce pas — c'est la fonction que le référentiel fonctionnel d'EURAFRIC désigne comme « modèles ML adaptatifs ».

Deux familles ont été retenues, toutes deux fondées sur des ensembles d'arbres de décision : forêts aléatoires et gradient boosting. Aucun réseau de neurones n'a été conservé — un modèle récurrent avait été développé et testé isolément, puis retiré de la comparaison après un conflit reproductible entre deux bibliothèques natives chargées dans le même processus. Il a paru préférable de retirer un composant instable que de publier une comparaison qui n'aurait pas pu être rejouée.

Trois choix structurent cette partie.

Un modèle unique, entraîné sur tous les actifs à la fois. Plutôt que neuf modèles indépendants, un seul apprend sur un tableau où chaque ligne est un couple (date, actif) et où l'identité de l'actif est une variable comme une autre. L'intérêt est arithmétique : le nombre de lignes d'entraînement est multiplié par le nombre d'actifs. Sur un univers de 1 300 journées, c'est la différence entre un problème d'apprentissage difficile et un problème impossible.

Le régime est une variable d'entrée, pas un aiguillage. La probabilité de régime issue du détecteur est fournie au modèle comme une colonne supplémentaire. L'alternative — deux modèles distincts, un par régime — fragmenterait un jeu de données déjà mince pour un problème d'apprentissage plus difficile que celui du détecteur.

La prédiction remplace un seul ingrédient. Le rendement prédit se substitue à la moyenne historique dans l'objectif de Markowitz, déjà écrit et déjà testé. La covariance reste inchangée. Le principe « une seule chose change à la fois » est ainsi préservé jusqu'au bout : tout écart de performance s'attribue à la qualité de la prédiction, à rien d'autre.

C'est ici que le risque de fuite est le plus grand, car la variable à prédire est construite à partir de la même matrice de rendements que les variables explicatives. La date de décision est donc exclue de l'entraînement structurellement, par comparaison de dates — et non par filtrage des valeurs manquantes, qu'un appel maladroit pourrait contourner. Un test dédié corrompt le futur et vérifie qu'aucune décision passée ne change, en s'assurant au passage que le modèle utilise réellement ces variables : sans cette seconde vérification, la garantie serait vide.

4.5 Quatrième échelon : payer le prix des transactions

L'échelon précédent a produit un diagnostic précis, exposé au chapitre 5 : le signal était informatif *avant* coûts et ne l'était plus après. Autrement dit, un échec de *construction* de portefeuille et non de *prédiction*. Trois leviers ont été ajoutés en réponse.

Une pénalité de rotation. L'objectif d'optimisation intègre un terme proportionnel à l'ampleur des transactions envisagées : la stratégie ne modifie une position que si le gain attendu dépasse le coût du mouvement. Un détail technique mérite mention, car il illustre le soin requis : la valeur absolue n'est pas dérivable exactement là où se situe l'optimum d'un problème pénalisé — c'est-à-dire « ne rien échanger » — et l'algorithme employé est fondé sur le gradient. Une approximation lisse de la valeur absolue est donc utilisée.

Un rétrécissement des rendements prédits vers la moyenne historique, et une variante n'en conservant que le *classement*. La justification est un résultat classique : une erreur sur les rendements attendus dégrade un optimiseur moyenne-variance environ dix fois plus qu'une erreur équivalente sur la covariance. Réduire l'amplitude d'une prédiction bruitée tout en conservant sa direction est donc souvent préférable à s'y fier pleinement.

Le choix de l'estimateur de covariance devient un paramètre des stratégies à signal, ce qui permet d'associer « meilleure prédiction » et « meilleure covariance » par configuration plutôt que par écriture de code.

Tous ces leviers sont **désactivés par défaut**. La raison est de reproductibilité : l'échelon précédent, avec son résultat négatif, reste exécutable à l'identique et sert de plancher honnête. On n'améliore pas un résultat en le rendant irretrouvable.

4.6 Le protocole d'évaluation (P4)

Tout ce qui précède serait sans valeur si la mesure était complaisante. Le problème P4 — le surapprentissage du backtest — est le seul des quatre qui ne puisse pas être résolu par un meilleur modèle, puisqu'il porte sur la mesure elle-même. Quatre dispositifs y répondent.

4.6.1 Rejouer le temps

Toute performance rapportée provient d'une simulation à fenêtre glissante (figure 4.2) : à chaque fin de mois, le modèle est réentraîné sur les seules données antérieures, décide, puis subit le mois suivant. Aucune performance n'est jamais mesurée sur des données ayant servi à décider.

4.6.2 Choisir les hyperparamètres sans tricher

Reste une fuite plus subtile : le choix des réglages. Essayer trente configurations et publier la meilleure revient à publier un maximum de bruit.

Définition — Purge, embargo, et sélection strictement antérieure

En apprentissage classique, on découpe les données en blocs et on teste sur chacun à tour de rôle. Sur des séries temporelles financières, c'est fautif : les observations voisines se ressemblent, et la variable à prédire d'une journée recouvre les journées suivantes. Le bloc de test « touche » donc son propre entraînement. La *purge* retire les observations d'entraînement dont l'horizon chevauche le bloc de validation ; l'*embargo* écarte en outre




FIG. 4.2: Principe du backtest à fenêtre glissante. La fenêtre d'entraînement s'élargit à chaque pas ; la performance est toujours encaissée *après* la décision. Le découpage est effectué par le moteur, jamais par la stratégie.

une bande de journées juste après ce bloc.

Ces deux mécanismes ne suffisent pas. La validation croisée purgée classique entraîne le modèle sur *toutes* les dates hors de la bande — y compris **postérieures** à la validation. La *sélection strictement antérieure* ajoute la contrainte manquante : l'entraînement précède toujours la validation, et chaque pli vérifie $\text{fin_entraînement} < \text{début_embargo} \leq \text{début_validation}$.

Cette validation croisée a été implémentée dans le projet plutôt qu'importée : la bibliothèque spécialisée de référence a adopté un modèle de licence restrictif, et une cinquantaine de lignes suffisaient. Un test de fuite dédié doit être vert avant que quoi que ce soit ne l'utilise.

4.6.3 Deux objectifs, deux instruments


Une distinction, discrète mais décisive, structure la sélection.

Définition — Coefficient d'information

Corrélation de rang entre les rendements prédits et les rendements réalisés. Il mesure si le modèle classe correctement les actifs — ce qui est exactement ce qu'un signal doit faire — sans exiger que ses prédictions soient justes en niveau. En prévision financière, un coefficient de quelques centièmes est déjà considéré comme exploitable ; c'est un domaine où le signal est tenu par nature.

Les *hyperparamètres des modèles* sont donc choisis par **validation strictement antérieure** (folds *forward-only* : l'entraînement précède toujours la validation, séparé d'une purge et d'un embargo), au coefficient d'information — rapporté *par pli* et non seulement en moyenne, une

- ① Le segment de test est mis de côté avant toute calibration



- ② Validation croisée standard : les blocs se touchent — fuite

la veille du test sert
à l'entraîner



- ③ Validation croisée purgée et sous embargo : les blocs sont séparés




FIG. 4.3: Le protocole de sélection. Le segment de test final est mis de côté avant toute calibration ; la sélection s'opère sur le reste, avec des blocs séparés par une purge et un embargo. Le découpage est effectué *par date*, non par ligne, car le tableau d'apprentissage comporte plusieurs actifs à chaque date.

moyenne identique pouvant recouvrir cinq plis stables ou un seul pli dominant. Les *leviers de portefeuille* (rétrécissement, pénalité de rotation) sont choisis autrement : sur un segment de validation distinct, au ratio de Sharpe net, à travers le moteur réel — car ce sont des paramètres de construction, pas de prédiction, et les juger au coefficient d'information serait une erreur de catégorie.

4.6.4 Un verdict rendu une seule fois, avec sa marge d'erreur

Les derniers 35 % de chaque univers sont mis de côté avant toute calibration et ne sont utilisés qu'une fois, les réglages figés. À ce verdict s'ajoutent deux précautions.

Définition — Intervalle de confiance par bootstrap à blocs

Pour estimer de combien une performance mesurée pourrait varier par simple hasard, on reconstitue des milliers d'historiques fictifs en retirant au sort des *blocs* de journées consécutives — ici des blocs d'un mois environ, afin de préserver la structure temporelle des rendements, qu'un tirage journée par journée détruirait. La dispersion des performances obtenues donne l'intervalle.

Définition — Ratio de Sharpe déflaté

Probabilité qu'une performance mesurée soit réellement positive une fois corrigée du nombre de stratégies essayées et de la non-normalité des rendements. Essayer 200 configurations et retenir la meilleure produit une bonne performance même si aucune ne vaut rien ; cette mesure quantifie cet effet.

Le nombre de configurations essayées n'est pas déclaré à la main : un registre enregistre chaque

configuration évaluée pendant la recherche, et c'est ce décompte qui alimente la correction. C'est une manière de rendre coûteuse — et visible — la tentation d'essayer une piste de plus.

4.7 La discipline expérimentale

Trois règles de conduite complètent le dispositif technique. Elles ne relèvent pas de l'outillage mais de l'honnêteté, et ce sont elles qui rendent le chapitre 5 défendable.

Choisi n'est pas calibré. Lorsqu'une valeur a été fixée par jugement et non par une procédure de sélection, le rapport le dit. Ajuster ces valeurs en regardant le résultat final serait exactement le surapprentissage que tout le chapitre cherche à empêcher.

Les issues sont écrites avant l'expérience. Les études exploratoires du projet énoncent, dans le script lui-même et avant exécution, les conclusions associées à chaque issue possible — « si tel écart dépasse tel seuil, alors l'hypothèse est retenue ; sinon elle est rejetée ». Plusieurs comportent en outre un *contrôle inversé* : une variante délibérément construite à contresens, qui doit faire moins bien. Si elle fait aussi bien, ce n'est pas l'hypothèse qui est validée, c'est l'expérience qui est sans pouvoir.

Un seuil ne se durcit qu'avant de voir le résultat. Un exemple concret mérite d'être rapporté, car il est plus parlant qu'un principe. Une expérience comparait deux configurations avec un simple « meilleur que » ; un essai préliminaire a rendu un écart de +0,0016, que cette règle aurait qualifié de victoire. Un seuil de matérialité a donc été ajouté *avant* l'exécution réelle ; il rend le test plus sévère, et le changement est consigné dans le script comme dans le document d'analyse plutôt que fondu silencieusement dans la méthode.

Synthèse du chapitre

- Quatre échelons ont été construits, chacun ne modifiant qu'un ingrédient du précédent : meilleure estimation du risque (P1), reconnaissance du régime de marché (P2, P3), prédiction des rendements, puis prise en compte du coût des transactions. Un gain est ainsi attribuable.
- Aucun échelon n'a modifié le moteur de backtest : toutes les stratégies ont été mesurées par le même instrument, sous les mêmes contraintes de gestion, sur les deux univers.
- Les choix ont systématiquement été faits contre l'option la plus ambitieuse lorsque les données ne la soutenaient pas : deux régimes et non trois, un basculement franc vers des optimiseurs déjà testés, un modèle unique entraîné sur tous les actifs, une posture défensive en cas de doute.
- L'évaluation traite le problème P4 comme un problème à part entière : rejeu du temps, sélection des réglages **strictement antérieure** (purge et embargo à la frontière, l'entraînement précédant toujours la validation), segment de test gelé, **comparaisons paires** par bootstrap à blocs — le test de la *différence*, que des intervalles marginaux ne fournissent pas — et correction pour le nombre de configurations essayées, compté automatiquement et non déclaré.
- Les issues des expériences sont écrites avant leur exécution, plusieurs comportent un contrôle délibérément inversé, et tout durcissement de critère est consigné. Ces règles n'ajoutent aucune performance : elles rendent les conclusions du chapitre suivant opposables.

Chapitre 5

Résultats, validation et produit livré

Comment lire ce chapitre

Ce chapitre présente ce que le système produit réellement. Il est organisé selon un principe simple, hérité du problème P4 exposé au chapitre 2 : **un chiffre n'est un résultat que si l'on sait de combien il pourrait être faux.**

Chaque résultat est donc qualifié selon son niveau de preuve. Le chapitre distingue explicitement quatre catégories :

- ce qu'il **observe** — des écarts historiques, sans les transformer en supériorité généralisable faute de test pairé ;
- ce qu'il **explore** — des associations sur un faible nombre d'événements, utiles pour orienter l'analyse mais non confirmatoires ;
- ce qu'il **teste sans l'établir** — une comparaison pairée ou une correction de recherche qui ne conclut pas à la surperformance ;
- ce qu'il **réfute** — cinq pistes explorées et fermées.

Cette troisième catégorie n'est pas un aveu d'échec. Sur un sujet où la littérature abonde en performances irreproductibles, une piste correctement fermée a plus de valeur qu'une performance invérifiable.

5.1 Le résultat principal

Le système complet — détection de régime par chaîne de Markov cachée et covariance dynamique — a été comparé aux trois approches classiques sur les deux univers, hors échantillon et net de coûts de transaction.

Sur le portefeuille EURAFRIC, le système obtient un ratio de Sharpe de **1,236** contre **1,164** pour la meilleure approche classique, soit un gain de +6,2 %. Sur l'univers ETF, il obtient 0,937 contre 0,953 : il **perd** de 1,6 %.

Le résultat est donc mitigé, et il est rapporté comme tel. Un système qui n'apporterait un gain que sur l'univers où on a choisi de le mettre en avant ne serait pas un système, mais une sélection.

TAB. 5.1: Performance nette de coûts, hors échantillon. *DD* désigne le drawdown maximal (la pire perte pic-à-creux), et le ratio de Calmar rapporte le rendement à ce drawdown.

Univers	Stratégie	Sharpe	Rendement	DD max.	Calmar
Portefeuille EURAFRIC (9 actifs)	Système ML (régime)	1,236	12,2 %	−14,1 %	0,862
	Markowitz Sharpe max.	1,164	13,2 %	−13,2 %	1,000
	Équipondéré (1/N)	1,160	11,6 %	−13,6 %	0,852
	Variance min. (Ledoit-Wolf)	1,074	9,9 %	− 12,8 %	0,775
ETF inter-nationaux (5 actifs)	Variance min. (Ledoit-Wolf)	0,953	10,3 %	−26,9 %	0,382
	Système ML (régime)	0,937	10,4 %	−26,9 %	0,386
	Markowitz Sharpe max.	0,912	10,8 %	−32,8 %	0,329
	Équipondéré (1/N)	0,769	9,6 %	−36,2 %	0,266




FIG. 5.1: Évolution des portefeuilles, nette de coûts et hors échantillon (échelle logarithmique). Le système ML est tracé en trait épais. L'écart entre stratégies est faible au regard de l'amplitude des mouvements de marché — ce que la section suivante quantifie.

5.1.1 Une réserve sur le choix de la mesure

Le tableau 5.1 appelle une observation que l'honnêteté impose de formuler, car elle nuance le résultat principal.

Sur le portefeuille EURAFRIC, le système ML l'emporte *au sens du ratio de Sharpe* — mais il est battu par le Markowitz classique sur le rendement annualisé (12,2 % contre 13,2 %), sur le drawdown maximal (−14,1 % contre −13,2 %), sur le ratio de Calmar (0,862 contre 1,000) et sur le turnover (0,29 contre 0,14, soit deux fois plus de transactions).

Autrement dit : **le gain provient d'une réduction de la volatilité, non d'un supplément de rendement**, et il n'apparaît que dans la mesure qui divise par cette volatilité. Un gérant dont le mandat privilégie le rendement par unité de perte maximale — le critère de Calmar — préférerait le Markowitz classique.

Cette dépendance du classement au choix de la mesure est un résultat en soi. Elle justifie que les sections suivantes ne s'appuient pas uniquement sur le ratio de Sharpe.

5.2 Ce chiffre est-il réel ? La validation hors échantillon

Un écart de +6,2 % mesuré sur une période unique ne dit rien tant qu'on ignore sa marge d'erreur. Deux protocoles ont été appliqués pour l'établir.

Le test gelé. Les derniers 35 % de chaque univers ont été mis de côté avant toute calibration. Les hyperparamètres des modèles ont été choisis sur la partie restante par **validation strictement antérieure** (*forward-only*), puis *figés* ; le verdict n'a été mesuré qu'une fois, sur ce segment jamais vu.

Le mot « strictement » est le correctif apporté à ce protocole. La version précédente employait une validation croisée purgée en blocs, qui entraîne le modèle sur *toutes* les dates hors de la bande de purge — y compris **postérieures** au bloc de validation. C'est la construction canonique de López de Prado, défendable lorsque les labels se chevauchent, mais elle note un pli de 2018 avec un modèle ajusté en partie sur 2019–2024 : une question qu'aucun gérant ne peut poser en direct. Chaque pli respecte désormais

$$\text{fin_entraînement} < \text{début_embargo} \leq \text{début_validation} \leq \text{fin_validation} < \text{début_test}$$

et la géométrie réellement appliquée — dates, effectifs, IC par pli — est publiée dans `phase5_validation_protocol.json` plutôt qu'affirmée ici.

Le walk-forward imbriqué. La fenêtre de test unique du protocole précédent ne représente que 455 jours sur le portefeuille EURAFRIC, ce qui produit des intervalles très larges. Un second protocole re-sélectionne la configuration à six frontières successives et concatène chaque segment hors échantillon, portant l'évaluation à **793 jours** — sans que la sélection ne voie jamais sa propre fenêtre d'évaluation.

Le test paillé — la preuve qui manquait. Les intervalles ci-dessus sont *marginiaux* : ils décrivent l'incertitude de *chaque* stratégie prise isolément. Ils ne testent pas si deux stratégies diffèrent, et les lire ainsi est une erreur dans les deux sens — deux intervalles peuvent se chevaucher largement alors que la différence paillée est systématiquement positive (les stratégies partagent les mêmes journées de marché et leurs erreurs sont corrélées), et un non-chevauchement n'établirait pas davantage une différence.




FIG. 5.2: Ratios de Sharpe hors échantillon et intervalles de confiance à 90 % (bootstrap par blocs), pour les deux protocoles. Le protocole imbriqué (bleu) resserre les intervalles de **28,6 %** en moyenne. Les intervalles marginaux restent néanmoins largement chevauchants : ils quantifient l'incertitude, sans constituer un test pairé de différence entre stratégies.

Ce rapport dispose désormais de l'instrument manquant : un **bootstrap par blocs pairé** sur les mêmes dates de la fenêtre gelée, net de coûts. Les deux séries sont rééchantillonnées avec les *mêmes* indices de blocs, ce qui préserve à la fois la dépendance sérielle de chaque stratégie et la corrélation intra-journalière entre elles. La p-value est *centrée sous l'hypothèse nulle* — les différences rééchantillonnées sont recentrées sur zéro, puis on mesure la part de cette distribution au-delà de l'écart observé. Ce n'est pas la fraction brute de tirages positifs, rapportée séparément et jamais présentée comme une p-value.

TAB. 5.2: Comparaisons pairées sur la fenêtre de test gelée, nettes de coûts (bootstrap par blocs, 2000 rééchantillons). *Aucune* des huit comparaisons n'établit de surperformance.

Univers	Comparaison	Δ Sharpe	IC 90 %	p
etf_2017	RF vs régimes	+0,009	[−0,025; +0,041]	0,326
	RF vs 1/N	+0,120	[−0,013; +0,247]	0,066
	XGB vs régimes	−0,149	[−0,308; +0,010]	0,939
	XGB vs 1/N	−0,038	[−0,177; +0,096]	0,671
full_2021	RF vs régimes	−0,212	[−0,551; +0,151]	0,850
	RF vs 1/N	−0,002	[−0,374; +0,360]	0,512
	XGB vs régimes	+0,096	[−0,315; +0,541]	0,361
	XGB vs 1/N	+0,306	[−0,158; +0,784]	0,147

Le verdict honnête

Aucune preuve de surperformance. Sur les huit comparaisons pairées, tous les intervalles contiennent zéro et toutes les p-values dépassent 0,05 ; la plus proche du seuil est RF contre l'équipondéré sur **etf_2017** ($p = 0,066$).

Un cas mérite d'être isolé, car il est exactement ce que ce test sert à révéler. Sur `full_2021`, le signal XGB calibré obtient 1,308 contre 1,213 pour la stratégie à régimes : en *estimation ponctuelle*, il « bat » la référence, et l'artefact l'enregistre comme tel. Le test pairé donne pourtant $\Delta = +0,096$, IC $[-0,315; +0,541]$, $p = 0,361$. Le classement ponctuel n'est pas soutenu par les données.

Ce n'est pas non plus une démonstration d'équivalence : ne pas rejeter n'est pas accepter l'hypothèse nulle. L'établir demanderait un test d'équivalence contre une marge fixée à l'avance, qui n'a pas été mené.

5.2.1 Corriger pour l'ampleur de la recherche

TAB. 5.3: Reality Check de White et SPA de Hansen sur l'ensemble des candidats explorés. L'hypothèse nulle est composite : *aucun* candidat ne surperforme la référence.

Univers	Référence	Statistique	RC p	SPA p
<code>etf_2017</code>	<code>regime_conditional</code>	mean return	0,2259	0,3588
<code>etf_2017</code>	<code>regime_conditional</code>	Sharpe	0,8811	0,6357
<code>etf_2017</code>	<code>equal_weight</code>	mean return	0,0630	0,0020
<code>etf_2017</code>	<code>equal_weight</code>	Sharpe	0,2714	0,0980
<code>full_2021</code>	<code>regime_conditional</code>	mean return	0,0690	0,0930
<code>full_2021</code>	<code>regime_conditional</code>	Sharpe	0,3163	0,2939
<code>full_2021</code>	<code>equal_weight</code>	mean return	0,0405	0,0085
<code>full_2021</code>	<code>equal_weight</code>	Sharpe	0,1009	0,0170

Les huit comparaisons paires ci-dessus testent chacune *un* candidat contre une référence. Mais ce candidat a été *choisi dans une recherche*, et le meilleur de plusieurs candidats bat une référence par chance plus souvent qu'un candidat unique. Tant que cette sélection n'est pas tarifée, « le modèle retenu a battu la haie » n'est pas l'affirmation qu'il paraît être.

L'ensemble corrigé est l'espace ATTEIGNABLE. La recherche était hiérarchique — hyperparamètres choisis par coefficient d'information, puis leviers de portefeuille conditionnellement à ces hyperparamètres. Le registre d'essais en avait enregistré 51, mais l'espace que la recherche pouvait sélectionner compte 240 configurations : 15 jeux d'hyperparamètres $\times$ 16 combinaisons de leviers. Corriger pour 51 quand 240 étaient atteignables sous-estimerait la multiplicité, donc c'est le nombre le plus grand qui est retenu. Chacune de ces 240 configurations a été réévaluée sur les dates de test gelées et sa série de rendement conservée.

Le verdict corrigé

Aucun des 240 candidats ne bat la stratégie à régimes une fois la recherche prise en compte, sur aucun des deux univers.

La référence primaire est pré-spécifiée : `regime_conditional` est la haie que la couche ML devait franchir et celle que toutes les phases antérieures rapportaient. Face à elle, ni le Reality Check ni le SPA n'établit de surperformance, sur aucun univers ni aucune statistique.

L'illustration la plus parlante tient en deux nombres. En retenant le meilleur des 240 candidats *jugé sur la fenêtre de test elle-même*, on obtient un Sharpe de 1,87 sur `full_2021` — contre 1,31 pour celui que la sélection honnête avait désigné. Cet écart ne mesure pas une performance : il mesure ce que la sélection sur l'échantillon de test *fabrique*, et c'est

exactement ce que la correction sert à tarifier.

Les comparaisons face à `equal_weight` sont **exploratoires par pré-spécification** et n'étaient aucune réussite du ML : la stratégie à régimes, et depuis la correction des dividendes le `max_sharpe` classique, franchissent déjà ce plancher.

Trois réserves qui accompagnent ce tableau. Le RC et le SPA sont rapportés *côte à côte* et aucun ne doit être cité seul : le SPA est plus puissant par construction — il studentise chaque candidat et écarte les candidats sans espoir du recentrage — donc il donnera d'ordinaire la plus petite p -value. Ici il conserve 227 à 240 candidats sur 240, ce qui montre que sa règle d'exclusion ne joue quasiment pas : l'écart entre les deux tests vient de la studentisation, gain de puissance documenté de Hansen sur la conservativité de White, et non d'un désaccord sur le résultat. Enfin, huit comparaisons externes ont été menées ($2 \text{ univers} \times 2 \text{ références} \times 2 \text{ statistiques}$) et ne sont pas elles-mêmes corrigées : citer la plus petite des huit serait de la multiplicité un niveau au-dessus de celle que ce tableau corrige.

Trois éléments confirment ce diagnostic plutôt qu'ils ne l'affaiblissent.

D'abord, le protocole imbriqué apporte un gain de précision réel : la largeur moyenne des intervalles tombe de 2,22 à 1,59, soit $-28,6 \%$, mieux que les $24,3 \%$ qu'un simple effet de taille d'échantillon laisserait attendre. Le Sharpe déflaté du gagnant atteint 0,835 sur 198 configurations testées, contre 0,67 sur 36 pour le découpage unique.

Ensuite, toutes les bornes inférieures marginales deviennent positives (de 0,48 à 0,89) dans ce protocole. C'est une description de chaque stratégie prise isolément ; elle ne démontre ni une rentabilité future ni un avantage relatif.

Enfin — et c'est l'observation la plus instructive — **le classement change selon le protocole**. Le découpage unique place le signal XGB calibré en tête ; le protocole imbriqué replace le système à régime devant. Un classement qui change de sens lorsqu'on modifie le protocole d'évaluation, sans test pairé établissant une différence, ne doit pas être promu en verdict.

5.3 Comportement en crise : une lecture métier descriptive (P3)

Les mesures précédentes portent sur des moyennes de période. Or pour un allocataire, la question décisive est différente : que se passe-t-il quand les marchés s'effondrent ? C'est le problème P3, et il n'avait jusque-là été étayé qu'indirectement.

Cinq crises ont donc été analysées, délimitées par les **dates de sommet-à-creux publiées de l'indice S&P 500** et fixées *avant* tout examen des résultats. Ce point de méthode est essentiel : déduire les fenêtres de nos propres pertes reviendrait à sélectionner les périodes où le système paraît bon.

Sur les cinq crises, **sans exception**, l'optimisation sous contrainte perd moins, chute moins profondément et récupère plus vite que la diversification naïve :

- lors de la crise financière de 2008, elle épargne **9,0 points** de performance et **9,3 points** de drawdown ;
- pendant la crise de la dette européenne, elle termine **positive** ($+1,6 \%$) là où l'équipondéré perd $5,4 \%$;
- le **délai de récupération** est l'écart le plus régulier — 37 jours contre 71 après le krach COVID, 53 contre 105 après le repli de 2018, soit environ **deux fois moins de temps sous l'eau**.




FIG. 5.3: Comportement pendant les cinq crises retenues, sur l'univers ETF. À gauche, la performance cumulée sur la fenêtre ; à droite, le nombre de jours nécessaires pour retrouver le sommet précédent.

Le délai de récupération n'apparaît dans aucune des mesures classiques du chapitre, alors qu'il est probablement le plus parlant pour un décideur : combien de temps le capital reste-t-il en dessous de sa valeur d'avant-crise ?

Attribution — ce que ce résultat ne dit pas. Ce gain revient à la **contrainte de portefeuille et au modèle de covariance** (P1 et P3), et non spécifiquement à la couche de régime. Sur trois des cinq fenêtres, les trois optimiseurs produisent des résultats identiques à la décimale près, pour deux raisons mécaniques : en régime baissier, le système à régime *devient* la variance minimale par construction ; et le plafond de 25 % sur cinq actifs contraint fortement l'allocation. L'attribuer au *Machine Learning* serait inexact.

5.4 La détection de régime : une analyse exploratoire (P2)

Le détecteur de régime est un modèle **non supervisé** : aucune date de crise, aucun label de récession ne lui a jamais été fourni. Il observe uniquement le rendement du marché, sa volatilité et la corrélation moyenne entre actifs, et classe chaque date de rééquilibrage en régime haussier ou baissier — *en temps réel*, à partir des seules données passées, sans savoir qu'une crise commence.

Le résultat est net : **91,7 %** des rééquilibrages situés dans une fenêtre de crise sont classés « baissier », contre **29,2 %** en dehors — un rapport de **3,13**, et les cinq crises dépassent le taux de base.




FIG. 5.4: Proportion de rééquilibrages classés « baissier » pendant chacune des cinq crises, comparée au taux observé hors crise. Le modèle n’a reçu aucune information sur ces événements.

TAB. 5.4: Deux diagnostics encadrent le problème de dépendance sérielle. Ils sont rapportés pour transparence, non comme une confirmation statistique généralisable sur cinq événements.

Diagnostic	Résultat	Lecture
Test des signes (<i>exploratoire</i>)	$p = 0,031$	Chaque crise compte pour une observation ($n = 5$). Ce calcul évite la dépendance sérielle interne, mais cinq observations ne permettent pas une conclusion confirmatoire.
Fisher exact (<i>libéral</i>)	$p = 7,8 \times 10^{-13}$	Traite 248 rééquilibrages mensuels corrélés comme indépendants : optimiste. À ne jamais citer seul.

Association exploratoire, non preuve de détection

Le détecteur est plus souvent dans l'état étiqueté « baissier » pendant les cinq fenêtres étudiées. Le test des signes donne $p = 0,031$, mais cet indicateur reste exploratoire : l'échantillon contient cinq événements et « baissier » est défini par le rendement moyen faible de l'état. Il ne doit pas être présenté comme un résultat confirmatoire, ni comme une preuve de valeur économique.

La réserve qui doit accompagner ce résultat. Le régime « baissier » est *défini* comme l'état de plus faible rendement moyen, et une crise est par nature une période de faible rendement : une part de l'association est donc définitionnelle. Ce qui ne l'est pas, c'est que la détection soit **causale et en temps réel**, et qu'elle ne se déclenche pas en permanence — le taux hors crise reste à 29 %, non à 80 %. Le modèle ne crie pas au loup.

*Deux affirmations distinctes, à ne jamais confondre : le détecteur produit une lecture causale de l'état de marché, associée aux cinq fenêtres étudiées ; le fait d'**agir** sur cette lecture n'a pas établi d'avantage économique robuste face aux approches classiques.*

5.5 La contrainte fait plus que les modèles (P1)

Le plafond de 25 % par actif avait été retenu comme une contrainte de gestion réaliste, non comme un outil de modélisation. En le faisant varier seul, tout le reste étant fixé, on obtient le résultat le plus inattendu du projet.




FIG. 5.5: Meilleur ratio de Sharpe classique en fonction du plafond par actif, sur 248 rééquilibrages et 20,7 ans. Le nombre d'allocations distinctes émises est indiqué sous chaque point.

Relâcher le plafond de 25 % jusqu'à l'absence de contrainte fait chuter le meilleur Sharpe classique de **0,9525 à 0,8650**, soit une perte de **10,1 %**, de façon monotone. C'est davantage que l'écart entre deux modèles quelconques sur cet univers : le rétrécissement de Ledoit-Wolf, l'EWMA, le DCC-GARCH et la commutation de régime réunis déplacent moins le résultat.

Il s'agit du résultat de **Jagannathan et Ma (2003)** reproduit sur nos données : une contrainte de poids active équivaut mathématiquement à un rétrécissement de la matrice de covariance. **La contrainte réalisait donc déjà le contrôle d'erreur d'estimation (P1) que le *Machine Learning* devait apporter.**

Le nombre d'allocations distinctes éclaire le mécanisme : à 25 % sur cinq actifs, $5 \times 0,25 = 1,25$, si bien que tout portefeuille admissible doit placer au moins quatre actifs au plafond. La variance minimale n'émet alors qu'**une seule** allocation sur 248 rééquilibrages ; à 30 %, elle en émet 171. Sur cet univers, la contrainte — et non le modèle — détermine l'essentiel de l'allocation.

À présenter comme un résultat, non comme une limite : le contrôle du risque le plus efficace de ce système s'est révélé être la limite de position qu'un mandat réel imposerait de toute façon. C'est précisément ce que le cadrage « contraintes réalistes de gestion » du cahier des charges invitait à découvrir.

5.6 Ce qui ne fonctionne pas : cinq pistes fermées

La couche de prédiction de rendement — des modèles d'apprentissage supervisé prédisant le rendement de chaque actif — n'a jamais dépassé la ligne de base. Plutôt que de l'accepter, cinq explications possibles ont été testées indépendamment, chacune avec un protocole pré-enregistré.

TAB. 5.5: Cinq tentatives indépendantes de dépasser la ligne de base régime + covariance dynamique.

Piste testée	Verdict
Prédiction de rendement calibrée honnêtement 5 fois plus d'historique de prix (univers marocain profond, 56 000 lignes)	aucune surperformance incrémentale établie
Données fondamentales point-in-time (P/E, P/B, P/S, D/E)	coefficient d'information $\times 2$ à $\times 4$, aucun avantage de portefeuille
Ré-sélection par pli, 74 % de données hors échantillon en plus	coefficient d'information $\times 2$, ratio de Sharpe en baisse
Contrainte conditionnée au régime	intervalles $-28,6$ %, classement instable
	réfutée par son propre contrôle

Deux de ces études méritent d'être détaillées, car elles établissent un point de méthode qui dépasse ce projet.

Précision de prédiction $\neq$ performance de portefeuille. L'ajout de données fondamentales a presque *doublé* la capacité prédictive mesurée du modèle (coefficient d'information de 0,028 à 0,058) — et a fait *baissier* le ratio de Sharpe du portefeuille correspondant. Le même phénomène est apparu avec cinq fois plus d'historique de prix. Améliorer un modèle et améliorer un portefeuille sont deux objectifs distincts ; le second ne découle pas automatiquement du premier.

L'importance d'un contrôle destiné à réfuter. L'étude sur la contrainte conditionnée au régime incluait une variante **inversée**, délibérément construite dans la mauvaise direction. Sur le portefeuille EURAFRIC, cette variante inversée est bien la pire — ce qui semblait confirmer l'existence d'un effet de régime. Mais sur l'univers ETF, elle *dépasse* la meilleure variante « correcte ». Un effet qui change de signe selon l'univers n'est pas un effet. Sans ce contrôle, la conclusion aurait été inverse.

Ce que la convergence de ces cinq études indique

Les cinq études ne justifient pas une valeur incrémentale de la couche de prédiction sur les univers et protocoles évalués. Elles montrent aussi que des écarts de l'ordre de grandeur observé restent trop instables pour être promus en surperformance. L'absence de preuve n'est pas une preuve d'absence ; c'est une limite mesurée, rendue visible par des tentatives comparables.

5.7 L'étiquette correspond-elle au modèle ? (P4)

Plusieurs estimateurs de ce système se dégradent au lieu d'échouer : DCC-GARCH retombe sur le rétrécissement de Ledoit-Wolf en cas de non-convergence, les signaux ML retombent sur la moyenne empirique si le panel est trop mince ou si l'ajustement échoue, et la stratégie à régimes résout une postérieure incertaine vers sa branche défensive. Chacun de ces replis est délibéré — une boucle walk-forward ne doit pas mourir sur une fenêtre difficile — mais chacun signifie aussi qu'un résultat peut porter une étiquette qui n'est pas toute la vérité. Un « DCC-GARCH » ayant replié une fois sur quatre est, sur ces dates, un résultat Ledoit-Wolf sous une étiquette DCC-GARCH.

Jusqu'ici ces replis n'étaient tracés qu'en journal applicatif, au niveau **WARNING** : un message que personne ne lit sur une exécution non surveillée, et absent de tout artefact publié. Une instrumentation par rééquilibrage enregistre désormais, pour chaque ajustement, le modèle demandé, le modèle effectif, le statut, la raison du repli et la taille de la fenêtre d'entraînement. Ces enregistrements sont persistés en couche Gold (`fit_reports.parquet`), versionnés et intégrés au manifeste de release avant qu'aucun tableau n'en soit tiré.

TAB. 5.6: Repli des estimateurs sur l'instantané publié. Un repli signifie que le résultat a été produit par un estimateur de substitution, non par le modèle nommé.

Univers	Stratégie	Replis / rééquilibrages	Replis / jours
etf_2017	dcc_garch	0 / 248	0 / 5387
etf_2017	regime_conditional	0 / 248	0 / 5387
etf_2017	rf_signal	0 / 248	0 / 5387
etf_2017	xgb_signal	0 / 248	0 / 5387
full_2021	dcc_garch	0 / 49	0 / 1061
full_2021	regime_conditional	0 / 49	0 / 1061
full_2021	rf_signal	0 / 49	0 / 1061
full_2021	xgb_signal	0 / 49	0 / 1061

Sur l'instantané publié, 0 ajustement sur 1188 — 4 stratégies évaluées, 297 dates de rééquilibrage — n'a utilisé de repli : chaque résultat rapporté ici a été produit par le modèle que son étiquette désigne. La portée de cette affirmation est exactement l'ensemble compté ci-dessus.

Ce que cette mesure établit, et ce qu'elle n'établit pas

Elle établit qu'aucun repli n'a été emprunté sur l'instantané publié, pour les stratégies et les dates comptées ci-dessus. La valeur est une *mesure reproductible et versionnée*, non une hypothèse — c'est là l'apport, davantage que le zéro lui-même.

Elle n'établit pas qu'aucun modèle ne replie jamais. Les chemins de repli sont du code vivant et testé, et un autre instantané peut les emprunter. L'instrumentation existe préci-

sément pour rendre cette question *vérifiable*, pas pour trancher d'avance.

Le contrôle qui rend le résultat crédible n'est pas le zéro mais le test d'équivalence du runner : celui-ci doit reproduire chaque ratio de Sharpe publié *à travers* le moteur instrumenté. Sans lui, l'instrumentation pourrait auditer une stratégie différemment configurée portant le même nom — ce qui s'est effectivement produit lors d'une première rédaction, où une configuration incomplète produisait un `rf_signal` à 0,146 contre 1,123 publié.

5.7.1 Sensibilité aux coûts de transaction

Un ratio de Sharpe net énonce autant une hypothèse de coûts qu'une propriété de stratégie ; les hypothèses retenues ici (10 pb ETF, 30 pb BVC) sont des jugements. Le tableau 5.7 reprice le *même* chemin d'allocation sous $0,5\times$, $1\times$, $1,5\times$ et $2\times$ ces coûts.

TAB. 5.7: Sharpe net du *même* chemin d'allocation, repricé sous des coûts de transaction multipliés. Il ne s'agit pas d'une ré-optimisation : les pondérations sont identiques dans chaque colonne. « Seuil » est le multiplicateur annulant le rendement net.

Univers	Stratégie	$0,5\times$	$1\times$	$1,5\times$	$2\times$	Seuil	Rotation
etf_2017	dcc_garch	0,895	0,888	0,881	0,874	$> 20\times$	0,130
etf_2017	regime_conditional	0,940	0,937	0,934	0,931	$> 20\times$	0,056
etf_2017	rf_signal	0,910	0,904	0,898	0,891	$> 20\times$	0,127
etf_2017	xgb_signal	0,711	0,694	0,678	0,661	$20,0\times$	0,380
full_2021	dcc_garch	1,281	1,228	1,175	1,122	$12,3\times$	0,363
full_2021	regime_conditional	1,275	1,236	1,197	1,158	$16,6\times$	0,293
full_2021	rf_signal	1,199	1,123	1,046	0,970	$8,1\times$	0,779
full_2021	xgb_signal	0,973	0,874	0,773	0,673	$5,2\times$	1,061

Portée de ce calcul. Il s'agit d'un *repricing d'un chemin d'allocation figé sous un modèle de coûts linéaire*, et non d'une analyse de sensibilité avec ré-optimisation. Il répond à « combien ces mêmes transactions auraient-elles coûté », jamais à « qu'aurait fait la stratégie si elle avait su les coûts plus élevés ». Trois conditions le bornent : le chemin de pondérations est figé (aucune stratégie évaluée ici ne lit les coûts) ; les coûts sont linéaires en notionnel échangé, sans terme d'impact de marché ni de capacité ; et le calcul ne s'applique *pas* à une stratégie pénalisée en rotation (phase 4C), où le coût atteint la fonction objectif et modifierait les pondérations — ces scénarios-là devraient être re-simulés, non repricés.

Toutes les estimations ponctuelles de Sharpe net rapportées restent positives à $2\times$ les coûts. Ce constat est descriptif : il ne vaut ni démonstration de robustesse ni validation économique. L'ordre de fragilité est en revanche informatif et recoupe le diagnostic des phases 4B/4C : les modèles de signal à forte rotation sont les plus sensibles aux coûts.

5.8 Gouvernance, explicabilité et monitoring

Trois *model cards* sont générées à partir des artefacts Gold : une carte pour la stratégie de référence `regime_conditional`, et une carte pour chacun des challengers `rf_signal` et `xgb_signal`. La première est la référence non parce qu'une supériorité a été démontrée, mais parce qu'aucun challenger ne l'a déplacée selon le protocole retenu et que sa décision est reconstituable. Les deux autres restent explicitement exploratoires.

L'explication est adaptée à la nature de chaque modèle. La stratégie de référence produit une trace de décision par rééquilibrage (régime, sous-optimizeur, contraintes, poids et éventuel re-

pli). Les challengers à arbres produisent des attributions additives exactes : TreeSHAP natif pour XGBoost et décomposition de chemin pour la forêt aléatoire. Les contrôles vérifient la reconstruction de la prédiction ; une explication ne peut donc pas provenir de poids différents de ceux de l’instantané publié.

Le monitoring est **prêt mais non actif**. L’ordonnanceur demeure arrêté après l’incident d’artefacts déchirés : avant toute reprise, publication atomique, vérification du manifeste avant lecture, répertoires de release versionnés avec verrou, et procédure de rollback exercée sont requis. Cette réserve est intentionnelle : documenté n’est pas validé indépendamment, et prêt au monitoring n’est pas monitoring en production.

5.9 Le produit livré

Le projet livre un **prototype de recherche** composé d’une application web à deux pages et d’une interface REST en lecture seule. Elles partagent une couche de données unique, afin que deux surfaces ne puissent pas afficher des chiffres divergents pour la même stratégie. Elles ne fournissent ni conseil d’investissement, ni ordre, ni service de production.

5.9.1 Page « Résultats de recherche » — destinée aux décideurs

Quatre contraintes d’intégrité sont imposées *par le code* de cette page, plutôt que laissées à la discipline de rédaction :

1. aucun chiffre n’est saisi en dur — tout est calculé à partir des artefacts versionnés, ce qu’un test vérifie en inspectant le code source ;
2. chaque performance affichée est accompagnée de son intervalle de confiance, et le texte indique explicitement que les intervalles se chevauchent ;
3. le cas défavorable — l’univers ETF, où le système perd — est affiché, non dissimulé ;
4. la couche de prédiction de rendement n’est jamais présentée comme l’apport du projet, puisque cinq études n’ont pas établi d’avantage incrémental de portefeuille.

5.9.2 Page « Explorateur de stratégies » — destinée à l’analyse

Cette page ajoute un **explorateur de plafond** : un curseur permettant de faire varier la contrainte de position et d’observer immédiatement son effet sur la performance. C’est le résultat le plus marquant du projet rendu manipulable plutôt que consigné dans un tableau.

5.9.3 L’interface REST

Une API expose les mêmes artefacts pour un usage externe (`/strategies`, `/metrics`, `/equity`, `/weights`, `/compare`, `/crisis`). Elle est délibérément *mince* : elle sert des artefacts versionnés et ne réentraîne jamais de modèle à la demande.

Deux points de conception méritent d’être signalés. D’une part, le point d’entrée `/compare` renvoie toujours l’intervalle de confiance *avec* l’écart de performance : un client ne peut pas récupérer le gain sans son incertitude. D’autre part, `/crisis` expose l’analyse exploratoire avec sa réserve d’attribution et ses limites d’inférence.





FIG. 5.6: Page destinée aux décideurs, vue déroulée complète (écrans 1–2 sur 4). Elle présente d’abord le comportement en crise, lecture descriptive, puis seulement ensuite le ratio de Sharpe, dont l’écart observé n’établit pas une surperformance. L’attribution honnête et les réserves statistiques sont affichées à l’écran, non reléguées en note.






FIG. 5.8: Page d’analyse, vue déroulée complète (écrans 1–2 sur 3) : comparaison de stratégies, métriques nettes de coûts, allocation cible et export CSV. Elle intègre également un explorateur de plafond, qui rend interactif le résultat de la section précédente.

Synthèse du chapitre

- **Exploré** — le détecteur de régime est plus souvent dans l'état « baissier » durant les cinq fenêtres étudiées. Le diagnostic $p = 0,031$ est rapporté comme exploratoire, non confirmatoire.
- **Observé, non démontré** — le système à régimes dépasse le Markowitz classique de 6,2 % sur le portefeuille EURAFRIC et lui est inférieur de 1,6 % sur l'univers ETF. Le classement dépend du protocole d'évaluation et de la mesure retenue.
- **Testé, non établi** — sous validation strictement antérieure, les **huit** comparaisons paires sur la fenêtre gelée ont un intervalle contenant zéro (p de 0,066 à 0,939). Aucun modèle de signal n'établit de surperformance, ni contre la stratégie à régimes ni contre l'équipondéré, sur aucun des deux univers. La correction White/SPA sur 240 configurations n'établit pas non plus de surperformance contre la référence primaire.
- **Observé** — l'optimisation sous contrainte protège mieux que la diversification naïve sur les cinq fenêtres de crise étudiées, avec un délai de récupération environ deux fois plus court. Cette lecture reste descriptive et ce gain revient à la contrainte et à la covariance, non à la couche de régime.
- **Découvert** — le plafond de position, choisi comme règle métier, est le régulariseur le plus efficace du système : 10,1 % de Sharpe, plus que tout modèle testé.
- **Réfuté / non établi** — cinq pistes indépendantes visant à dépasser la ligne de base n'ont pas établi d'avantage incrémental; deux montrent que précision de prédiction et performance de portefeuille sont des objectifs distincts.

Le chapitre suivant conclut en dressant le bilan de ce que le système apporte, des limites qui subsistent, et des directions qu'un prolongement devrait privilégier.




FIG. 5.9: Page « Explorateur de stratégies » — vue déroulée complète (écran 3 sur 3).

Conclusion générale

Ce qui était demandé, ce qui a été livré

L'énoncé d'EURAFRIC Information demandait un système d'optimisation de portefeuille piloté par apprentissage automatique, capable d'apprendre les corrélations dynamiques entre actifs, opérant sous des contraintes réalistes de gestion, et évalué dans un cadre rigoureux de *backtesting* hors échantillon.

Le livrable est une chaîne complète et reproductible : collecte et validation de données provenant de cinq sources hétérogènes ; une couche de préparation en trois niveaux, validée à l'écriture ; un moteur de simulation temporelle dont l'absence de vision du futur est vérifiée par des tests plutôt qu'affirmée ; quatre familles de modèles ajoutées une à une, du rétrécissement de covariance à la détection de régime, de la prédiction de rendement à l'optimisation sensible aux coûts ; un protocole d'évaluation comportant une sélection strictement antérieure, un segment de test gelé, des **comparaisons paires** et une correction pour le nombre d'essais ; trois cartes de modèle, une couche d'explicabilité et une instrumentation des replis ; et deux surfaces de consultation — une application web à deux pages et une interface REST en lecture seule — partageant une couche de données unique. L'ensemble est couvert par **plus de 580 tests** exécutés hors ligne.

Ce que le projet établit

Les résultats sont classés selon leur force probante, et cette distinction est elle-même un résultat de la démarche.

Exploré. Le détecteur de régime, non supervisé et n'ayant jamais reçu de liste de crises, est plus souvent dans son état étiqueté « baissier » à l'intérieur des cinq fenêtres de crise étudiées (91,7 %) qu'en dehors (29,2 %), soit un rapport de **3,13**. Le diagnostic par test des signes ($p = 0,031$) est conservé pour transparence, mais ne constitue pas une preuve confirmatoire : l'échantillon ne comporte que cinq événements et l'état « baissier » est défini par son rendement moyen plus faible. La portée défendable est plus étroite : le modèle produit une lecture causale de l'état de marché associée à ces fenêtres ; il ne démontre pas qu'agir sur cette lecture améliore la performance économique.

Observé, non démontré. Le système complet présente un écart observé de **6,2 %** de ratio de Sharpe net sur le portefeuille visé, et de $-1,6$ % sur l'univers ETF. Le classement change selon le protocole d'évaluation retenu et l'écart provient d'une réduction de volatilité, non d'un supplément de rendement.

Testé, non établi. La réserve précédente n'est plus une réserve : le test manquant a été mené. Sous sélection strictement antérieure — l'entraînement ne pouvant plus consulter des

dates postérieures à sa fenêtre de validation — les **huit** comparaisons pairées effectuées sur la fenêtre de test gelée ont un intervalle contenant zéro (p compris entre 0,066 et 0,939). **Aucune surperformance n'est établie**, ni pour les modèles de signal contre la stratégie à régimes, ni contre l'équipondéré, sur aucun des deux univers.

Un cas résume l'intérêt de la démarche. Sur `full_2021`, le signal XGB calibré obtient 1,308 contre 1,213 pour la stratégie à régimes : en estimation ponctuelle il « bat » la référence, et l'artefact l'enregistre ainsi. Le test pairé donne $p = 0,361$. Le classement ponctuel, celui qu'on aurait rapporté sans ce test, n'est pas soutenu par les données.

Ce n'est pas pour autant une preuve d'équivalence : ne pas rejeter n'est pas accepter l'hypothèse nulle. L'établir demanderait un test d'équivalence contre une marge fixée à l'avance, qui n'a pas été mené. Ces réserves sont affichées dans le rapport, le tableau de bord et l'interface de programmation.

Observé sur cinq fenêtres. Pendant les cinq crises, l'optimisation sous contrainte a systématiquement mieux protégé le capital que la diversification naïve, avec un délai de retour au sommet environ deux fois plus court. L'attribution est faite honnêtement : ce gain revient à la contrainte de position et au modèle de covariance, non à la couche de régime, qui dans trois de ces cinq fenêtres produit exactement la même allocation qu'une stratégie classique.

Découvert. Le plafond de 25 % par actif, retenu comme règle métier et non comme dispositif de modélisation, s'est révélé le régulariseur le plus efficace du système : le relâcher coûte 10,1 % de ratio de Sharpe, davantage que l'écart entre deux modèles quelconques testés sur cet univers. Ce résultat est la reproduction, sur nos propres données, d'un théorème connu — une contrainte de position active équivaut mathématiquement à un rétrécissement de la matrice de covariance.

Réfuté. Cinq pistes indépendantes visant à dépasser la ligne de base ont été explorées et fermées : la prédiction de rendement calibrée honnêtement, un historique cinq fois plus long, l'ajout de données fondamentales, la re-sélection à chaque repli temporel, et le conditionnement de la contrainte au régime. Le constat qui émerge de leur convergence est plus intéressant que chaque échec pris isolément : **aucune de ces pistes n'établit un avantage incrémental de portefeuille dans les protocoles évalués**. Deux de ces études montrent en outre, séparément, que *précision de prédiction et performance de portefeuille sont deux objectifs distincts* : le coefficient d'information a doublé sans que le ratio de Sharpe suive, et il a même reculé dans un cas.

Ce que le projet apporte au-delà des chiffres

La contribution la plus durable de ce travail n'est probablement pas une performance, mais un *dispositif*.

Un incident l'illustre mieux qu'un discours. À trois semaines de la fin, la découverte que les dividendes marocains manquaient dans les données a réduit de plus de moitié le gain publié du système. Le chiffre corrigé a remplacé l'ancien partout — rapport, tableau de bord, livrables — et deux affirmations défendues depuis le début du projet ont dû être retirées. Cette correction n'a été possible que parce que la chaîne était restructurable de bout en bout à partir des sources ; elle n'aurait probablement pas été détectée du tout dans un projet où les résultats sont produits à la main.

De là vient le principe qui structure l'ingénierie du projet : **une règle importante n'est pas documentée, elle est rendue exécutable**. L'impossibilité de consulter le futur, l'interdiction

d'écrire un chiffre de performance en dur dans une interface, la cohérence entre documents publiés, la traçabilité de chaque fonction vers le problème qu'elle traite, l'hermétisme réseau de la suite de tests : chacune de ces règles est un test qui échoue si on l'enfreint. Les trois incidents les plus coûteux du projet ont tous consisté en une règle respectée par discipline jusqu'au jour où elle ne l'a plus été, sans que rien ne le signale. Chacun a donné lieu à un garde-fou automatique, validé en rejouant l'incident réel. Les cartes de modèle et les traces d'explication complètent ce dispositif : la stratégie de référence est expliquée par ses décisions, les challengers par des attributions additives vérifiées, et le monitoring est explicitement prêt mais non actif tant que ses préconditions de publication atomique et de rollback ne sont pas satisfaites.

Limites

Elles sont énoncées ici plutôt que laissées à découvrir.

- **La taille d'échantillon est la limite dominante.** Le portefeuille visé ne compte qu'environ cinq années d'historique exploitable. C'est ce qui empêche de conclure, et aucun modèle supplémentaire ne le corrigera.
- **L'historique marocain gratuit ne remonte pas avant 2021**, ce qui exclut la crise de 2020 de l'univers principal. L'univers ETF, lui, remonte désormais à novembre 2004 et couvre 2008, 2020 et 2022 ; il atténue ce manque sans transformer l'univers BVC en historique long.
- **Un rendement de dividende sur quatre a dû être estimé**, la source publique ne le publiant pas. L'analyse de sensibilité correspondante est documentée, mais la donnée reste une estimation.
- **La correction pour le nombre d'essais est bornée** aux 240 configurations atteignables de la recherche évaluée contre la référence primaire. Les huit comparaisons externes et les résultats contre l'équipondéré restent signalés comme multiplicité externe ou exploratoire.
- **Le système n'a pas été exposé à des conditions d'exploitation réelles** : ni exécution d'ordres, ni flux temps réel, ni couverture du risque de change dirham/dollar, exclus du périmètre dès le cadrage.

Perspectives

Quatre suites se dégagent, classées par rapport valeur/effort.

Étendre l'historique marocain. C'est la seule action qui attaque la limite dominante. Un historique long a été obtenu manuellement pour dix-sept valeurs de la Bourse de Casablanca lors d'une des études ; l'industrialiser — raccorder cet historique profond aux données récentes sur leur période de recouvrement, puis l'intégrer à la chaîne — donnerait au portefeuille visé la profondeur dont il manque, y compris la crise de 2008.

Faire valider le modèle indépendamment et activer le monitoring. Une validation extérieure doit challenger le protocole, les hypothèses de coûts et les artefacts de release. Ensuite seulement, le monitoring pourra être activé après publication atomique, vérification de manifeste, verrouillage des releases et exercice de rollback.

Calibrer la pénalité de rotation par modèle. Les mesures ont établi qu’une valeur globale unique dégrade le bon modèle tout en corrigeant le mauvais. La rendre spécifique à chaque modèle est un travail de calibration circonscrit, au protocole déjà disponible.

Adoucir le basculement de régime. Le basculement franc actuel produit un pic de transactions à chaque frontière de régime. Un mélange continu, pondéré par la probabilité de régime, est une alternative documentée dès la conception et non encore mesurée.

Bilan

Ce projet aura moins appris à l’équipe comment faire gagner un modèle qu’à *savoir si un modèle gagne*. C’est un apprentissage inconfortable : il consiste, l’essentiel du temps, à construire les instruments qui feront tomber les résultats auxquels on tenait — un test qui interdit de voir le futur, un intervalle de confiance qui absorbe l’écart qu’on voulait annoncer, une donnée corrigée qui divise un gain par deux à trois semaines de la remise.

C’est pourtant, dans un domaine où les performances publiées sont notoirement difficiles à reproduire, la seule compétence qui se transporte d’un sujet à l’autre. Le prototype livré à EURAFRIC Information ne prétend pas battre les méthodes classiques, ni recommander ou exécuter une allocation : il expose les écarts historiques observés, leurs limites et les conditions de leur reproduction. Il constitue un socle de recherche et d’analyse, pas un outil de gestion en production.