

Rapport de projet de fin d'année

FILIERE : SMART ICT

Système d'optimisation de portefeuille pilote par apprentissage automatique

*De la donnée financière à une décision explicable,
reproductible et gouvernée*



Réalisé par :

Souhail BOURHIM • Zakarya EL WALI • Yasmine BOUAJINE

Encadré par :

M. Abdelmoultalib MAQIL

EURAFRIC Information

*Projet réalisé à distance pour EURAFRIC Information,
du 18 juin au 1^{er} août 2026*



AGENCE NATIONALE DE RÉGLEMENTATION DES TÉLÉCOMMUNICATIONS

INSTITUT NATIONAL DES POSTES ET TÉLÉCOMMUNICATIONS

Promotion : 2025/2026

*À mes parents,
pour leur patience et leur soutien sans faille.*

*À ma famille et à mes amis,
qui ont accompagné ce parcours.*

*À celles et ceux qui m'ont appris
qu'un résultat que l'on ne sait pas remettre en question
n'est pas encore un résultat.*

Remerciements

Je tiens à exprimer ma reconnaissance à **M. Abdelmoultalib MAQIL**, mon encadrant au sein d'EURAFRIC Information, pour la qualité de son suivi tout au long de ces six semaines. Ses exigences — rattacher chaque composant au problème qu'il traite, livrer une chaîne complète avant de la raffiner, et savoir défendre chaque décision de conception sans notes — ont façonné ce travail bien au-delà de sa dimension technique. Sa manière d'accueillir un résultat négatif comme un résultat à part entière est, rétrospectivement, ce qui a rendu ce projet intéressant.

Je remercie **EURAFRIC Information** d'avoir proposé un sujet à la fois ouvert et exigeant, et d'avoir rendu possible un encadrement à distance qui n'a rien perdu en exigence ; ainsi que l'ensemble des collaborateurs qui ont pris le temps de répondre à nos questions.

Mes remerciements vont également au corps professoral et à l'administration de l'**Institut National des Postes et Télécommunications**, et en particulier à la filière **Smart ICT**, pour la formation reçue et pour le cadre donné à ce projet de fin d'année.

Je remercie enfin mes camarades **Zakarya EL WALI** et **Yasmine BOUAJINE**, avec qui ce projet a été mené, pour la qualité des échanges et pour la rigueur qu'ils ont apportée aux relectures — plusieurs des vérifications décrites dans ce rapport sont nées d'une objection formulée par l'un ou l'autre.

Que ma famille et mes proches trouvent ici l'expression de ma gratitude pour leur soutien constant.

Résumé

Ce projet de fin d'année, réalisé à distance pour EURAFRIC Information, porte sur l'allocation d'un capital entre plusieurs actifs financiers : comment répartir une somme entre quatre valeurs de la Bourse de Casablanca et cinq fonds indiciels internationaux de manière à obtenir le meilleur rendement possible pour un risque maîtrisé.

La théorie classique répond à cette question depuis 1952, mais échoue en pratique pour quatre raisons structurelles : les quantités qu'elle estime sont bruitées, le comportement des marchés change au cours du temps, la diversification disparaît précisément pendant les crises, et les performances mesurées sur le passé sont systématiquement optimistes. Le travail construit une chaîne complète qui traite ces quatre problèmes : préparation et validation des données en trois couches, moteur de simulation temporelle dont l'absence de vision du futur est vérifiée par des tests, puis quatre familles de modèles ajoutées une à une — rétrécissement de la matrice de covariance, détection non supervisée de régimes de marché par modèle de Markov caché, prédiction de rendement par ensembles d'arbres, et optimisation tenant compte des coûts de transaction. L'évaluation est traitée comme un objet d'ingénierie à part entière : sélection strictement antérieure (l'entraînement précède toujours la validation, purge et embargo à la frontière), segment de test gelé, et **comparaisons paires** par bootstrap à blocs — le test de la *différence* entre deux stratégies, que des intervalles marginaux ne fournissent pas.

Les résultats sont rapportés selon leur force probante. Sur cinq fenêtres de crise externes, le détecteur de régime est plus souvent dans son état « baissier » qu'en dehors des fenêtres ; cette association est présentée comme exploratoire, car cinq événements et une définition de l'état par le rendement ne permettent pas une conclusion confirmatoire. L'écart ponctuel entre la stratégie à régimes et la meilleure approche classique est de $-10,47\%$ de ratio de Sharpe net sur le portefeuille visé et de $-1,6\%$ sur l'univers international ; aucun test paillé de cette différence n'est présenté, dans un sens comme dans l'autre. **Le portefeuille visé est libellé en dirhams** au taux de référence officiel de Bank Al-Maghrib et demeure **non couvert** contre le risque de change ; l'univers international, composé uniquement de fonds indiciels en dollars, est mono-devises. Les niveaux de Sharpe ne sont donc pas comparables d'un univers à l'autre. Sur l'instantané publié, 7 des 1184 ajustements — 4 stratégies évaluées, 296 dates de rééquilibrage — ont emprunté un repli d'estimateur : sur ces rééquilibrages, le résultat provient d'un estimateur de substitution et non du modèle que l'étiquette désigne. Le décompte est généré depuis les artefacts, versionné, et confronté à un second artefact indépendant. Après correction White/SPA pour les 240 configurations atteignables, sous validation strictement antérieure, les huit comparaisons paires menées sur la fenêtre de test gelée ont toutes un intervalle contenant zéro : **aucune surperformance n'est établie**, ni pour les modèles de signal contre la stratégie à régimes, ni contre l'équipondéré. Ce n'est pas davantage une preuve d'équivalence, faute de test dédié. Cinq pistes indépendantes ont été explorées et fermées, établissant notamment que précision de prédiction et performance de portefeuille sont deux objectifs distincts : un historique marocain cinq fois plus profond multiplie par deux à quatre la qualité du signal sans produire d'avantage de portefeuille établi. Cette absence traduit d'abord un pouvoir de résolution insuffisant — que ces données ont plus que doublé sans le porter jusqu'au seuil — et non une réfutation. Enfin, le plafond de position imposé comme règle métier s'est révélé le régulariseur le plus efficace du système. Le livrable comprend un tableau de bord de recherche à deux pages et une interface REST de consultation, trois cartes de modèle générées depuis les artefacts, une couche d'explicitabilité adaptée à chaque décision et un monitoring prêt mais non actif, couverts par **plus de 780 tests automatisés**. Les corrections successives des dividendes puis du numéraire ont changé le verdict publié ; elles constituent un résultat d'ingénierie à part entière, car chaque révision est reconstruite, versionnée et propagée automatiquement jusqu'au rapport et aux interfaces.

Mots-clés : optimisation de portefeuille, apprentissage automatique, modèle de Markov caché, matrice de covariance, backtesting, validation hors échantillon, Bourse de Casablanca, gestion du risque.

Abstract

This final-year project, carried out remotely for EURAFRIC Information, addresses capital allocation across financial assets : how to split a sum between four Casablanca Stock Exchange equities and five international index funds so as to obtain the best possible return for a controlled level of risk.

Classical theory has answered this question since 1952, but fails in practice for four structural reasons : the quantities it estimates are noisy, market behaviour changes over time, diversification vanishes precisely during crises, and performance measured on past data is systematically optimistic. This work builds a complete pipeline addressing all four : a three-layer data preparation and validation stack, a walk-forward simulation engine whose inability to see the future is enforced by tests rather than asserted, and four model families added one at a time — covariance shrinkage, unsupervised market-regime detection via a hidden Markov model, return prediction with tree ensembles, and transaction-cost-aware optimisation. Evaluation is treated as an engineering artefact in its own right : strictly forward-only selection (training always precedes validation, with a purge and an embargo at the boundary), a frozen test segment, and **paired** block-bootstrap comparisons — a test of the *difference* between two strategies, which marginal intervals do not provide.

Results are reported by strength of evidence. Across five external crisis windows, the regime detector is more often in its “bear” state than outside those windows; this association is reported as exploratory because five events and a return-based state definition cannot support a confirmatory conclusion. The observed net-Sharpe difference between the regime strategy and the best classical approach is -10.47% on the target portfolio and -1.6% on the international universe; no paired test of either difference is presented, in neither direction. **The target portfolio is MAD-denominated** at Bank Al-Maghrib’s official reference rate and remains **unhedged**; the international universe holds only USD funds and is single-currency. Sharpe levels are therefore not comparable across universes. On the released snapshot 7 of 1184 fits — 4 evaluated strategies, 296 rebalance dates — used an estimator fallback : on those rebalances the result came from a substitute estimator rather than the model its label names. The count is generated from the artifacts, versioned, and cross-checked against an independent second artifact. After White/SPA correction across the 240 reachable configurations and under forward-only selection, all eight paired comparisons on the frozen test window have intervals containing zero : **no outperformance is established**, for either signal model against either the regime strategy or equal weighting. Nor is this evidence of equivalence, absent a dedicated test. Five independent avenues for improvement were explored and closed, establishing among other things that prediction accuracy and portfolio performance are distinct objectives : a fivefold deeper Moroccan history multiplies signal quality by two to four without producing an established portfolio advantage. That absence reflects insufficient resolving power in the first place — which those data more than doubled without carrying it past the threshold — rather than a refutation. Finally, the position cap imposed as a business rule turned out to be the system’s most effective regulariser. Deliverables include a two-page research dashboard and a read-only REST interface, three artefact-generated model cards, decision-specific explainability, and monitoring that is ready but deliberately not live, covered by **more than 780 automated tests**. Successive dividend and base-currency corrections changed the published verdict; they are an engineering result in their own right because every revision is reconstructed, versioned,

and propagated consistently to the report and interfaces.

Keywords : portfolio optimisation, machine learning, hidden Markov model, covariance estimation, backtesting, out-of-sample validation, Casablanca Stock Exchange, risk management.

Liste des acronymes

Acronyme	Signification
API	<i>Application Programming Interface</i> — interface de programmation applicative
BAM	Bank Al-Maghrib — banque centrale du Royaume du Maroc
BVC	Bourse des Valeurs de Casablanca
DCC	<i>Dynamic Conditional Correlation</i> — corrélation conditionnelle dynamique (Engle, 2002)
DSR	<i>Deflated Sharpe Ratio</i> — ratio de Sharpe déflaté
DVC	<i>Data Version Control</i> — outil de versionnement des données et des pipelines
EM	<i>Expectation-Maximization</i> — algorithme d'estimation employé par le modèle de Markov caché
ETF	<i>Exchange-Traded Fund</i> — fonds indiciel coté
EWMA	<i>Exponentially Weighted Moving Average</i> — moyenne mobile à pondération exponentielle
FRED	<i>Federal Reserve Economic Data</i> — base de données macroéconomiques de la Réserve fédérale de Saint-Louis
GARCH	<i>Generalized Autoregressive Conditional Heteroskedasticity</i> — modèle de volatilité variable dans le temps
HMM	<i>Hidden Markov Model</i> — modèle de Markov caché
IC	<i>Information Coefficient</i> — coefficient d'information
INPT	Institut National des Postes et Télécommunications
MAD	Dirham marocain (code ISO 4217)
ML	<i>Machine Learning</i> — apprentissage automatique
MPT	<i>Modern Portfolio Theory</i> — théorie moderne du portefeuille (Markowitz, 1952)
OOS	<i>Out-Of-Sample</i> — hors échantillon
PFA	Projet de Fin d'Année
PSI	<i>Population Stability Index</i> — indice de stabilité d'une distribution entre une référence et une période évaluée
RC	<i>Reality Check</i> — test de White corrigeant la sélection du meilleur parmi de nombreux candidats
REST	<i>Representational State Transfer</i> — style d'architecture des interfaces web
RF	<i>Random Forest</i> — forêt aléatoire
SLSQP	<i>Sequential Least Squares Programming</i> — algorithme d'optimisation sous contraintes
SPA	<i>Superior Predictive Ability</i> — test de Hansen pour la comparaison d'un ensemble de modèles à une référence
USD	Dollar américain (code ISO 4217)

Acronyme	Signification
VIX	<i>Volatility Index</i> — indice de volatilité implicite du marché américain
XGB	<i>eXtreme Gradient Boosting</i> — bibliothèque de <i>gradient boosting</i> d'arbres

Glossaire

Actif Objet dans lequel on peut placer de l'argent : action d'entreprise, obligation d'État, fonds indiciel.

Allocation Répartition d'un capital entre plusieurs actifs. Synonyme usuel : *poïds* du portefeuille.

Backtest Simulation d'une stratégie sur des données passées, en rejouant le temps tel qu'il s'est écoulé.

Biais de survivance / de vision du futur Toute situation où une décision passée est influencée par une information qui n'était pas disponible à ce moment-là. C'est l'erreur la plus grave possible dans ce domaine : elle produit des performances impossibles à reproduire en conditions réelles.

Bootstrap à blocs Méthode d'estimation de l'incertitude consistant à reconstituer des milliers d'historiques fictifs en retirant au sort des blocs de journées consécutives, afin de préserver la structure temporelle des rendements.

Coefficient d'information Corrélation de rang entre rendements prédits et rendements réalisés : mesure la capacité d'un signal à *classer* les actifs, sans exiger que ses prédictions soient justes en niveau.

Data snooping Biais produit lorsque de nombreuses stratégies sont essayées sur les mêmes données et que seule la meilleure est retenue. Même sans fraude ni fuite temporelle, le maximum observé est alors optimiste.

Corrélation Mesure du degré auquel deux actifs évoluent ensemble. Comprise entre -1 (mouvements opposés) et $+1$ (mouvements identiques).

Covariance (matrice de) Tableau décrivant conjointement la volatilité de chaque actif et la corrélation de chaque paire. C'est la description du risque d'un portefeuille, et la quantité la plus difficile à estimer.

Drawdown (perte maximale) Baisse maximale subie entre un sommet et le creux qui le suit. Répond à la question « combien aurais-je pu perdre au pire moment ? ».

Équipondération (1/N) Stratégie consistant à placer la même somme sur chaque actif. Sans paramètre à estimer, donc sans erreur d'estimation : c'est la référence de comparaison honnête.

Fonds indiciel (ETF) Fonds coté en bourse répliquant un indice de marché ; en acheter une part revient à détenir une fraction de tout l'indice.

Hors échantillon Se dit d'une performance mesurée sur des données qui n'ont servi ni à entraîner ni à sélectionner le modèle évalué.

Modèle de Markov caché Modèle statistique supposant que les observations sont engendrées par un état non observable qui change au cours du temps ; l'état est inféré à partir de ce qu'il produit.

Numéraire Monnaie dans laquelle un patrimoine, son profit et son risque sont mesurés. Pour un investisseur marocain non couvert, un actif en dollars doit inclure la variation USD/MAD dans son rendement en dirhams.

Population Stability Index (PSI) Indicateur comparant la distribution d'une variable ou d'un score entre une période de référence et une période évaluée. Il signale une dérive ; il n'en explique pas la cause.

Point de base Un centième de point de pourcentage (0,01 %). Unité usuelle des coûts de transaction.

Ratio de Calmar Rendement annualisé divisé par la perte maximale. Mesure le rendement obtenu par unité de *pire* perte, là où le ratio de Sharpe divise par la volatilité moyenne.

Ratio de Sharpe Rendement obtenu par unité de risque, le risque étant mesuré par la volatilité. Principal indicateur de comparaison entre stratégies — et, comme le montre le chapitre 5, un indicateur dont le choix n'est pas neutre.

Régime de marché Période durant laquelle le marché se comporte de manière homogène (par exemple : hausse régulière et faible volatilité, ou baisse et forte volatilité). Les régimes ne sont pas observables directement.

Rendement logarithmique Rendement calculé comme $\ln(P_t/P_{t-1})$. Se somme dans le temps, contrairement au rendement en pourcentage — d'où son usage systématique dans ce projet.

Rétrécissement Aussi appelé *shrinkage*, technique consistant à rapprocher une estimation bruitée d'une cible simple et stable. On accepte un biais volontaire en échange d'une forte réduction de variance.

Sharpe déflaté Probabilité qu'une performance mesurée soit réellement positive après correction du nombre de stratégies essayées et de la non-normalité des rendements.

Turnover (rotation) Proportion du portefeuille effectivement échangée lors d'un rééquilibrage. Détermine directement les coûts de transaction supportés.

Sélection strictement antérieure Découpage de validation dans lequel l'entraînement précède toujours la fenêtre de validation, séparé d'elle par une purge et un embargo. À la différence de la validation croisée purgée en blocs, aucune date postérieure à la validation ne peut entrer dans l'entraînement : c'est la seule forme qui simule une décision d'allocation séquentielle.

Test pairé Comparaison de deux stratégies sur les *mêmes* dates, en rééchantillonnant les deux séries avec les mêmes blocs. Teste la *différence*, ce que deux intervalles de confiance marginaux ne font pas : ils peuvent se chevaucher alors que la différence est systématiquement positive.

Validation croisée purgée Variante de la validation croisée adaptée aux séries temporelles : les observations d'entraînement dont l'horizon chevauche le bloc de test sont retirées (*purge*), et une bande de journées suivant ce bloc est écartée (*embargo*).

Volatilité Ampleur des variations d'un actif, mesurée par l'écart-type de ses rendements. Mesure usuelle — et imparfaite — du risque.

Table des matières

Remerciements	iii
Résumé	v
Abstract	vii
Liste des acronymes	ix
Glossaire	xi
Faits publiés	1
1 Contexte : l'entreprise, le stage et le sujet	3
Ce que ce chapitre explique	3
1.1 L'organisme d'accueil : EURAFRIC Information	3
1.1.1 Activité et positionnement	3
1.1.2 Quelques repères	3
1.1.3 Pourquoi ce sujet dans cette entreprise	3
1.2 Le cadre du stage	4
1.3 Le sujet tel qu'il a été formulé	5
1.4 Objectifs et périmètre	6
1.5 Déroulement du travail	6
1.6 Guide de lecture	7
Synthèse du chapitre	7
2 Problématique : de l'allocation d'actifs à ses quatre échecs	9
Ce que ce chapitre explique	9
2.1 Le problème, en une phrase	9
2.2 Un portefeuille, un rendement, un risque	9
2.2.1 Le vocabulaire minimal	9
2.2.2 Une image	10
2.3 La diversification, et pourquoi elle fonctionne	10

2.4	Markowitz (1952) : formaliser l'intuition	11
2.5	Les quatre échecs de la théorie classique	12
2.5.1	P1 — L'estimation est bruitée	12
2.5.2	P2 — Le monde ne reste pas immobile	13
2.5.3	P3 — La diversification disparaît quand elle devient nécessaire	13
2.5.4	P4 — Se tromper soi-même : le surapprentissage	14
2.6	Ce que le Machine Learning peut — et ne peut pas — apporter	15
2.7	Les contraintes réalistes de gestion	16
2.8	Problématique retenue	16
2.9	État de l'art	16
	Synthèse du chapitre	17
3	Architecture : la chaîne de données et les garde-fous	19
	Ce que ce chapitre explique	19
3.1	Trois couches, une seule direction	19
3.2	Deux univers, et une frontière de données canonique	20
3.3	Le dividende manquant : un défaut trouvé tardivement	21
3.4	Le moteur de backtest, frontière de confiance	22
3.5	Rendre les règles exécutables	23
3.6	Reproduire, ordonnancer, tracer : trois outils, trois questions	23
3.6.1	DVC — « ce résultat correspond-il encore à ces données ? »	23
3.6.2	Dagster — « qu'est-ce qui doit se réexécuter, et quand ? »	25
3.6.3	MLflow — « d'où vient ce chiffre ? »	25
3.7	Ce que l'exploitation a appris	25
3.8	La pile technique	26
	Synthèse du chapitre	26
4	Modélisation et protocole d'évaluation	29
	Ce que ce chapitre explique	29
4.1	Les références classiques	29
4.2	Premier échelon : mieux estimer le risque (P1)	30
4.3	Deuxième échelon : reconnaître le régime de marché (P2, P3)	31
4.4	Troisième échelon : prédire les rendements	32
4.5	Quatrième échelon : payer le prix des transactions	32
4.6	Le protocole d'évaluation (P4)	33
4.6.1	Rejouer le temps	33
4.6.2	Choisir les hyperparamètres sans tricher	33
4.6.3	Deux objectifs, deux instruments	34
4.6.4	Un verdict rendu une seule fois, avec sa marge d'erreur	35

4.7	La discipline expérimentale	35
	Synthèse du chapitre	36
5	Résultats, validation et produit livré	37
	Comment lire ce chapitre	37
5.1	Le résultat principal	37
5.1.1	Une réserve sur le choix de la mesure	39
5.2	Ce chiffre est-il réel ? La validation hors échantillon	39
5.2.1	Corriger pour l'ampleur de la recherche	41
5.3	Comportement en crise : une lecture métier descriptive (P3)	42
5.4	La détection de régime : une analyse exploratoire (P2)	43
5.5	La contrainte fait plus que les modèles (P1)	45
5.6	Ce qui ne fonctionne pas : cinq pistes fermées	46
5.7	L'étiquette correspond-elle au modèle ? (P4)	47
5.7.1	Sensibilité aux coûts de transaction	48
5.8	Gouvernance, explicabilité et monitoring	48
5.9	Le produit livré	49
5.9.1	Page « Résultats de recherche » — destinée aux décideurs	49
5.9.2	Page « Explorateur de stratégies » — destinée à l'analyse	49
5.9.3	L'interface REST	49
	Synthèse du chapitre	54
6	Le marché marocain : ce que vingt ans de données changent	55
6.1	Deux lectures d'un même résultat	55
6.2	Constituer vingt ans de Bourse de Casablanca	55
6.2.1	Ce que les sources permettent réellement	55
6.2.2	L'univers retenu	56
6.2.3	Ce que ces données ne sont pas	56
6.3	Le protocole : celui du chapitre 4, sans adaptation	56
6.4	Étape A — le modèle s'aiguise réellement	57
6.5	Étape B — le portefeuille, lui, ne suit pas	58
6.6	Ce que « pas de gain » signifie exactement	58
6.7	Ce qui ne s'est pas reproduit	59
6.8	Ce qu'il faudrait pour intégrer ce panel à la release	60
7	Révisions, qualité de mesure et gouvernance de la preuve	61
7.1	Trois mesures du même système, trois verdicts	61
7.2	Le numéraire : une notion simple aux conséquences matérielles	62
7.3	Le protocole fait partie du résultat	63

7.4	Du data snooping à une conclusion corrigée	64
7.5	Une chaîne de preuve exécutable	64
7.6	Intégrité des modèles sous défaillance	65
7.7	Lecture pour une organisation financière régulée	66
8	Démonstrateur, explicabilité et préparation industrielle	67
8.1	Deux interfaces, un seul contrat de vérité	68
8.2	Expliquer des objets différents de manière différente	68
8.3	Performance économique : regarder aussi l'intensité de trading	68
8.4	Artefacts de gouvernance	74
8.5	Reproductibilité et exploitation contrôlée	74
8.6	Monitoring prêt, mais non actif	75
8.7	Notebooks : exploration sans contaminer la release	75
8.8	Ce qui est livré, et ce qui ne l'est pas	75
9	L'univers global_2004 : un test enfin équitable	79
9.1	Deux défauts d'identification, mesurés et non supposés	79
9.2	Un protocole gelé avant toute donnée	79
9.3	Le défaut d'expressivité est levé	80
9.4	Q1 — la couche de régimes face au comparateur classique	80
9.5	Q2 — la famille des challengers, et la correction	81
9.6	Les challengers honnêtement sélectionnés	81
9.7	Limites	82
	Conclusion générale	85

Table des figures

1.1	Déroulement du stage	6
2.1	La frontière efficiente	11
2.2	Les quatre problèmes P1–P4	12
2.3	Volatilité et régimes de marché	13
2.4	Rupture de la diversification en crise	15
3.1	Le pipeline DVC	24
3.2	Catalogue des actifs Dagster	25
4.1	Sortie du détecteur de régime	31
4.2	Backtest à fenêtre glissante	34
4.3	Protocole de sélection	35
5.1	Évolution des portefeuilles	38
5.2	Intervalles de confiance	40
5.3	Comportement en crise	43
5.4	Détection non supervisée des crises	44
5.5	Effet du plafond par actif	45
5.6	Tableau de bord — page décideur	50
5.7	Tableau de bord — résultats de recherche	51
5.8	Tableau de bord — explorateur de stratégies	52
5.9	Tableau de bord — explorateur de stratégies	53
6.1	Coefficient d’information : univers canonique et panel profond	57
6.2	Pouvoir de résolution du protocole	59
7.1	Évolution du résultat après correction successive de la définition du rendement et du numéraire. Les deux valeurs positives sont historiques et remplacées par la mesure en MAD. Source : artefacts Gold versionnés.	62
7.2	Avant et après correction du numéraire sur l’univers mixte. La conversion est appliquée aux niveaux de prix avec uniquement l’information disponible à la date considérée ; aucune position de couverture n’est simulée.	63

7.3	Protocoles temporels comparés. Une purge retire les observations dont l'horizon de cible chevauche la validation ; l'embargo impose un espace supplémentaire à la frontière.	63
7.4	Correction White/SPA sur 240 configurations	64
7.5	Sept couches de contrôle entre la donnée et la phrase publiée. Chaque garde-fou est né d'une classe d'erreur effectivement observée dans le projet.	65
8.1	Architecture fonctionnelle du prototype. Les flèches représentent une direction de preuve : toute information publiée doit remonter à un artefact validé, puis à une transformation et à une source.	67
8.2	Tableau de bord — page « Résultats de recherche », vue générale. Le numéraire MAD, le caractère non couvert et l'écart observé sont visibles avant tout détail de stratégie.	69
8.3	Tableau de bord — attribution des résultats et comportement dans les fenêtres de crise. Les diagnostics exploratoires sont séparés des preuves confirmatoires. . .	70
8.4	Tableau de bord — page « Explorateur de stratégies ». Cette vue expose la performance, le risque, les coûts et l'allocation au lieu de réduire la décision à un seul ratio.	71
8.5	Contrat OpenAPI du service de recherche en lecture seule. Les routes de publication exposent l'allocation historisée, son explication, sa carte de modèle et la provenance du snapshot ; aucune route d'ordre n'existe.	72
8.6	Explicabilité adaptée au rôle du modèle. À gauche, importances globales des challengers ; à droite, trace reconstituée de la décision finale du système à régimes sur <code>full_2021</code>	73
8.7	Sharpe net et rotation moyenne par rééquilibrage sur <code>full_2021</code> en MAD. Les modèles de signal occupent généralement la zone la plus coûteuse sans compensation robuste en performance.	73
8.8	État industriel du livrable. « Prêt » signifie que les artefacts et contrôles existent ; cela ne signifie pas qu'un service est actif ou autorisé en production.	74
8.9	Graphique d'actifs Dagster : orchestration locale et lignage des couches du pipeline. L'ordonnanceur reste arrêté sur la release de maintenance.	77
9.1	Expressivité de l'allocation	80
9.2	Correction pour tests multiples	81
9.3	Sharpe des stratégies retenues	82

Liste des tableaux

1.1	Repères sur EURAFRIC Information	4
1.2	Cadre du stage	4
1.3	Périmètre du projet	6
3.1	Les trois couches de données	20
3.2	Les deux univers de test	20
3.3	Pile technique	26
5.1	Performance comparée, hors échantillon	38
5.2	Comparaisons pairées	40
5.3	Correction pour tests multiples	41
5.4	Diagnostic de la détection	44
5.5	Les cinq pistes testées	46
5.6	Intégrité des modèles	47
5.7	Sensibilité aux coûts	48
6.1	Univers canonique et panel marocain profond	56
6.2	Panel marocain profond : test gelé	58

Faits publiés

Ce chapitre énonce, sans interprétation, ce que les résultats de ce dépôt établissent et ce qu'ils n'établissent pas. Chaque énoncé est produit à partir des artefacts Gold ; aucun nombre n'y est saisi à la main.

1. `full_2021` est libellé en MAD, converti au taux de référence officiel de Bank Al-Maghrib (USDMAD, MAD par USD). Le portefeuille reste **non couvert** : la variation de change réalisée est incluse dans la performance, aucun contrat à terme ni coût de roulement n'est modélisé.
2. `etf_2017` est libellé en USD : cet univers ne contient que des ETF mono-devise, n'a donc jamais présenté de défaut de numéraire, et est **inchangé** par la correction.
3. Les niveaux de Sharpe ne sont pas comparables d'un univers à l'autre : les deux univers sont libellés dans des devises différentes, sur des fenêtres différentes et avec un nombre d'actifs différent.
4. Sur `full_2021`, l'écart ponctuel entre `regime_conditional` et `max_sharpe` est de **-10,47 %** (0,9571 contre 1,0690 de Sharpe net). L'écart est également défavorable sur `etf_2017` : **-1,6 %**.
5. Ces écarts ne démontrent pas une supériorité de l'approche classique : aucun test païré de cette différence n'est présenté.
6. `regime_conditional` demeure le comparateur primaire pré-spécifié des tests White/SPA. Ce choix a été fixé avant l'observation des résultats et n'est pas réécrit maintenant que le signe de l'écart a changé.
7. Correction pour tests multiples (White 2000, Hansen 2005) sur les 240 configurations atteignables : aucun candidat n'établit de surperformance face au comparateur primaire pré-spécifié.
8. Walk-forward imbriqué (fenêtre OOS 2023-07-28 → 2026-07-24, 781 lignes) : le classement est sensible au protocole d'évaluation et à la fenêtre hors échantillon associée. Ratio de Sharpe dégonflé (DSR) = 0,7370 sur 198 configurations.
9. Intégrité des modèles : 7 ajustements sur 1 184 ont emprunté un repli d'estimateur (4 stratégies évaluées, 296 dates de rééquilibrage). Sur ces rééquilibrages, le résultat a été produit par un estimateur de substitution et non par le modèle que son étiquette désigne : les séries concernées sont des HYBRIDES. La portée de cette mesure est exactement l'ensemble compté ci-dessus : elle n'affirme pas qu'aucun repli n'est possible sur un autre instantané.
10. Aucune stratégie n'est recommandée, déployée, ni présentée comme une valeur ajoutée établie. Ce livrable est un prototype de recherche.

Comparateur primaire. Le comparateur `regime_conditional` a été fixé *avant* l'observation des résultats et sert de référence aux tests de White et de Hansen sur 240 configurations. Il n'est ni un système recommandé, ni un candidat déployé.

Chapitre 1

Contexte : l'entreprise, le stage et le sujet

Ce que ce chapitre explique

Ce chapitre situe le travail : l'entreprise qui l'a commandé, le cadre universitaire dans lequel il s'inscrit, le sujet tel qu'il a été formulé, et la manière dont il a été conduit en six semaines et demie. Il se termine par un guide de lecture, car les chapitres suivants ne s'adressent pas tous au même lecteur.

1.1 L'organisme d'accueil : EURAFRIC Information

1.1.1 Activité et positionnement

EURAFRIC Information est une entreprise de services informatiques marocaine, créée en **octobre 2008** et implantée sur le campus BMCE Bank, Bouskoura Green City, à Casablanca. Elle conçoit et exploite des systèmes d'information pour des acteurs de la **banque, de la finance, de l'assurance et du crédit à la consommation**, et se présente comme un centre de services informatiques mutualisés au service de plusieurs entités clientes.

Son expertise couvre le développement applicatif, les réseaux et télécommunications, les systèmes et bases de données, ainsi que la cybersécurité. L'entreprise exploite ses propres centres de données et opère, en outre, comme prestataire de services de confiance au sens de la loi marocaine 43-20 relative aux services de confiance pour les transactions électroniques.

1.1.2 Quelques repères

Les éléments du tableau 1.1 sont ceux publiés par l'entreprise sur son site institutionnel ; ils sont reproduits à titre de repères et non vérifiés indépendamment.

1.1.3 Pourquoi ce sujet dans cette entreprise

Le rapprochement entre une société de services informatiques et un sujet de finance quantitative n'a rien d'incongru dès lors que l'on regarde sa clientèle. Une banque, une compagnie d'assurance ou un organisme de crédit ne se contente pas d'exécuter des opérations : il place des fonds propres, gère des réserves techniques, et doit répondre à des exigences de contrôle du risque.

TAB. 1.1 : Repères sur l'organisme d'accueil, d'après ses publications institutionnelles.

Élément	Valeur
Création	Octobre 2008
Implantation	Campus BMCE Bank, Bouskoura Green City, Casablanca
Effectif	Environ 350 collaborateurs, majoritairement ingénieurs
Secteurs servis	Banque, finance, assurance, crédit à la consommation
Infrastructure	2 centres de données, plus de 3 000 serveurs, plus de 10 000 utilisateurs connectés
Activité projet	Plus de 300 projets par an
Certifications	Conception et exploitation de centre de données TIER III, ISO 22301 (continuité d'activité), accréditation prestataire de services de confiance (loi 43-20)
Distinction	<i>Top Employer Maroc</i> , cinq années consécutives jusqu'en 2024

Les outils d'aide à l'allocation d'actifs relèvent donc directement du système d'information de ces métiers.

Deux caractéristiques du marché marocain rendent en outre le sujet particulièrement intéressant à traiter localement. La Bourse de Casablanca est un marché de taille modeste, peu liquide sur certaines valeurs, et dont l'historique public gratuit est court — trois contraintes qui invalident l'application mécanique de méthodes calibrées sur les marchés américains. Et la conjonction d'actifs marocains libellés en dirham et d'actifs internationaux libellés en dollar pose une question d'allocation qui n'a pas d'équivalent direct dans la littérature standard.

1.2 Le cadre du stage

Ce travail constitue le **Projet de Fin d'Année (PFA)** de l'année universitaire 2025–2026, réalisé dans le cadre de la formation **Smart ICT** de l'Institut National des Postes et Télécommunications (INPT).

TAB. 1.2 : Cadre administratif et humain du projet.

Période	Du 18 juin au 1 ^{er} août 2026, soit 44 jours (environ six semaines et demie)
Établissement	INPT — filière Smart ICT, année 2025–2026
Organisme commanditaire	EURAFRIC Information, Bouskoura
Modalité	À distance, avec une journée sur site
Encadrement	M. Abdelmoultalib MAQIL (EURAFRIC Information)
Équipe	Souhail BOURHIM, Zakarya EL WALI, Yasmine BOUAJINE

Le projet s'est déroulé **à distance** : l'équipe ne s'est rendue sur le site de Bouskoura qu'une seule fois, le suivi s'effectuant ensuite par points d'étape réguliers. Cette modalité a une conséquence directe sur la manière de travailler, et elle explique une partie des choix décrits au chapitre 3 : un encadrant qui ne voit pas l'écran par dessus l'épaule juge sur ce qui est livré et sur ce qui est écrit. Un livrable par phase, des chiffres reconstituables depuis les sources et des règles vérifiées par des tests plutôt que par la confiance ne sont pas seulement de bonnes pratiques ici : ce sont les conditions du travail à distance.

L'encadrement a été assuré côté entreprise. Sa méthode a façonné le projet autant que le sujet lui-même, et mérite d'être explicitée, car elle explique plusieurs partis pris qui pourraient sinon

surprendre :

- **Traçabilité** — tout composant doit indiquer à quel problème identifié il répond ; un composant qu'on ne sait pas rattacher à un problème est retiré, si sophistiqué soit-il.
- **Produit minimal d'abord** — une chaîne complète de bout en bout avec des modèles simples vaut mieux qu'une moitié de chaîne avec des modèles élaborés.
- **Défendabilité** — chaque membre de l'équipe doit pouvoir justifier n'importe quelle décision de conception sans notes.
- **Honnêteté sur les limites** — les manques de données et les questions ouvertes se déclarent d'eux-mêmes plutôt que d'être découverts par le lecteur.

1.3 Le sujet tel qu'il a été formulé

L'énoncé remis par l'entreprise est le suivant :

Dans le cadre de ce challenge, les étudiants travailleront sur une problématique centrale de la finance quantitative : comment allouer intelligemment un capital entre plusieurs actifs financiers afin de maximiser le rendement tout en maîtrisant le risque. Ils concevront et implémenteront un système d'optimisation de portefeuille piloté par le Machine Learning, capable d'analyser des séries temporelles financières, d'apprendre les corrélations dynamiques entre actifs et de proposer automatiquement des stratégies d'allocation robustes, sous des contraintes réalistes de gestion. Le prototype devra être évalué dans un cadre rigoureux de backtesting sur des données hors échantillon, avec une attention particulière portée à la robustesse, au risque de surapprentissage et à la pertinence financière des résultats.

Cet énoncé est plus prescriptif qu'il n'y paraît. Quatre de ses expressions fixent en réalité l'architecture du travail, et chacune est traitée dans un chapitre précis de ce rapport :

- « *apprendre les corrélations dynamiques* » — les corrélations entre actifs ne sont pas constantes ; les estimer comme si elles l'étaient est le premier des quatre problèmes exposés au chapitre 2.
- « *sous des contraintes réalistes de gestion* » — cette incise a été traitée comme une *contrainte* et non comme un indicateur : interdiction de vente à découvert, plafond par actif et coûts de transaction s'appliquent à l'intérieur de l'optimisation, pas seulement au moment de rendre compte. Le chapitre 5 montre que cette décision, prise pour réalisme, s'est révélée le levier de performance le plus efficace du projet.
- « *données hors échantillon* » et « *risque de surapprentissage* » — l'évaluation devient un objet d'ingénierie à part entière, décrit au chapitre 4.
- « *pertinence financière des résultats* » — un gain moyen ne suffit pas ; le comportement en période de crise est examiné séparément.

L'énoncé demande un système « capable de proposer automatiquement des stratégies d'allocation robustes ». Il ne demande pas de démontrer que le Machine Learning bat les méthodes classiques. Cette nuance est décisive : elle autorise — et même impose — de rapporter un résultat négatif lorsque c'est ce que les données montrent. Le chapitre 5 en contient plusieurs.

1.4 Objectifs et périmètre

L'objectif retenu est la livraison d'une **chaîne complète, documentée et reproductible**, sous la forme d'un **prototype de recherche** : collecte et validation des données, modèles d'allocation, évaluation rigoureuse, et deux surfaces de consultation (une application web et une interface de programmation). Il ne constitue ni un conseil d'investissement, ni un outil de production, ni un dispositif d'exécution d'ordres.

Le périmètre a été délimité explicitement dès le cadrage, et tenu.

TAB. 1.3 : Ce qui est dans le périmètre, et ce qui en a été écarté délibérément.

Dans le périmètre	Hors périmètre (assumé)
Chaîne de données de bout en bout, versionnée et ordonnancée	Flux de données en temps réel
Modèles d'allocation classiques et ML, sous contraintes de gestion	Passage d'ordres et exécution réelle
Évaluation hors échantillon avec intervalles de confiance	Déploiement sur une infrastructure d'hébergement
Tableau de bord de recherche et explorateur de stratégies, interface REST	Couverture du risque de change dirham/dollar

L'exclusion du temps réel et de l'exécution d'ordres n'est pas une facilité : elle concentre l'effort sur la question que l'énoncé pose réellement, qui est celle de la *qualité de la décision d'allocation*, non celle de son acheminement vers un marché.

1.5 Déroulement du travail

Le projet a été conduit en phases successives, chacune close par un livrable remis à l'encadrant (figure 1.1). Deux observations sur ce déroulement méritent d'être faites, parce qu'elles ne se lisent pas sur un planning prévisionnel.




FIG. 1.1 : Déroulement réel du projet. Les bandes du haut sont les phases ; l'histogramme du bas est l'activité de développement *réellement enregistrée* dans l'historique de versionnement, jour par jour. Les onze premiers jours ne comportent aucun code.

Onze jours avant la première ligne de code. Le cadrage — comprendre le domaine, identifier les quatre problèmes structurels, inventorier les sources de données disponibles pour

le marché marocain et constater leurs limites — a occupé la première semaine et demie. C’est ce travail préalable qui a permis d’écarter très tôt des pistes coûteuses, et de découvrir avant de s’engager que l’historique gratuit de la Bourse de Casablanca ne remonte pas au-delà de 2021 — contrainte qui a directement produit la conception à double univers décrite au chapitre 3.

Une activité très inégale, et c’est normal. L’histogramme montre des journées à quinze contributions et des semaines quasi vides. Les creux correspondent aux phases d’exécution longue — certaines évaluations demandent plusieurs heures de calcul — et aux périodes de rédaction des livrables. Le volume de contributions mesure l’activité de développement, pas l’avancement du projet ; c’est précisément pour cela qu’il est présenté à côté des phases et non à leur place.

1.6 Guide de lecture

Les chapitres qui suivent ne visent pas le même lecteur, et peuvent être lus séparément.

- Le **chapitre 2** expose le problème financier et ses quatre échecs structurels. Il ne suppose *aucune* connaissance en finance : toute notion y est définie à son premier emploi. C’est le chapitre à lire en premier pour un lecteur non spécialiste.
- Le **chapitre 3** décrit la chaîne de données et les garde-fous qui empêchent les erreurs de mesure. Il intéressera un lecteur d’ingénierie logicielle ou de données.
- Le **chapitre 4** présente les modèles et, surtout, le protocole d’évaluation. Il ne contient volontairement aucun résultat, afin que la méthode puisse être jugée indépendamment de ses conclusions.
- Le **chapitre 5** donne les résultats, chacun assorti de sa marge d’erreur, et distingue explicitement ce que le projet démontre, ce qu’il observe sans le démontrer, et ce qu’il réfute. Il présente également le produit livré.
- Le **chapitre 6** est consacré au marché marocain : il teste ce que change un historique de vingt ans de la Bourse de Casablanca, et mesure ce que le dispositif d’évaluation peut, ou ne peut pas, conclure à partir de lui. C’est le chapitre à lire pour un lecteur intéressé par la place de Casablanca en particulier.

Synthèse du chapitre

- Le projet a été réalisé **à distance** pour **EURAFRIC Information**, entreprise de services informatiques créée en 2008 à Bouskoura, dont les clients relèvent de la banque, de la finance et de l’assurance — secteurs pour lesquels l’aide à l’allocation d’actifs est un besoin métier direct.
- Il s’agit du **PFA** de la filière Smart ICT de l’INPT, conduit à trois du 18 juin au 1^{er} août 2026, sous encadrement d’entreprise.
- L’énoncé impose quatre exigences qui structurent tout le rapport : corrélations dynamiques, contraintes réalistes de gestion, évaluation hors échantillon, et pertinence financière — et il n’exige nulle part que le ML l’emporte.
- Le périmètre exclut délibérément le temps réel, l’exécution d’ordres, l’hébergement et la couverture de change, afin de concentrer l’effort sur la qualité de la décision d’allocation.

- Les onze premiers jours, sans code, ont produit la contrainte de données la plus structurante du projet — celle qui a imposé d'évaluer chaque stratégie sur deux univers plutôt qu'un.

Chapitre 2

Problématique : de l'allocation d'actifs à ses quatre échecs

Ce que ce chapitre explique

Ce chapitre pose le problème que le projet cherche à résoudre. Il est écrit pour être lu sans connaissance préalable de la finance de marché : chaque notion est définie au moment où elle apparaît, et chaque formule est précédée de la phrase qui dit ce qu'elle signifie.

Le fil est le suivant. Nous partons d'une question simple — comment répartir une somme d'argent entre plusieurs placements ? — et nous montrons que la réponse classique, formulée par Harry Markowitz en 1952 et encore enseignée aujourd'hui, repose sur quatre hypothèses qui ne tiennent pas en pratique. Ces quatre échecs, notés **P1** à **P4**, structurent l'intégralité du travail présenté dans ce rapport : chaque composant développé y répond explicitement.

2.1 Le problème, en une phrase

Une banque, une compagnie d'assurance ou un particulier dispose d'une somme d'argent et doit la répartir entre plusieurs placements. Combien mettre sur chacun ?

La question paraît anodine. Elle ne l'est pas : c'est l'une des décisions les plus lourdes de conséquence en gestion financière, parce qu'elle détermine à la fois ce que l'on peut espérer gagner et ce que l'on risque de perdre. Et elle n'a pas de réponse évidente, parce que les deux objectifs — gagner davantage et risquer moins — s'opposent presque toujours.

L'objet de ce projet est de construire un système capable de proposer automatiquement une telle répartition, à partir de données de marché, et de mesurer honnêtement si ce système fait mieux que les méthodes classiques.

2.2 Un portefeuille, un rendement, un risque

2.2.1 Le vocabulaire minimal

Un *actif* est un objet dans lequel on peut placer de l'argent : une action d'entreprise, une obligation d'État, un fonds indicel. Un *portefeuille* est simplement une répartition de capital entre plusieurs actifs : par exemple 40 % sur l'un, 35 % sur un deuxième, 25 % sur un troisième. Ces proportions sont appelées les *poids* du portefeuille ; par construction, elles totalisent 100 %.

Définition — Rendement

Le *rendement* d'un actif sur une période est la variation relative de sa valeur. Un actif passant de 100 à 105 dirhams sur un mois a produit un rendement de +5 % sur ce mois. Le rendement d'un portefeuille est la moyenne des rendements de ses actifs, *pondérée par les poids* : c'est mécanique, sans surprise.

Le rendement est la partie facile. La difficulté est ailleurs : un placement ne produit pas le même rendement chaque mois. Il monte, il descend, il repart. Cette irrégularité est ce que la finance appelle le *risque*, et sa mesure usuelle est la *volatilité*.

Définition — Volatilité

La *volatilité* est l'écart-type des rendements : elle mesure l'amplitude habituelle des variations autour de la moyenne. Deux placements peuvent rapporter 8 % par an en moyenne, l'un en variant de ± 2 % d'un mois sur l'autre, l'autre de ± 15 %. Le second est beaucoup plus risqué, bien que sa moyenne soit identique. C'est cette distinction que la volatilité capture.

2.2.2 Une image

Un gérant qui doit répartir un capital ressemble à un agriculteur qui doit répartir ses parcelles entre plusieurs cultures. Chaque culture a un rendement moyen espéré et une sensibilité propre au climat. L'agriculteur ne connaît ni le temps qu'il fera, ni les prix à la récolte ; il ne peut que raisonner sur ce que les saisons passées lui ont appris, en sachant que la prochaine ne leur ressemblera pas exactement.

Cette image, à laquelle nous reviendrons, contient déjà l'essentiel des difficultés traitées dans ce rapport : on décide aujourd'hui, on récolte demain, et l'on ne dispose que du passé pour s'orienter.

2.3 La diversification, et pourquoi elle fonctionne

L'adage — ne pas mettre tous ses œufs dans le même panier — est connu de tous. Sa traduction financière est plus précise, et c'est cette précision qui compte.

Si deux placements montent et descendent *en même temps*, les répartir entre eux ne réduit presque rien : quand l'un chute, l'autre chute aussi. Si en revanche ils évoluent *indépendamment*, ou mieux encore en sens contraire, alors les mauvaises périodes de l'un sont partiellement compensées par les bonnes de l'autre. Le portefeuille dans son ensemble varie moins que chacune de ses composantes.

La grandeur qui mesure ce phénomène est la *corrélation*.

Définition — Corrélation et covariance

La *corrélation* entre deux actifs est un nombre compris entre -1 et $+1$. À $+1$, ils évoluent exactement de concert ; à 0 , leurs mouvements sont sans rapport ; à -1 , ils s'opposent systématiquement. La *covariance* est la même idée, exprimée dans les unités des rendements plutôt que normalisée. Rangées dans un tableau croisant tous les actifs deux à deux, ces covariances forment la *matrice de covariance*, notée Σ : c'est l'objet central de toute la théorie qui suit.

Le point à retenir, et il porte tout le reste du rapport : **la valeur de la diversification ne dépend pas des actifs pris isolément, mais de la manière dont ils bougent les uns par rapport aux autres.** Un portefeuille se juge sur ses corrélations autant que sur ses rendements.

2.4 Markowitz (1952) : formaliser l'intuition

Harry Markowitz a transformé cette intuition en un problème mathématique posé et résolu, ce qui lui a valu le prix Nobel d'économie en 1990. Son raisonnement tient en trois temps.

1. À partir de l'historique, on estime le rendement moyen espéré de chaque actif (noté μ) et la matrice de covariance Σ .
2. Pour tout portefeuille de poids w , on calcule alors son rendement espéré $w^\top \mu$ et sa volatilité $\sqrt{w^\top \Sigma w}$.
3. On cherche enfin les poids w qui, pour un niveau de risque donné, maximisent le rendement espéré.

L'ensemble des portefeuilles ainsi obtenus forme une courbe appelée *frontière efficiente* (figure 2.1) : chaque point est un portefeuille dont on ne peut améliorer le rendement sans accepter davantage de risque. Tout portefeuille situé sous cette courbe est, au sens de ce critère, sous-optimal.




FIG. 2.1 : La frontière efficiente, calculée sur les actifs réels du projet. Chaque point gris est un portefeuille tiré au hasard ; la courbe bleue rassemble ceux qu'aucun autre ne domine. Les actifs pris individuellement (points rouges) se situent tous à l'intérieur de la frontière : c'est la diversification, rendue visible.

Pour comparer deux portefeuilles d'un seul chiffre, on rapporte le rendement au risque consenti.

Définition — Ratio de Sharpe

Le *ratio de Sharpe* divise le rendement d'un portefeuille par sa volatilité. Il répond à la question : « combien de rendement ce portefeuille produit-il par unité de risque supportée ? » Un Sharpe de 1,0 est généralement jugé bon, 0,5 médiocre. C'est la mesure de référence du secteur, et celle que ce rapport emploie le plus souvent — non sans réserves, sur lesquelles nous reviendrons au chapitre 5.

Cette construction est élégante, enseignée partout, et implémentée dans tous les outils professionnels. Elle a pourtant une réputation ambivalente auprès des praticiens. La raison tient en une phrase : **elle suppose connus des paramètres qui ne le sont pas.**

2.5 Les quatre échecs de la théorie classique

Markowitz suppose que μ et Σ sont donnés. Dans la réalité, on ne les connaît jamais : on les *estime* à partir du passé, et cette estimation est la source de quatre difficultés distinctes. Ces quatre problèmes structurent tout le projet ; chaque composant décrit aux chapitres suivants indique explicitement auxquels il répond.




FIG. 2.2 : Les quatre échecs structurels de l'optimisation moyenne-variance classique, et la réponse apportée par le système développé. Chaque fonction du code source déclare, dans sa documentation, le ou les problèmes qu'elle adresse — une exigence de traçabilité vérifiée automatiquement par la suite de tests.

2.5.1 P1 — L'estimation est bruitée

Estimer une corrélation entre deux actifs à partir de quelques centaines d'observations donne une valeur approximative. Avec neuf actifs, il faut estimer 36 corrélations et 9 volatilités simultanément, à partir du même historique limité. Chacune porte son erreur.

Le problème n'est pas seulement que ces estimations soient imprécises : c'est que l'optimiseur les traite comme exactes. S'il lit dans les données qu'un actif possède une corrélation légèrement plus faible que les autres — un pur accident d'échantillonnage — il conclut que cet actif est un excellent diversificateur et lui attribue un poids considérable. L'optimiseur ne distingue pas le signal du bruit ; il amplifie ce dernier.

On résume souvent ce comportement en disant que l'optimisation moyenne-variance est un maximiseur d'erreur d'estimation. Ce n'est pas une critique de la méthode, mais de son usage naïf : elle donne exactement ce qu'on lui demande, à partir d'entrées dont on a négligé l'incertitude.

Le résultat pratique est un portefeuille concentré sur quelques positions, qui paraît optimal sur l'historique utilisé pour le construire, et se comporte médiocrement sur les données suivantes.

2.5.2 P2 — Le monde ne reste pas immobile

La théorie suppose implicitement que les rendements sont tirés d'une même loi de probabilité, stable dans le temps. Les marchés ne se comportent pas ainsi. Ils traversent des *régimes* : des périodes calmes et haussières, des périodes agitées et baissières, avec des transitions parfois brutales.

Concrètement, la volatilité se regroupe — les journées agitées se suivent — et les corrélations elles-mêmes se déforment. Des paramètres estimés sur une période calme décrivent mal la période de tension qui suit.




FIG. 2.3 : Volatilité glissante du marché sur l'univers ETF du projet (2004–2026). Les périodes d'agitation sont manifestement groupées et non réparties uniformément : c'est la non-stationnarité (P2), visible à l'œil nu. Les zones ombrées correspondent aux crises identifiées au chapitre 5.

C'est précisément ce que le *Machine Learning* peut apporter : plutôt que de supposer un monde unique, on peut apprendre à reconnaître dans quel régime le marché se trouve, et adapter la posture du portefeuille en conséquence.

2.5.3 P3 — La diversification disparaît quand elle devient nécessaire

C'est le plus contre-intuitif des quatre, et le plus coûteux.

En période normale, des actifs variés — actions marocaines, actions américaines, or, obligations — évoluent avec une certaine indépendance. La diversification fonctionne. Mais en période de

crise, les investisseurs vendent *simultanément* tout ce qu'ils peuvent vendre pour se procurer des liquidités. Les corrélations convergent alors vers 1 : tout baisse ensemble.

Autrement dit : la protection que l'on a payée toute l'année en acceptant un rendement moindre cesse d'agir exactement le jour où l'on en a besoin. Les parapluies se referment quand la pluie commence.

Ce phénomène n'est pas théorique, et les données du projet permettent de le mesurer. Elles apportent toutefois une nuance que la formulation usuelle omet, et qui mérite d'être exposée telle quelle.

Si l'on calcule simplement la corrélation moyenne sur *tous* les couples d'actifs de l'univers, on obtient 0,24 en période calme et 0,16 en crise : la corrélation *baisse*, ce qui contredit apparemment P3. Cette moyenne est trompeuse, car elle agrège deux mouvements opposés. En les séparant (figure 2.4) :

- **entre actions** (SPY, QQQ, EEM), la corrélation passe de 0,79 en période calme à 0,85 en crise, et culmine à 0,94 lors du krach de mars 2020. P3 se vérifie pleinement : à l'intérieur d'une même classe d'actifs, tout chute ensemble ;
- **entre actions et valeurs refuges** (or, obligations d'État longues), la corrélation, déjà quasi nulle en temps normal ($-0,04$), devient nettement négative en crise ($-0,18$) : c'est la fuite vers la qualité, ces actifs montant lorsque les actions s'effondrent.

La leçon est double, et elle oriente toute la suite du travail. D'une part P3 est bien réel, mais il s'exprime au sein d'une classe d'actifs. D'autre part une diversification véritablement multi-classes conserve une partie de son efficacité en crise — à condition que le portefeuille puisse effectivement se déplacer vers les actifs qui se découplent. C'est exactement ce que fait l'optimisation sous contrainte, et le chapitre 5 montre qu'elle protège en crise là où une répartition figée ne le fait pas.

2.5.4 P4 — Se tromper soi-même : le surapprentissage

Les trois premiers problèmes concernent les marchés. Le quatrième concerne l'analyste, et c'est celui auquel ce projet a consacré le plus d'efforts.

Pour évaluer une stratégie, on la teste sur des données historiques : c'est le *backtest*. L'exercice est indispensable — et il est piégeux, pour deux raisons distinctes.

Le biais d'anticipation (*lookahead*). Il consiste à utiliser, au moment de décider, une information qui n'était pas encore disponible. Il prend des formes très discrètes : normaliser des données sur l'historique complet avant de découper le test, employer un cours de clôture non encore publié, ou choisir un paramètre en observant le résultat final. Une stratégie affectée d'un biais d'anticipation affiche des performances remarquables et ne les reproduit jamais en conditions réelles.

Le surapprentissage par répétition. Il est plus insidieux encore. En essayant cinquante stratégies sur le même historique, on en trouvera mécaniquement une qui paraît excellente — même si aucune n'a la moindre valeur. C'est le hasard, et non la compétence, qui produit ce résultat. Publier la meilleure sans mentionner les quarante-neuf autres revient à publier un mensonge statistique, souvent commis de bonne foi.




FIG. 2.4 : Corrélations glissantes (63 jours) sur l'univers ETF, décomposées par famille. En crise (zones ombrées), les actions se resserrent entre elles tandis que l'or et les obligations s'en détachent. Une moyenne calculée sur l'ensemble des couples masquerait ces deux effets en les compensant l'un par l'autre — d'où la décomposition retenue ici.

C'est le problème que l'encadrement du projet a désigné comme le critère de correction le plus important : tout chemin par lequel une donnée future pourrait influencer une décision passée constitue un échec automatique. Le chapitre 3 montre comment cette exigence a été traduite en une garantie structurelle plutôt qu'en une règle de discipline.

2.6 Ce que le Machine Learning peut — et ne peut pas — apporter

Il serait tentant de présenter le *Machine Learning* comme la solution à ces quatre problèmes. Ce serait inexact, et le présent rapport se garde de le faire.

Ce qu'il peut raisonnablement apporter. Sur P1 et P2, l'apport est tangible : des estimateurs de covariance plus élaborés qu'une simple moyenne historique (rétrécissement de Ledoit-Wolf, moyennes exponentielles, modèles GARCH) réduisent l'erreur d'estimation, et des modèles à variables latentes (chaînes de Markov cachées) permettent de détecter un changement de régime sans qu'on ait à le spécifier à l'avance. Sur P4, le *Machine Learning* apporte surtout sa *méthodologie* d'évaluation — validation croisée adaptée aux séries temporelles, correction du nombre d'essais, intervalles de confiance.

Ce qu'il ne peut pas apporter. La prédiction fiable des rendements futurs. C'est l'application que l'on attend spontanément, et c'est la plus difficile : le rapport signal/bruit des rendements financiers est extrêmement faible, et les marchés sont compétitifs par nature — toute régularité exploitable tend à disparaître dès qu'elle est exploitée. Le chapitre 5 présente cinq tentatives indépendantes menées dans ce projet pour exploiter une telle prédiction, et le

résultat honnête auquel elles conduisent.

Une distinction méthodologique importante, et vérifiée expérimentalement au chapitre 5 : améliorer la précision de prédiction d'un modèle n'améliore pas nécessairement la performance du portefeuille qui en découle. Ce sont deux objectifs différents, et le second n'est pas une conséquence automatique du premier.

2.7 Les contraintes réalistes de gestion

Un dernier élément sépare l'exercice académique d'un prototype crédible : un gérant professionnel n'est jamais libre de choisir n'importe quelle répartition. Il opère sous contraintes, imposées par la réglementation, par son mandat ou par la prudence.

- **Pas de vente à découvert** — les poids sont positifs : on ne peut pas parier à la baisse sur un actif.
- **Un plafond par actif** — dans ce projet 25 %, afin d'éviter les portefeuilles excessivement concentrés.
- **Des coûts de transaction** — chaque transaction se paie. Le projet retient 10 points de base sur les ETF internationaux et 30 sur les valeurs de la Bourse de Casablanca, moins liquides.

Le cahier des charges du client formule explicitement cette exigence de « contraintes réalistes de gestion ». Elle a été traitée non comme une mesure secondaire, mais comme une contrainte à part entière de l'optimiseur et du simulateur. Nous verrons au chapitre 5 que cette décision, prise pour des raisons de réalisme métier, s'est révélée produire l'un des résultats les plus marquants du projet.

2.8 Problématique retenue

L'ensemble de ce qui précède se résume en une problématique en trois volets, qui sont ceux du présent rapport :

1. **Construire** un système d'allocation de portefeuille exploitant le *Machine Learning* pour répondre à P1, P2 et P3, sous des contraintes de gestion réalistes, et sur un univers combinant valeurs de la Bourse de Casablanca et ETF internationaux.
2. **Évaluer** ce système avec une rigueur suffisante pour que P4 ne puisse pas invalider les conclusions : absence de biais d'anticipation garantie par construction, données de test jamais utilisées pour le choix des paramètres, et intervalles de confiance sur chaque chiffre publié.
3. **Rapporter** honnêtement ce que le système apporte et ce qu'il n'apporte pas — un résultat négatif correctement établi ayant, dans ce domaine, davantage de valeur qu'un résultat positif invérifiable.

2.9 État de l'art

Les travaux sur lesquels le projet s'appuie sont les suivants.

Markowitz (1952). *Portfolio Selection* est le texte fondateur qui introduit le cadre moyenne-variance et la frontière efficiente. Il constitue la référence par rapport à laquelle tout le reste se compare.

DeMiguel et al. (2009). Dans *Optimal Versus Naive Diversification*, les auteurs établissent un résultat célèbre et dérangeant : sur de nombreux jeux de données, le portefeuille équipondéré — répartir également, sans rien estimer — fait aussi bien, voire mieux, que les portefeuilles optimisés, une fois les coûts pris en compte. Précisément parce qu'il n'estime rien, il ne peut pas surapprendre le bruit. Ce portefeuille sert dans ce projet de *haie d'honnêteté* : toute méthode sophistiquée doit d'abord démontrer qu'elle le dépasse.

Ledoit et Wolf (2004), *shrinkage* de covariance. Réponse statistique directe à P1 : rapprocher la matrice de covariance empirique d'une cible structurée, avec une intensité estimée sur les données elles-mêmes.

Engle (2002), *Dynamic Conditional Correlation*. Réponse à P2 au niveau de l'estimation : un modèle où volatilités et corrélations évoluent dans le temps plutôt que d'être supposées constantes.

Jagannathan et Ma (2003), *Risk Reduction in Large Portfolios*. Résultat théorique important pour ce projet : imposer une contrainte de poids active équivaut mathématiquement à opérer un rétrécissement de la matrice de covariance. Autrement dit, une contrainte de gestion réaliste effectuée implicitement le travail de régularisation que l'on attend d'une méthode sophistiquée. Le chapitre 5 reproduit ce résultat sur les données du projet.

López de Prado (2018), *Advances in Financial Machine Learning*. Ouvrage de référence sur P4. Deux outils en sont directement repris : la *purge* et *embargo* — qui retirent du jeu d'entraînement les observations temporellement voisines du jeu de validation, appliqués ici dans un découpage strictement antérieur plutôt qu'en blocs (chapitre 4) — et le *Deflated Sharpe Ratio* de Bailey et López de Prado (2014), qui corrige un ratio de Sharpe observé du nombre de stratégies essayées pour l'obtenir.

Synthèse du chapitre

L'allocation de portefeuille consiste à répartir un capital entre plusieurs actifs de manière à maximiser le rendement tout en maîtrisant le risque. La théorie classique de Markowitz formalise ce compromis, mais suppose connus des paramètres qui doivent en réalité être estimés à partir d'un historique limité. Il en découle quatre difficultés : l'amplification du bruit d'estimation (P1), la non-stationnarité des marchés (P2), l'effondrement de la diversification en période de crise (P3), et le risque que l'analyste se trompe lui-même en évaluant sa propre stratégie (P4).

Le *Machine Learning* offre des réponses crédibles à P1 et P2, une réponse partielle à P3, et surtout — c'est le point le moins attendu — un appareil méthodologique pour traiter P4. Il n'offre pas, en revanche, de prédiction fiable des rendements futurs.

Le chapitre suivant décrit l'architecture du système construit pour répondre à cette problématique, en commençant par l'infrastructure de données sur laquelle tout le reste repose.

Chapitre 3

Architecture : la chaîne de données et les garde-fous

Ce que ce chapitre explique

Le chapitre 2 a posé quatre échecs à corriger. Celui-ci décrit la machine construite pour y répondre — non pas les modèles eux-mêmes, qui font l’objet du chapitre suivant, mais la chaîne qui les alimente et le dispositif qui les surveille.

Le fil conducteur tient en une phrase, et c’est la décision d’ingénierie la plus structurante du projet : **une règle importante n’est pas documentée, elle est rendue exécutable**. Interdire à un modèle de consulter le futur, garantir que deux documents citent le même chiffre, imposer que chaque fonction déclare le problème qu’elle traite — chacune de ces règles est, dans ce dépôt, un test qui échoue si on la viole. La raison est empirique : les trois incidents les plus coûteux du projet, relatés en fin de chapitre, ont tous consisté en une règle respectée par discipline jusqu’au jour où elle ne l’a plus été, sans que rien ne le signale.

3.1 Trois couches, une seule direction

Les données brutes d’un marché financier sont hétérogènes : des cours d’actions marocaines relevés à la Bourse de Casablanca, des cours de fonds indiciels américains, des indicateurs macroéconomiques publiés par la Réserve fédérale américaine et par Bank Al-Maghrib. Chaque source a son calendrier, son format, ses trous et ses erreurs. Les mélanger sans discipline produit un jeu de données dont plus personne ne sait comment il a été fabriqué.

Définition — Architecture en médaillon

Organisation d’un entrepôt de données en couches successives, chacune obtenue par transformation *déterministe* de la précédente : **Bronze** (les données telles que reçues, jamais modifiées), **Silver** (les mêmes données alignées, nettoyées et validées), **Gold** (les tableaux directement exploitables par un modèle). Une couche ne lit jamais une couche située en aval d’elle ; l’information ne circule que dans un sens.

Ce projet applique ce patron strictement (tableau 3.1). Son intérêt n’est pas esthétique : il rend chaque anomalie *localisable*. Si un chiffre final surprend, il existe exactement une couche où l’erreur a pu naître, et les couches amont sont intactes pour le prouver.

Deux conventions méritent d’être signalées, parce qu’elles paraissent techniques et sont en réalité des décisions de fond.

TAB. 3.1 : Les trois couches de données, leur contenu et la garantie que chacune apporte.

Couche	Contenu	Garantie apportée
Bronze	Cours ETF, cours et dividendes BVC, indicateurs macro, taux de change — au format reçu.	Immuable. Une source qui change produit un nouveau fichier, jamais une réécriture : l'historique reste auditable.
Silver	Rendements logarithmiques, calendriers alignés (la Bourse de Casablanca et les places américaines ne ferment pas les mêmes jours), zones d'illiquidité signalées.	Validée à l'écriture par un contrat de données : rendement journalier borné à $\pm 50\%$, au moins 500 lignes, index trié, aucune valeur manquante. Une violation interrompt le traitement.
Gold	Deux matrices de rendements (une par univers), variables ML causales, tests de stationnarité, résultats des comparaisons de stratégies.	Seule couche que la modélisation a le droit de lire. Aucun modèle n'ouvre un fichier Bronze ou Silver.

Les rendements sont logarithmiques, c'est-à-dire calculés comme $\ln(P_t/P_{t-1})$ plutôt que comme la variation en pourcentage. La raison est qu'ils s'additionnent : le rendement d'une semaine est la somme des cinq rendements quotidiens, ce qui n'est pas vrai des pourcentages. Toute la chaîne en dépend.

Les trous de calendrier sont comblés vers l'avant, jamais vers l'arrière. Si la Bourse de Casablanca est fermée un jour où New York est ouverte, on reporte le dernier cours *connu*. Comblé avec le cours *suivant* — techniquement plus simple, et proposé par toutes les bibliothèques — reviendrait à injecter dans le passé une information du futur. C'est la première forme, et la plus discrète, du biais que le chapitre 2 a appelé P4.

3.2 Deux univers, et une frontière de données canonique

Le portefeuille visé par EURAFRIC mêle quatre valeurs de la Bourse de Casablanca — Maroc Telecom, Attijariwafa Bank, CIH Bank, Banque Centrale Populaire — et cinq fonds indiciels internationaux couvrant les grandes actions américaines, les technologiques, les marchés émergents, l'or et les obligations d'État.

La chaîne canonique rencontre une frontière claire : **aucune source gratuite, contractualisée et reproductible dans ce pipeline ne fournit l'historique complet de la Bourse de Casablanca avant la mi-2021**. Le portefeuille complet publié ne peut donc pas être étudié sur le krach de 2020, ni sur la crise de 2008. Plutôt que de dissimuler cette limite, nous avons adopté une **double base de test** (tableau 3.2) : toute stratégie est évaluée sur les deux univers, et les deux résultats sont publiés côte à côte.

TAB. 3.2 : Les deux univers d'évaluation. Toute stratégie du projet est exécutée sur les deux, sans exception.

Univers	Actifs	Jours	Période et intérêt
full_2021	9	1 321	2021-07 → 2026-07 — le portefeuille réel visé
etf_2017	5	5 656	2004-11 → 2026-07 — inclut 2008, 2020 et 2022

Ce choix a un coût de rédaction — il faut commenter deux résultats au lieu d'un, et ils ne

concordent pas toujours — mais il a une vertu décisive : une conclusion qui ne tient que sur un seul univers se voit immédiatement. Le chapitre 5 montre que c’est précisément le cas du résultat principal.

Cette frontière ne signifie pas que les données marocaines antérieures à 2021 n’existent pas. Une étude séparée a constitué un univers BVC profond de 12 actions sur 2005–2024 (56 184 lignes de panel, soit environ cinq fois le volume de `full_2021`) et couvrant 2008. Elle a amélioré le coefficient d’information des signaux RF/XGB d’un facteur deux à quatre, sans établir un avantage de portefeuille net de coûts. Cet historique reste hors de la release : ses prix bruts doivent encore être contractualisés, rapprochés de la période de recouvrement récente et ajustés des dividendes et opérations sur titres. C’est une limite de gouvernance des données et d’intégration, non une absence de données.

L’univers ETF a été étendu de 2017 à 2004 en cours de projet, lorsque nous avons constaté que la date de départ initiale était une décision arbitraire et non une limite des données. Les douze années supplémentaires ont réduit la largeur des intervalles de confiance d’environ 38 % et ajouté la crise de 2008. Le nom technique de l’univers, `etf_2017`, est resté : le renommer aurait invalidé les artefacts déjà produits, pour un gain purement cosmétique.

3.3 Le dividende manquant : un défaut trouvé tardivement

Cet épisode est rapporté en détail parce qu’il illustre mieux que tout autre le type de défaut contre lequel l’architecture doit protéger : silencieux, non détecté par les tests existants, et *favorable* au résultat que nous espérons.

Définition — Dividende

Part du bénéfice qu’une entreprise verse à ses actionnaires, généralement une fois par an. Un actionnaire gagne donc de deux manières : la hausse du cours, et les dividendes encaissés. Ne compter que la première revient à sous-estimer durablement ce que l’actif a réellement rapporté.

La chaîne mélangeait deux définitions du rendement sans que personne ne l’ait décidé. Les cours des fonds indiciels arrivaient *ajustés des dividendes* (rendement total), tandis que les cours de la Bourse de Casablanca arrivaient *hors dividendes*. Les rendements du dividende publiés pour ces quatre valeurs s’échelonnent de 3,8 % à 5,5 % par an : c’est l’ordre de grandeur de la performance qui disparaissait chaque année du côté marocain.

L’instinct veut qu’un biais commun s’annule dans une comparaison. **Il ne s’annule pas ici**, et la raison est instructive. La stratégie équilibrée est *contrainte* de détenir les actifs sous-évalués ; les optimiseurs sont *libres* de les sous-pondérer — et ils l’ont fait, précisément parce que le dividende manquant les faisait paraître moins bons qu’ils ne l’étaient. Les modèles étaient donc crédités d’avoir évité un défaut de notre propre traitement de données. Le biais gonflait mécaniquement l’avantage mesuré du ML.

La correction a nécessité d’écrire un collecteur dédié : l’interface publique prévue à cet effet dans la bibliothèque utilisée était hors service, et les montants ont dû être extraits du site de la Bourse de Casablanca, *avec leur date de détachement* — car un dividende doit être crédité le jour où il est effectivement versé, non réparti sur l’année. Les montants obtenus concordent avec une source indépendante à environ 0,3 point de pourcentage près.

Effet de la correction — et la suite de la chaîne

Estimation initiale : +14,3 %. Après correction des dividendes : +6,2 %. **Ces deux valeurs sont désormais *superseded*.** Après conversion du portefeuille en dirhams aux taux de référence officiels de Bank Al-Maghrib, l'écart ponctuel devient −10,47 %. Ces écarts sont descriptifs : ils ne constituent pas un test pairé.

Un second résultat, présenté depuis le début du projet, ne survit pas non plus : l'équipondération ne bat plus les optimiseurs une fois les coûts déduits.

Trois conséquences ont été tirées, et elles sont toutes de nature architecturale. Le cache de dividendes est devenu une *dépendance déclarée* du pipeline — auparavant, l'unique donnée qui rend les rendements marocains complets était invisible des deux graphes de dépendances du projet. Un échec de collecte *interrompt* désormais le traitement au lieu d'émettre un avertissement que personne ne lit sur une exécution nocturne ; une collecte *vide* compte comme un échec, car un résultat à zéro ligne est la même corruption déguisée en succès. Enfin — et c'est le point le plus embarrassant — la suite de tests atteignait le réseau réel : en masquant le cache, les tests restaient *verts* tout en écrivant des rendements hors dividendes. Un blocage des connexions sortantes, actif par défaut dans toute la suite, ferme définitivement ce trou.

3.4 Le moteur de backtest, frontière de confiance

Définition — Backtest à fenêtre glissante

Simulation d'une stratégie sur des données passées, où l'on rejoue le temps *comme il s'est écoulé* : à chaque date de rééquilibrage, le modèle est réentraîné sur les seules données disponibles à cette date, décide une répartition, puis subit les rendements des jours suivants. Toute autre méthode mesure une performance impossible à obtenir en pratique.

Le composant le plus important du projet n'est pas un modèle : c'est le moteur qui les exécute. Il est écrit une fois, au chapitre du projet correspondant à la phase 2, et *aucune* des extensions ultérieures ne l'a modifié.

Sa conception repose sur une inversion de responsabilité. Une stratégie ne va pas chercher ses données : elle reçoit, en argument, une fenêtre d'entraînement que le moteur a découpée pour elle. Le moteur tronque la matrice de rendements *et chaque tableau de variables auxiliaire* à la date de décision avant tout appel. Une stratégie ne peut donc pas consulter le futur, non parce qu'elle s'en abstient, mais parce qu'elle ne le reçoit jamais. Symétriquement, le moteur *vérifie* ce qu'il reçoit en retour : poids positifs, somme égale à un, plafond de 25 % respecté. Un producteur défectueux est rejeté à la frontière.

Cinq tests verrouillent cette propriété. Le plus parlant construit une stratégie *tricheuse*, à qui l'on transmet délibérément l'intégralité du jeu de données et qui choisit chaque mois l'actif le plus performant du mois suivant. Passée par le moteur, sa performance doit s'effondrer à zéro. Si elle ne s'effondre pas, le moteur fuit. Un second test corrompt le *futur* d'un tableau de variables et exige qu'*aucune* décision passée n'en soit modifiée — tout en vérifiant que la stratégie utilise réellement ces variables, faute de quoi la garantie serait vide de sens.

Le moteur applique aussi les contraintes de gestion réelles : interdiction de vendre à découvert, plafond de 25 % par actif, et surtout des coûts de transaction déduits à chaque rééquilibrage — 10 points de base sur les fonds indiciels, 30 sur la Bourse de Casablanca, dont la liquidité est plus faible. Les performances brute et nette sont toujours rapportées

ensemble : une stratégie qui gagne brut et perd net est un résultat, pas un incident.

3.5 Rendre les règles exécutables

Le dépôt compte **plus de 780 tests**, exécutés hors ligne et sur des jeux de données synthétiques minuscules. Leur nombre importe moins que leur nature : la majorité ne vérifie pas qu’une fonction calcule juste, mais qu’une *règle de projet* ne peut pas être enfreinte. Ils sont d’ailleurs nommés d’après la règle qu’ils protègent, non d’après la fonction qu’ils appellent, de sorte que la suite se lit comme la liste des erreurs déjà commises.

- **Absence de vision du futur** — les cinq tests décrits ci-dessus, plus un test d’intégration par famille de modèles ajoutée ensuite.
- **Hermétisme** — toute connexion sortante est bloquée pendant les tests. C’est ce qui rend l’affirmation « la suite s’exécute hors ligne » vérifiable plutôt que déclarative.
- **Cohérence entre documents** — un test compare tous les fichiers de résultats publiés et échoue s’ils divergent sur une stratégie commune, une fenêtre d’évaluation ou une valeur de référence. Il a été validé en rejouant sur une copie les trois incidents réels du projet : il les détecte tous les trois, alors que chacun n’avait été repéré que par hasard.
- **Aucun chiffre écrit à la main** — un test lit le *code source* de la couche qui alimente le tableau de bord et refuse toute valeur de performance saisie en dur. Une surface destinée à un décideur est le pire endroit où laisser un chiffre périmé.
- **Traçabilité P1–P4** — la première exigence de l’encadrant est elle aussi vérifiée automatiquement : chaque fonction publique doit déclarer le ou les problèmes qu’elle traite. 107 fonctions sur 110 sont conformes ; les 3 exceptions sont des utilitaires d’infrastructure, inscrites avec leur justification dans une liste qui n’a le droit que de se réduire.

3.6 Reproduire, ordonnancer, tracer : trois outils, trois questions

Trois outils d’exploitation coexistent dans le projet. On les confond souvent ; ils répondent en réalité à trois questions différentes, et supprimer l’un d’entre eux laisserait sa question sans réponse.

3.6.1 DVC — « ce résultat correspond-il encore à ces données ? »

DVC décrit le traitement comme un graphe d’étapes, chacune déclarant ses entrées, sa commande et ses sorties (figure 3.1). Une seule commande recalcule alors *uniquement* ce qui est devenu obsolète, en comparant les empreintes des fichiers.

L’apport dépasse le confort. Le graphe rend le calcul *invalidable* : si une donnée amont change, tous les résultats qui en dépendent sont marqués périmés, qu’un humain s’en souviene ou non. Le projet a appris cette leçon à ses dépens — le fichier contenant la performance de référence à battre n’était initialement pas suivi par le pipeline, et a dérivé d’une version de données sans que rien ne le signale. Il est aujourd’hui une sortie d’étape à part entière.

Le pipeline DVC : dix étapes, un graphe de dépendances explicite





FIG. 3.1 : Le pipeline de bout en bout : dix étapes et vingt-et-une dépendances explicites, de la collecte des sources aux chiffres affichés par le tableau de bord. Cette figure est *engendrée à partir du fichier de configuration du pipeline* : elle ne peut pas décrire une chaîne différente de celle réellement exécutée.

3.6.2 Dagster — « qu'est-ce qui doit se réexécuter, et quand ? »

Dagster planifie l'exécution et matérialise la lignée (figure 3.2) : neuf *actifs* de données, chacun rattaché à sa couche du médaillon, avec la date de leur dernière production. La règle imposée au projet est que Dagster *ordonnance* le traitement mais n'en contient aucune logique ; ses actifs appellent les fonctions du code source, inchangées.



Asset name	Code location / Asset group	Status
bvc_dividends BVC per-share dividend history (amounts + ex-dates) scraped from casa...	definitions.py bronze	Materialized Jul 29, 11:00 PM
gold_layer Stationarity report + lagged macro features — Phase 2 input.	definitions.py gold	Materialized Jul 29, 11:02 PM
log_returns Calendar-aligned, Pandera-validated log-returns (9-asset universe), on a...	definitions.py silver	Materialized Jul 29, 11:02 PM
log_returns_etf ETF-only log-returns (2017+, includes COVID + the 2022 rate shock) — L...	definitions.py silver	Materialized Jul 29, 11:02 PM
ml_features_layer Phase 3 causal ML features (both universes) + reproducibility manifest ...	definitions.py gold	Materialized Jul 29, 11:02 PM
raw_bam_macro Bank Al-Maghrib indicators (FX + policy rate).	definitions.py bronze	Materialized Jul 29, 11:00 PM
raw_bvc_prices BVC (Bourse de Casablanca) equity prices.	definitions.py bronze	Materialized Jul 29, 11:00 PM
raw_etf_prices ETF adjusted-close prices via yfinance.	definitions.py bronze	Materialized Jul 29, 11:02 PM
raw_fred_macro Global macro indicators via FRED.	definitions.py bronze	Materialized Jul 29, 11:00 PM

FIG. 3.2 : Catalogue Dagster : les neuf actifs de données du projet, leur description, la couche à laquelle ils appartiennent (bronze, silver, gold) et l'état de leur dernière matérialisation. Toute sortie censée se rafraîchir automatiquement doit figurer ici — une omission a coûté au projet deux semaines de dérive silencieuse entre ses deux univers.

3.6.3 MLflow — « d'où vient ce chiffre ? »

MLflow enregistre les *résultats* : pour chaque exécution, les paramètres employés, les métriques obtenues, le fichier source et le commit exact du code. C'est le registre qui permet, six semaines après, de répondre à la question « quel Sharpe publié, sur quelles données et avec quels réglages ? » sans relancer un calcul. Les valeurs de performance courantes ne sont jamais lues dans une capture d'écran : elles proviennent des artefacts Gold versionnés du chapitre 5.

Ce registre a lui-même révélé un défaut lors de la préparation de ce chapitre : la version de MLflow employée n'écrivait que les fichiers joints dans le mode de stockage configuré, et abandonnait silencieusement paramètres et métriques. L'interface affichait des exécutions vides. La configuration a été corrigée et centralisée dans une fonction unique appelée par les six programmes concernés — et la valeur de référence régénérée est identique au bit près à celle publiée, ce qui confirme que seul l'enregistrement était en cause, non les calculs.

3.7 Ce que l'exploitation a appris

Deux incidents méritent d'être rapportés, parce qu'ils ne relèvent ni de la finance ni du ML, et que ce sont eux qui ont façonné les garde-fous décrits plus haut.

Un serveur de code périmé. La tâche nocturne a échoué plusieurs jours de suite sans que personne ne le sache. Le processus qui sert le code aux exécutions planifiées avait démarré *avant* la création d'un nouveau module ; il ne pouvait pas l'importer, et rechargeait bien les définitions mais jamais l'état d'importation de son interpréteur. Conséquence : un univers se mettait à jour, l'autre non — exactement la dérive que la double base de test rend visible. La correction technique fut d'une ligne (importer le module au chargement plutôt qu'à l'exécution, pour que la panne survienne immédiatement et bruyamment). La vraie correction fut un test : *rien* dans la suite n'importait le paquet d'ordonnancement, si bien que des centaines de tests passaient sur un pipeline incapable de démarrer.

Un artefact déchiré. Une longue exécution de modélisation et l'ordonnanceur nocturne partageaient le même répertoire de données. Le second a reconstruit la couche Gold *pendant* que la première la lisait : le fichier de résultats produit décrivait un univers avec des données au 24 juillet et l'autre avec des données plus récentes. Aucune erreur, aucun avertissement — un fichier parfaitement bien formé et faux. Les données ont été restaurées depuis le cache de versionnement, l'ordonnanceur arrêté, l'exécution refaite avec une assertion préalable sur la date des données. La leçon générale : **une exécution longue et un ordonnanceur actif ne doivent jamais partager un répertoire de données**, et c'est ce cas précis que le test de cohérence entre documents détecte désormais.

3.8 La pile technique

TAB. 3.3 : Principaux outils et rôle de chacun.

Outil	Rôle dans le projet
Python, pandas, NumPy	Langage et calcul numérique.
Parquet, DuckDB	Stockage en colonnes des trois couches ; requêtes analytiques sur la couche Gold.
Pandera	Contrats de données appliqués à l'écriture (Silver et Gold).
scikit-learn, SciPy	Rétrécissement de covariance de Ledoit-Wolf ; optimisation sous contrainte.
hmmlearn, arch	Modèles de régime à états cachés ; modèles de volatilité.
xgboost	Modèles de prédiction de rendement (chapitre 4).
DVC	Versionnement des données et graphe de reproductibilité.
Dagster	Ordonnancement local et lignée des actifs.
MLflow	Journal des expériences : paramètres, métriques, code.
Streamlit, FastAPI	Tableau de bord à deux pages et interface REST.
pytest	Plus de 780 tests, hors ligne, exécutés à chaque modification.

Deux choix négatifs méritent d'être mentionnés, car ils ont été délibérés. Une bibliothèque spécialisée de validation croisée pour la finance a été *écartée* au profit d'une implémentation interne d'une cinquantaine de lignes, son modèle de licence étant devenu restrictif : une dépendance dont l'accès peut disparaître n'a pas sa place au cœur d'un dispositif d'évaluation. Et aucun ordonnanceur d'entreprise n'a été retenu : le projet s'exécute sur une machine unique, et l'outil choisi cartographie directement les couches du médaillon.

Synthèse du chapitre

- Les données transitent par trois couches à sens unique, chacune validée à l'écriture ; la modélisation ne lit que la dernière.

- L'univers BVC *canonique* commence en 2021. Un historique marocain profond a été testé séparément : il améliore la prédiction sans établir d'avantage de portefeuille, et reste hors release tant que ses sources et ses ajustements ne sont pas contractualisés. La **double base de test** publie les désaccords entre univers au lieu de les masquer.
- Le moteur de backtest, écrit une fois et jamais modifié, est une **frontière de confiance** : il découpe les données que les modèles reçoivent et valide les décisions qu'ils rendent. L'impossibilité de voir le futur est un test, pas une convention.
- Les règles qui comptent sont exécutables : hermétisme des tests, cohérence entre documents publiés, interdiction des chiffres écrits à la main, traçabilité P1–P4 (107 fonctions sur 110).
- DVC, Dagster et MLflow répondent à trois questions distinctes — *ce résultat est-il à jour, quand doit-il se recalculer, d'où vient ce chiffre*. Les trois incidents d'exploitation du projet ont chacun consisté en une réponse devenue fausse sans que rien ne le signale ; ils ont tous donné lieu à un garde-fou automatique.

Chapitre 4

Modélisation et protocole d'évaluation

Ce que ce chapitre explique

Le chapitre précédent a décrit la chaîne qui produit les données et le moteur qui exécute les stratégies. Celui-ci décrit *les stratégies elles-mêmes* — quatre familles de modèles, construites l'une après l'autre — puis le dispositif qui décide si elles valent quelque chose.

Ce chapitre ne contient volontairement **aucun résultat chiffré**. Le protocole d'évaluation doit pouvoir être lu, compris et contesté indépendamment des conclusions qu'il produit ; si les deux étaient présentés ensemble, un lecteur ne pourrait plus distinguer un protocole conçu pour être juste d'un protocole conçu pour donner raison. Les chiffres sont au chapitre 5.

Deux principes de méthode gouvernent tout ce qui suit.

Une seule chose change à la fois. Les modèles sont ajoutés par *échelons*, chacun ne modifiant qu'un ingrédient du précédent. Un gain devient alors attribuable : on sait *à quoi* il est dû. C'est le contraire de la démarche qui consiste à assembler d'emblée le système le plus sophistiqué possible et à constater qu'il fonctionne, sans pouvoir dire pourquoi.

Rien ne touche au moteur. Toutes les stratégies décrites ci-dessous respectent la même interface : elles reçoivent une fenêtre d'entraînement et retournent une répartition. Aucune n'a nécessité de modifier le moteur de backtest ni ses garanties. C'est ce qui rend leurs performances comparables : elles ont été mesurées par le même instrument, sans exception.

4.1 Les références classiques

Quatre stratégies non-ML servent de référence. Elles ne sont pas un échauffement : ce sont les concurrentes que le ML doit battre, et l'une d'elles est notoirement difficile à battre.

- **L'équipondération** — la même somme sur chaque actif. Aucun paramètre, aucune estimation, donc aucune erreur d'estimation possible. La littérature établit qu'elle bat, une fois les coûts déduits, la plupart des optimiseurs ; c'est la référence honnête par excellence.
- **La variance minimale** — la répartition qui minimise la volatilité du portefeuille, sans chercher à prévoir les rendements.
- **La variance minimale à covariance rétrécie** — la même, avec la correction d'estimation décrite plus bas.

- **Le Markowitz classique** (Sharpe maximal) — la formulation de 1952 : on maximise le rendement attendu par unité de risque, en estimant les rendements attendus par leur moyenne historique.

Toutes s'exécutent sous les contraintes réelles décrites au chapitre 3 — pas de vente à découvert, plafond de 25 % par actif, coûts de transaction déduits — et sur les deux univers.

4.2 Premier échelon : mieux estimer le risque (P1)

Le problème P1 est celui de l'*erreur d'estimation*. La matrice de covariance — qui décrit comment les actifs bougent ensemble — doit être estimée à partir d'un échantillon fini. Avec neuf actifs, elle comporte 45 quantités distinctes à estimer ; chacune est bruitée, et l'optimiseur, qui cherche l'extremum, se précipite précisément sur les combinaisons où le bruit lui est favorable. Il produit alors un portefeuille concentré, magnifique sur le passé et fragile sur l'avenir.

Quatre échelons ont été construits, du plus simple au plus élaboré.

1. **Covariance empirique** — la moyenne des co-mouvements observés. Le point de départ, et le plus exposé au bruit.
2. **Rétrécissement de Ledoit-Wolf** — on mélange la matrice observée avec une matrice « naïve » très structurée, dans une proportion calculée automatiquement. On accepte un biais volontaire contre une forte réduction de variance. C'est le compromis classique de la statistique : une estimation légèrement fausse mais stable bat une estimation juste en moyenne mais instable.
3. **Covariance à mémoire exponentielle** — les observations récentes pèsent davantage que les anciennes, avec une décroissance géométrique. C'est la première réponse au problème P2 : si le marché change de régime, l'année dernière est plus informative que la précédente.
4. **DCC-GARCH** — le modèle le plus élaboré de la chaîne. Il estime d'abord, actif par actif, un modèle de volatilité variable dans le temps (les fortes secousses en appellent d'autres, phénomène bien documenté), puis fait évoluer les *corrélations* elles-mêmes selon leur propre dynamique.

Le quatrième échelon a demandé un travail d'implémentation réel : la bibliothèque employée fournit uniquement des modèles de volatilité univariés. La réursion multivariée d'Engle (2002) et l'estimation de ses deux paramètres par maximum de vraisemblance ont donc été écrites à la main. Une sécurité l'accompagne : si l'estimation ne converge pas pour un actif, la stratégie retombe sur le rétrécissement de Ledoit-Wolf en journalisant un avertissement. Ce chemin est testé et instrumenté ; son taux d'activation sur l'instantané de release est rapporté avec les résultats au chapitre 5, plutôt que déduit d'une observation historique.

4.3 Deuxième échelon : reconnaître le régime de marché (P2, P3)

Définition — Modèle de Markov caché

Modèle statistique supposant que les observations (ici : rendement du marché, volatilité récente, corrélation moyenne entre actifs) sont engendrées par un *état* non observable qui change au cours du temps. On ne voit jamais l'état directement ; on l'infère à partir de ce qu'il produit. Le modèle est *non supervisé* : on ne lui fournit aucune liste de crises, il découvre lui-même que deux régimes de comportement coexistent.

Le détecteur est entraîné sur trois variables seulement — le rendement du marché, sa volatilité récente et la corrélation moyenne entre actifs. Ce choix est directement dicté par les problèmes : la volatilité est la signature de P2, la corrélation moyenne est la mesure même de P3. À chaque décision, le modèle est réentraîné sur la seule fenêtre disponible et produit une probabilité de régime (figure 4.1).




FIG. 4.1 : Sortie du détecteur sur l'univers ETF : un régime par décision de rééquilibrage, estimé sans aucune connaissance de la suite. Les bandes verticales marquent cinq crises dont les dates proviennent d'une source externe et ont été fixées *avant* toute mesure. La question de savoir si les amas rouges sont associés à ces bandes est traitée comme une analyse exploratoire au chapitre 5.

Quatre décisions de conception méritent d'être justifiées, car elles ont toutes été prises contre l'option en apparence plus ambitieuse.

Deux états, pas trois. Un troisième état « crise » était tentant. Il a été écarté parce que l'univers principal ne compte qu'environ 1 300 journées : un troisième état aurait été estimé sur une poignée d'observations, et sa définition aurait dépendu de la graine aléatoire plus que des données.

Un basculement franc, pas un mélange. Une fois le régime identifié, la décision est entièrement confiée à une stratégie classique déjà testée : le Markowitz classique en régime haussier, la variance minimale rétrécie en régime baissier. Aucun code d'optimisation nouveau n'a été écrit. L'inconvénient est assumé et documenté : un basculement franc provoque un pic de transactions à la frontière entre deux régimes, et c'est effectivement la stratégie la plus coûteuse en rotation du projet.

En cas de doute, la posture défensive. Si la fenêtre est trop courte ou si l'estimation ne

converge pas, la probabilité neutre de 50/50 est résolue vers la stratégie *défensive*, non vers un tirage arbitraire. Un système d'allocation qui ne sait pas où il est ne doit pas parier à la hausse.

Les étiquettes sont recalculées à chaque réestimation. La bibliothèque employée ne garantit pas que l'état numéro 0 désigne le même régime d'une estimation à l'autre. Les états sont donc réordonnés à chaque fois d'après le rendement moyen ajusté, et « baissier » est *défini* comme l'état de rendement moyen le plus faible. Cette définition a une conséquence importante, rappelée au chapitre 5 : une partie de l'association entre régime baissier et crise est définitionnelle, et seul le caractère *temps réel* de la détection est un résultat.

4.4 Troisième échelon : prédire les rendements

Les échelons précédents ne prédisent jamais un rendement : ils estiment un risque et un régime. L'échelon suivant franchit ce pas — c'est la fonction que le référentiel fonctionnel d'EURAFRIC désigne comme « modèles ML adaptatifs ».

Deux familles ont été retenues, toutes deux fondées sur des ensembles d'arbres de décision : forêts aléatoires et gradient boosting. Aucun réseau de neurones n'a été conservé — un modèle récurrent avait été développé et testé isolément, puis retiré de la comparaison après un conflit reproductible entre deux bibliothèques natives chargées dans le même processus. Il a paru préférable de retirer un composant instable que de publier une comparaison qui n'aurait pas pu être rejouée.

Trois choix structurent cette partie.

Un modèle unique, entraîné sur tous les actifs à la fois. Plutôt que neuf modèles indépendants, un seul apprend sur un tableau où chaque ligne est un couple (date, actif) et où l'identité de l'actif est une variable comme une autre. L'intérêt est arithmétique : le nombre de lignes d'entraînement est multiplié par le nombre d'actifs. Sur un univers de 1 300 journées, c'est la différence entre un problème d'apprentissage difficile et un problème impossible.

Le régime est une variable d'entrée, pas un aiguillage. La probabilité de régime issue du détecteur est fournie au modèle comme une colonne supplémentaire. L'alternative — deux modèles distincts, un par régime — fragmenterait un jeu de données déjà mince pour un problème d'apprentissage plus difficile que celui du détecteur.

La prédiction remplace un seul ingrédient. Le rendement prédit se substitue à la moyenne historique dans l'objectif de Markowitz, déjà écrit et déjà testé. La covariance reste inchangée. Le principe « une seule chose change à la fois » est ainsi préservé jusqu'au bout : tout écart de performance s'attribue à la qualité de la prédiction, à rien d'autre.

C'est ici que le risque de fuite est le plus grand, car la variable à prédire est construite à partir de la même matrice de rendements que les variables explicatives. La date de décision est donc exclue de l'entraînement structurellement, par comparaison de dates — et non par filtrage des valeurs manquantes, qu'un appel maladroit pourrait contourner. Un test dédié corrompt le futur et vérifie qu'aucune décision passée ne change, en s'assurant au passage que le modèle utilise réellement ces variables : sans cette seconde vérification, la garantie serait vide.

4.5 Quatrième échelon : payer le prix des transactions

L'échelon précédent a produit un diagnostic précis, exposé au chapitre 5 : le signal était informatif *avant* coûts et ne l'était plus après. Autrement dit, un échec de *construction* de portefeuille

et non de *prédiction*. Trois leviers ont été ajoutés en réponse.

Une pénalité de rotation. L'objectif d'optimisation intègre un terme proportionnel à l'ampleur des transactions envisagées : la stratégie ne modifie une position que si le gain attendu dépasse le coût du mouvement. Un détail technique mérite mention, car il illustre le soin requis : la valeur absolue n'est pas dérivable exactement là où se situe l'optimum d'un problème pénalisé — c'est-à-dire « ne rien échanger » — et l'algorithme employé est fondé sur le gradient. Une approximation lisse de la valeur absolue est donc utilisée.

Un rétrécissement des rendements prédits vers la moyenne historique, et une variante n'en conservant que le *classement*. La justification est un résultat classique : une erreur sur les rendements attendus dégrade un optimiseur moyenne-variance environ dix fois plus qu'une erreur équivalente sur la covariance. Réduire l'amplitude d'une prédiction bruitée tout en conservant sa direction est donc souvent préférable à s'y fier pleinement.

Le choix de l'estimateur de covariance devient un paramètre des stratégies à signal, ce qui permet d'associer « meilleure prédiction » et « meilleure covariance » par configuration plutôt que par écriture de code.

Tous ces leviers sont **désactivés par défaut**. La raison est de reproductibilité : l'échelon précédent, avec son résultat négatif, reste exécutable à l'identique et sert de plancher honnête. On n'améliore pas un résultat en le rendant irretrouvable.

4.6 Le protocole d'évaluation (P4)

Tout ce qui précède serait sans valeur si la mesure était complaisante. Le problème P4 — le surapprentissage du backtest — est le seul des quatre qui ne puisse pas être résolu par un meilleur modèle, puisqu'il porte sur la mesure elle-même. Quatre dispositifs y répondent.

4.6.1 Rejouer le temps

Toute performance rapportée provient d'une simulation à fenêtre glissante (figure 4.2) : à chaque fin de mois, le modèle est réentraîné sur les seules données antérieures, décide, puis subit le mois suivant. Aucune performance n'est jamais mesurée sur des données ayant servi à décider.

4.6.2 Choisir les hyperparamètres sans tricher

Reste une fuite plus subtile : le choix des réglages. Essayer trente configurations et publier la meilleure revient à publier un maximum de bruit.

Définition — Purge, embargo, et sélection strictement antérieure

En apprentissage classique, on découpe les données en blocs et on teste sur chacun à tour de rôle. Sur des séries temporelles financières, c'est fautif : les observations voisines se ressemblent, et la variable à prédire d'une journée recouvre les journées suivantes. Le bloc de test « touche » donc son propre entraînement. La *purge* retire les observations d'entraînement dont l'horizon chevauche le bloc de validation ; l'*embargo* écarte en outre une bande de journées juste après ce bloc.

Ces deux mécanismes ne suffisent pas. La validation croisée purgée classique entraîne le modèle sur *toutes* les dates hors de la bande — y compris **postérieures** à la validation. La *sélection strictement antérieure* ajoute la contrainte manquante : l'entraînement précède toujours la validation, et chaque pli vérifie $\text{fin_entraînement} < \text{début_embargo} \leq$




FIG. 4.2 : Principe du backtest à fenêtre glissante. La fenêtre d'entraînement s'élargit à chaque pas ; la performance est toujours encaissée *après* la décision. Le découpage est effectué par le moteur, jamais par la stratégie.

début_validation.

Cette validation croisée a été implémentée dans le projet plutôt qu'importée : la bibliothèque spécialisée de référence a adopté un modèle de licence restrictif, et une cinquantaine de lignes suffisaient. Un test de fuite dédié doit être vert avant que quoi que ce soit ne l'utilise.

4.6.3 Deux objectifs, deux instruments

Une distinction, discrète mais décisive, structure la sélection.

Définition — Coefficient d'information

Corrélation de rang entre les rendements prédits et les rendements réalisés. Il mesure si le modèle classe correctement les actifs — ce qui est exactement ce qu'un signal doit faire — sans exiger que ses prédictions soient justes en niveau. En prévision financière, un coefficient de quelques centièmes est déjà considéré comme exploitable ; c'est un domaine où le signal est tenu par nature.

Les *hyperparamètres des modèles* sont donc choisis par **validation strictement antérieure** (folds *forward-only* : l'entraînement précède toujours la validation, séparé d'une purge et d'un embargo), au coefficient d'information — rapporté *par pli* et non seulement en moyenne, une moyenne identique pouvant recouvrir cinq plis stables ou un seul pli dominant. Les *leviers de portefeuille* (rétrécissement, pénalité de rotation) sont choisis autrement : sur un segment de validation distinct, au ratio de Sharpe net, à travers le moteur réel — car ce sont des paramètres de construction, pas de prédiction, et les juger au coefficient d'information serait une erreur de catégorie.

- ① Le segment de test est mis de côté avant toute calibration



- ② Validation croisée standard : les blocs se touchent — fuite

la veille du test sert
à l'entraîner



- ③ Validation croisée purgée et sous embargo : les blocs sont séparés




FIG. 4.3 : Le protocole de sélection. Le segment de test final est mis de côté avant toute calibration ; la sélection s'opère sur le reste, avec des blocs séparés par une purge et un embargo. Le découpage est effectué *par date*, non *par ligne*, car le tableau d'apprentissage comporte plusieurs actifs à chaque date.

4.6.4 Un verdict rendu une seule fois, avec sa marge d'erreur

Les derniers 35 % de chaque univers sont mis de côté avant toute calibration et ne sont utilisés qu'une fois, les réglages figés. À ce verdict s'ajoutent deux précautions.

Définition — Intervalle de confiance par bootstrap à blocs

Pour estimer de combien une performance mesurée pourrait varier par simple hasard, on reconstitue des milliers d'historiques fictifs en retirant au sort des *blocs* de journées consécutives — ici des blocs d'un mois environ, afin de préserver la structure temporelle des rendements, qu'un tirage journée par journée détruirait. La dispersion des performances obtenues donne l'intervalle.

Définition — Ratio de Sharpe déflaté

Probabilité qu'une performance mesurée soit réellement positive une fois corrigée du nombre de stratégies essayées et de la non-normalité des rendements. Essayer 200 configurations et retenir la meilleure produit une bonne performance même si aucune ne vaut rien ; cette mesure quantifie cet effet.

Le nombre de configurations essayées n'est pas déclaré à la main : un registre enregistre chaque configuration évaluée pendant la recherche, et c'est ce décompte qui alimente la correction. C'est une manière de rendre coûteuse — et visible — la tentation d'essayer une piste de plus.

4.7 La discipline expérimentale

Trois règles de conduite complètent le dispositif technique. Elles ne relèvent pas de l'outillage mais de l'honnêteté, et ce sont elles qui rendent le chapitre 5 défendable.

Choisi n'est pas calibré. Lorsqu'une valeur a été fixée par jugement et non par une procédure de sélection, le rapport le dit. Ajuster ces valeurs en regardant le résultat final serait exactement le surapprentissage que tout le chapitre cherche à empêcher.

Les issues sont écrites avant l'expérience. Les études exploratoires du projet énoncent, dans le script lui-même et avant exécution, les conclusions associées à chaque issue possible — « si tel écart dépasse tel seuil, alors l'hypothèse est retenue ; sinon elle est rejetée ». Plusieurs comportent en outre un *contrôle inversé* : une variante délibérément construite à contresens, qui doit faire moins bien. Si elle fait aussi bien, ce n'est pas l'hypothèse qui est validée, c'est l'expérience qui est sans pouvoir.

Un seuil ne se durcit qu'avant de voir le résultat. Un exemple concret mérite d'être rapporté, car il est plus parlant qu'un principe. Une expérience comparait deux configurations avec un simple « meilleur que » ; un essai préliminaire a rendu un écart de +0,0016, que cette règle aurait qualifié de victoire. Un seuil de matérialité a donc été ajouté *avant* l'exécution réelle ; il rend le test plus sévère, et le changement est consigné dans le script comme dans le document d'analyse plutôt que fondu silencieusement dans la méthode.

Synthèse du chapitre

- Quatre échelons ont été construits, chacun ne modifiant qu'un ingrédient du précédent : meilleure estimation du risque (P1), reconnaissance du régime de marché (P2, P3), prédiction des rendements, puis prise en compte du coût des transactions. Un gain est ainsi attribuable.
- Aucun échelon n'a modifié le moteur de backtest : toutes les stratégies ont été mesurées par le même instrument, sous les mêmes contraintes de gestion, sur les deux univers.
- Les choix ont systématiquement été faits contre l'option la plus ambitieuse lorsque les données ne la soutenaient pas : deux régimes et non trois, un basculement franc vers des optimiseurs déjà testés, un modèle unique entraîné sur tous les actifs, une posture défensive en cas de doute.
- L'évaluation traite le problème P4 comme un problème à part entière : rejeu du temps, sélection des réglages **strictement antérieure** (purge et embargo à la frontière, l'entraînement précédant toujours la validation), segment de test gelé, **comparaisons paires** par bootstrap à blocs — le test de la *différence*, que des intervalles marginaux ne fournissent pas — et correction pour le nombre de configurations essayées, compté automatiquement et non déclaré.
- Les issues des expériences sont écrites avant leur exécution, plusieurs comportent un contrôle délibérément inversé, et tout durcissement de critère est consigné. Ces règles n'ajoutent aucune performance : elles rendent les conclusions du chapitre suivant opposables.

Chapitre 5

Résultats, validation et produit livré

Comment lire ce chapitre

Ce chapitre présente ce que le système produit réellement. Il est organisé selon un principe simple, hérité du problème P4 exposé au chapitre 2 : **un chiffre n'est un résultat que si l'on sait de combien il pourrait être faux.**

Chaque résultat est donc qualifié selon son niveau de preuve. Le chapitre distingue explicitement quatre catégories :

- ce qu'il **observe** — des écarts historiques, sans les transformer en supériorité généralisable faute de test pairé ;
- ce qu'il **explore** — des associations sur un faible nombre d'événements, utiles pour orienter l'analyse mais non confirmatoires ;
- ce qu'il **teste sans l'établir** — une comparaison pairée ou une correction de recherche qui ne conclut pas à la surperformance ;
- ce qu'il **réfute** — cinq pistes explorées et fermées.

Cette troisième catégorie n'est pas un aveu d'échec. Sur un sujet où la littérature abonde en performances irreproductibles, une piste correctement fermée a plus de valeur qu'une performance invérifiable.

5.1 Le résultat principal

Le système complet — détection de régime par chaîne de Markov cachée et covariance dynamique — a été comparé aux trois approches classiques sur les deux univers, hors échantillon et net de coûts de transaction.

Sur le portefeuille EURAFRIC — libellé en dirhams aux taux de référence officiels de Bank Al-Maghrib et non couvert contre le risque de change — la stratégie à régimes obtient un ratio de Sharpe net de **0,9571** contre **1,0690** pour la meilleure approche classique, soit un écart ponctuel de $-10,47\%$. Sur l'univers ETF, mono-devise en dollars et inchangé par la correction, elle obtient 0,937 contre 0,953 : un écart de $-1,6\%$. Ces écarts ne démontrent pas une supériorité de l'approche classique : aucun test pairé de cette différence n'est présenté.

TAB. 5.1 : Performance nette de coûts, hors échantillon. *DD* désigne le drawdown maximal (la pire perte pic-à-creux), et le ratio de Calmar rapporte le rendement à ce drawdown.

Univers	Stratégie	Sharpe	Rendement	DD max.	Calmar
Portefeuille EURAFRIC (9 actifs)	Système ML (régime)	0,957	9,4 %	−14,6 %	0,641
	Markowitz Sharpe max.	1,069	12,0 %	−11,3 %	1,060
	Équipondéré (1/N)	0,953	9,5 %	−12,4 %	0,762
	Variance min. (Ledoit-Wolf)	0,878	8,3 %	−12,6 %	0,655
ETF inter-nationaux (5 actifs)	Variance min. (Ledoit-Wolf)	0,953	10,3 %	−26,9 %	0,382
	Système ML (régime)	0,937	10,4 %	−26,9 %	0,386
	Markowitz Sharpe max.	0,912	10,8 %	−32,8 %	0,329
	Équipondéré (1/N)	0,769	9,6 %	−36,2 %	0,266




FIG. 5.1 : Évolution des portefeuilles, nette de coûts et hors échantillon (échelle logarithmique). Le système ML est tracé en trait épais. L'écart entre stratégies est faible au regard de l'amplitude des mouvements de marché — ce que la section suivante quantifie.

Le résultat est donc mitigé, et il est rapporté comme tel. Un système qui n'apporterait un gain que sur l'univers où on a choisi de le mettre en avant ne serait pas un système, mais une sélection.

5.1.1 Une réserve sur le choix de la mesure

Le tableau 5.1 appelle une observation que l'honnêteté impose de formuler, car elle nuance le résultat principal.

Sur le portefeuille EURAFRIC, le système ML est derrière le Markowitz classique sur les cinq mesures publiées : Sharpe net (0,957 contre 1,069), rendement annualisé (9,4 % contre 12,0 %), drawdown maximal (−14,6 % contre −11,3 %), ratio de Calmar (0,641 contre 1,060) et turnover (0,32 contre 0,14, soit plus de deux fois plus de transactions).

Autrement dit : **l'écart observé défavorable au système à régimes ne repose pas sur une seule métrique**. Il demeure néanmoins descriptif : aucun test pairé de cette comparaison de pleine période n'autorise à conclure à une supériorité de l'approche classique. Le classement dépend aussi du protocole et de la fenêtre hors échantillon, comme le montre la suite du chapitre.

Cette dépendance du classement au choix de la mesure est un résultat en soi. Elle justifie que les sections suivantes ne s'appuient pas uniquement sur le ratio de Sharpe.

5.2 Ce chiffre est-il réel ? La validation hors échantillon

Un écart ponctuel mesuré sur une période unique — ici −10,47 % — ne dit rien tant qu'on ignore sa marge d'erreur. Deux protocoles ont été appliqués pour l'établir.

Le test gelé. Les derniers 35 % de chaque univers ont été mis de côté avant toute calibration. Les hyperparamètres des modèles ont été choisis sur la partie restante par **validation strictement antérieure** (*forward-only*), puis *figés* ; le verdict n'a été mesuré qu'une fois, sur ce segment jamais vu.

Le mot « strictement » est le correctif apporté à ce protocole. La version précédente employait une validation croisée purgée en blocs, qui entraîne le modèle sur *toutes* les dates hors de la bande de purge — y compris **postérieures** au bloc de validation. C'est la construction canonique de López de Prado, défendable lorsque les labels se chevauchent, mais elle note un pli de 2018 avec un modèle ajusté en partie sur 2019–2024 : une question qu'aucun gérant ne peut poser en direct. Chaque pli respecte désormais

$$\text{fin_entraînement} < \text{début_embargo} \leq \text{début_validation} \leq \text{fin_validation} < \text{début_test}$$

et la géométrie réellement appliquée — dates, effectifs, IC par pli — est publiée dans `phase5_validation_protocol.json` plutôt qu'affirmée ici.

Le walk-forward imbriqué. La fenêtre de test unique du protocole précédent ne représente que 455 jours sur le portefeuille EURAFRIC, ce qui produit des intervalles très larges. Un second protocole re-sélectionne la configuration à six frontières successives et concatène chaque segment hors échantillon, portant l'évaluation à **793 jours** — sans que la sélection ne voie jamais sa propre fenêtre d'évaluation.




FIG. 5.2 : Ratios de Sharpe hors échantillon et intervalles de confiance à 90 % (bootstrap par blocs), pour les deux protocoles. Le protocole imbriqué (bleu) resserre les intervalles de **28,6 %** en moyenne. Les intervalles marginaux restent néanmoins largement chevauchants : ils quantifient l'incertitude, sans constituer un test païré de différence entre stratégies.

Le test païré — la preuve qui manquait. Les intervalles ci-dessus sont *marginaux* : ils décrivent l'incertitude de *chaque* stratégie prise isolément. Ils ne testent pas si deux stratégies diffèrent, et les lire ainsi est une erreur dans les deux sens — deux intervalles peuvent se chevaucher largement alors que la différence païrée est systématiquement positive (les stratégies partagent les mêmes journées de marché et leurs erreurs sont corrélées), et un non-chevauchement n'établirait pas davantage une différence.

Ce rapport dispose désormais de l'instrument manquant : un **bootstrap par blocs païré** sur les mêmes dates de la fenêtre gelée, net de coûts. Les deux séries sont rééchantillonnées avec les *mêmes* indices de blocs, ce qui préserve à la fois la dépendance sérielle de chaque stratégie et la corrélation intra-journalière entre elles. La p-value est *centrée sous l'hypothèse nulle* — les différences rééchantillonnées sont recentrées sur zéro, puis on mesure la part de cette distribution au-delà de l'écart observé. Ce n'est pas la fraction brute de tirages positifs, rapportée séparément et jamais présentée comme une p-value.

TAB. 5.2 : Comparaisons païrées sur la fenêtre de test gelée, nettes de coûts (bootstrap par blocs, 2 000 rééchantillons). *Aucune* des huit comparaisons n'établit de surperformance.

Univers	Comparaison	Δ Sharpe	IC 90 %	p
etf_2017	RF vs régimes	+0,009	[−0,025; +0,041]	0,326
	RF vs 1/N	+0,120	[−0,013; +0,247]	0,066
	XGB vs régimes	−0,149	[−0,308; +0,010]	0,939
	XGB vs 1/N	−0,038	[−0,177; +0,096]	0,671
full_2021	RF vs régimes	−0,128	[−0,486; +0,239]	0,715
	RF vs 1/N	−0,005	[−0,424; +0,389]	0,513
	XGB vs régimes	−0,168	[−0,577; +0,264]	0,740
	XGB vs 1/N	−0,046	[−0,445; +0,329]	0,587

Le verdict honnête

Aucune preuve de surperformance. Sur les huit comparaisons paires, tous les intervalles contiennent zéro et toutes les p-values dépassent 0,05 ; la plus proche du seuil est RF contre l'équipondéré sur `etf_2017` ($p = 0,066$).

Un cas mérite d'être isolé, car il est exactement ce que ce test sert à révéler. Sur `etf_2017`, le signal RF calibré obtient 1,102 contre 1,093 pour la stratégie à régimes : en *estimation ponctuelle*, il « bat » la référence, et l'artefact l'enregistre comme tel. Le test pairé donne pourtant $\Delta = +0,009$, IC $[-0,025; +0,041]$, $p = 0,326$. Le classement ponctuel n'est pas soutenu par les données.

Ce n'est pas non plus une démonstration d'équivalence : ne pas rejeter n'est pas accepter l'hypothèse nulle. L'établir demanderait un test d'équivalence contre une marge fixée à l'avance, qui n'a pas été mené.

5.2.1 Corriger pour l'ampleur de la recherche

TAB. 5.3 : Reality Check de White et SPA de Hansen sur l'ensemble des candidats explorés. L'hypothèse nulle est composite : *aucun* candidat ne surperforme la référence.

Univers	Référence	Statistique	RC p	SPA p
<code>etf_2017</code>	<code>regime_conditional</code>	mean return	0,2259	0,3588
<code>etf_2017</code>	<code>regime_conditional</code>	Sharpe	0,8811	0,6357
<code>etf_2017</code>	<code>equal_weight</code>	mean return	0,0630	0,0020
<code>etf_2017</code>	<code>equal_weight</code>	Sharpe	0,2714	0,0980
<code>full_2021</code>	<code>regime_conditional</code>	mean return	0,1239	0,0855
<code>full_2021</code>	<code>regime_conditional</code>	Sharpe	0,3253	0,3778
<code>full_2021</code>	<code>equal_weight</code>	mean return	0,0915	0,0280
<code>full_2021</code>	<code>equal_weight</code>	Sharpe	0,1699	0,0510

Les huit comparaisons paires ci-dessus testent chacune *un* candidat contre une référence. Mais ce candidat a été *choisi dans une recherche*, et le meilleur de plusieurs candidats bat une référence par chance plus souvent qu'un candidat unique. Tant que cette sélection n'est pas tarifée, « le modèle retenu a battu la haie » n'est pas l'affirmation qu'il paraît être.

L'ensemble corrigé est l'espace ATTEIGNABLE. La recherche était hiérarchique — hyperparamètres choisis par coefficient d'information, puis leviers de portefeuille conditionnellement à ces hyperparamètres. Le registre d'essais en avait enregistré 51, mais l'espace que la recherche pouvait sélectionner compte 240 configurations : 15 jeux d'hyperparamètres $\times$ 16 combinaisons de leviers. Corriger pour 51 quand 240 étaient atteignables sous-estimerait la multiplicité, donc c'est le nombre le plus grand qui est retenu. Chacune de ces 240 configurations a été réévaluée sur les dates de test gelées et sa série de rendement conservée.

Le verdict corrigé

Aucun des 240 candidats ne bat la stratégie à régimes une fois la recherche prise en compte, sur aucun des deux univers.

La référence primaire est pré-spécifiée : `regime_conditional` est la haie que la couche ML devait franchir et celle que toutes les phases antérieures rapportaient. Face à elle, ni le Reality Check ni le SPA n'établissent de surperformance, sur aucun univers ni aucune statistique.

L'illustration la plus parlante tient en deux nombres. En retenant le meilleur des 240 candidats *jugé sur la fenêtre de test elle-même*, on obtient un Sharpe de 1,87 sur `full_2021` — contre 1,31 pour celui que la sélection honnête avait désigné. Cet écart ne mesure pas une performance : il mesure ce que la sélection sur l'échantillon de test *fabrique*, et c'est exactement ce que la correction sert à tarifier.

Les comparaisons face à `equal_weight` sont **exploratoires par pré-spécification** et n'étaient aucune réussite du ML : la stratégie à régimes, et depuis la correction des dividendes le `max_sharpe` classique, franchissent déjà ce plancher.

Trois réserves qui accompagnent ce tableau. Le RC et le SPA sont rapportés *côte à côte* et aucun ne doit être cité seul : le SPA est plus puissant par construction — il studentise chaque candidat et écarte les candidats sans espoir du recentrage — donc il donnera d'ordinaire la plus petite p -value. Ici il conserve 227 à 240 candidats sur 240, ce qui montre que sa règle d'exclusion ne joue quasiment pas : l'écart entre les deux tests vient de la studentisation, gain de puissance documenté de Hansen sur la conservativité de White, et non d'un désaccord sur le résultat. Enfin, huit comparaisons externes ont été menées ($2 \text{ univers} \times 2 \text{ références} \times 2 \text{ statistiques}$) et ne sont pas elles-mêmes corrigées : citer la plus petite des huit serait de la multiplicité un niveau au-dessus de celle que ce tableau corrige.

Trois éléments confirment ce diagnostic plutôt qu'ils ne l'affaiblissent.

D'abord, le protocole imbriqué apporte un gain de précision réel : la largeur moyenne des intervalles tombe de 2,08 à 1,53, soit $-26,3 \%$, mieux que les $23,7 \%$ qu'un simple effet de taille d'échantillon laisserait attendre. Le ratio de Sharpe déflaté du meilleur candidat vaut 0,7370 sur 198 configurations testées. Aucun seuil n'ayant été pré-spécifié pour cette statistique, elle est rapportée telle quelle, sans qualificatif.

Ensuite, toutes les bornes inférieures marginales deviennent positives (de 0,33 à 0,61) dans ce protocole. C'est une description de chaque stratégie prise isolément ; elle ne démontre ni une rentabilité future ni un avantage relatif.

Enfin — et c'est l'observation la plus instructive — **le classement est sensible au protocole d'évaluation et à la fenêtre hors échantillon associée**. Sur la fenêtre walk-forward complète, la meilleure approche classique devance la stratégie à régimes ; le protocole imbriqué, dont la fenêtre hors échantillon (2023-07-28 → 2026-07-24, 781 lignes) diffère de celle du découpage unique, la place devant. Les deux facteurs sont ici confondus : on ne peut attribuer le changement de signe au seul choix de protocole, puisque la période évaluée change en même temps. Un classement qui s'inverse ainsi, sans test païré établissant une différence, ne doit pas être promu en verdict.

5.3 Comportement en crise : une lecture métier descriptive (P3)

Les mesures précédentes portent sur des moyennes de période. Or pour un allocataire, la question décisive est différente : que se passe-t-il quand les marchés s'effondrent ? C'est le problème P3, et il n'avait jusque-là été étayé qu'indirectement.

Cinq crises ont donc été analysées, délimitées par les **dates de sommet-à-creux publiées de l'indice S&P 500** et fixées *avant* tout examen des résultats. Ce point de méthode est essentiel : déduire les fenêtres de nos propres pertes reviendrait à sélectionner les périodes où le système paraît bon.

Sur les cinq crises, **sans exception**, l'optimisation sous contrainte perd moins, chute moins profondément et récupère plus vite que la diversification naïve :




FIG. 5.3 : Comportement pendant les cinq crises retenues, sur l'univers ETF. À gauche, la performance cumulée sur la fenêtre ; à droite, le nombre de jours nécessaires pour retrouver le sommet précédent.

- lors de la crise financière de 2008, elle épargne **9,0 points** de performance et **9,3 points** de drawdown ;
- pendant la crise de la dette européenne, elle termine **positive** (+1,6 %) là où l'équipondéré perd 5,4 % ;
- le **délai de récupération** est l'écart le plus régulier — 37 jours contre 71 après le krach COVID, 53 contre 105 après le repli de 2018, soit environ **deux fois moins de temps** sous l'eau.

Le délai de récupération n'apparaît dans aucune des mesures classiques du chapitre, alors qu'il est probablement le plus parlant pour un décideur : combien de temps le capital reste-t-il en dessous de sa valeur d'avant-crise ?

Attribution — ce que ce résultat ne dit pas. Ce gain revient à la **contrainte de portefeuille et au modèle de covariance** (P1 et P3), et non spécifiquement à la couche de régime. Sur trois des cinq fenêtres, les trois optimiseurs produisent des résultats identiques à la décimale près, pour deux raisons mécaniques : en régime baissier, le système à régime *devient* la variance minimale par construction ; et le plafond de 25 % sur cinq actifs contraint fortement l'allocation. L'attribuer au *Machine Learning* serait inexact.

5.4 La détection de régime : une analyse exploratoire (P2)

Le détecteur de régime est un modèle **non supervisé** : aucune date de crise, aucun label de récession ne lui a jamais été fourni. Il observe uniquement le rendement du marché, sa volatilité et la corrélation moyenne entre actifs, et classe chaque date de rééquilibrage en régime haussier ou baissier — *en temps réel*, à partir des seules données passées, sans savoir qu'une crise commence.




FIG. 5.4 : Proportion de rééquilibrages classés « baissier » pendant chacune des cinq crises, comparée au taux observé hors crise. Le modèle n'a reçu aucune information sur ces événements.

Le résultat est net : **91,7 %** des rééquilibrages situés dans une fenêtre de crise sont classés « baissier », contre **29,2 %** en dehors — un rapport de **3,13**, et les cinq crises dépassent le taux de base.

TAB. 5.4 : Deux diagnostics encadrent le problème de dépendance sérielle. Ils sont rapportés pour transparence, non comme une confirmation statistique généralisable sur cinq événements.

Diagnostic	Résultat	Lecture
Test des signes (<i>exploratoire</i>)	$p = 0,031$	Chaque crise compte pour une observation ($n = 5$). Ce calcul évite la dépendance sérielle interne, mais cinq observations ne permettent pas une conclusion confirmatoire.
Fisher exact (<i>libéral</i>)	$p = 7,8 \times 10^{-13}$	Traite 248 rééquilibrages mensuels corrélés comme indépendants : optimiste. À ne jamais citer seul.

Association exploratoire, non preuve de détection

Le détecteur est plus souvent dans l'état étiqueté « baissier » pendant les cinq fenêtres étudiées. Le test des signes donne $p = 0,031$, mais cet indicateur reste exploratoire : l'échantillon contient cinq événements et « baissier » est défini par le rendement moyen faible de l'état. Il ne doit pas être présenté comme un résultat confirmatoire, ni comme une preuve de valeur économique.

La réserve qui doit accompagner ce résultat. Le régime « baissier » est *défini* comme l'état de plus faible rendement moyen, et une crise est par nature une période de faible rendement : une part de l'association est donc définitionnelle. Ce qui ne l'est pas, c'est que la détection soit **causale et en temps réel**, et qu'elle ne se déclenche pas en permanence — le taux hors crise reste à 29 %, non à 80 %. Le modèle ne crie pas au loup.

*Deux affirmations distinctes, à ne jamais confondre : le détecteur produit une lecture causale de l'état de marché, associée aux cinq fenêtres étudiées ; le fait d'**agir** sur cette lecture n'a pas établi d'avantage économique robuste face aux approches classiques.*

5.5 La contrainte fait plus que les modèles (P1)

Le plafond de 25 % par actif avait été retenu comme une contrainte de gestion réaliste, non comme un outil de modélisation. En le faisant varier seul, tout le reste étant fixé, on obtient le résultat le plus inattendu du projet.




FIG. 5.5 : Meilleur ratio de Sharpe classique en fonction du plafond par actif, sur 248 rééquilibrages et 20,7 ans. Le nombre d'allocations distinctes émises est indiqué sous chaque point.

Relâcher le plafond de 25 % jusqu'à l'absence de contrainte fait chuter le meilleur Sharpe classique de **0,9525 à 0,8650**, soit une perte de **10,1 %**, de façon monotone. C'est davantage que l'écart entre deux modèles quelconques sur cet univers : le rétrécissement de Ledoit-Wolf, l'EWMA, le DCC-GARCH et la commutation de régime réunis déplacent moins le résultat.

Il s'agit du résultat de **Jagannathan et Ma (2003)** reproduit sur nos données : une contrainte de poids active équivaut mathématiquement à un rétrécissement de la matrice de covariance. **La contrainte réalisait donc déjà le contrôle d'erreur d'estimation (P1) que le *Machine Learning* devait apporter.**

Le nombre d'allocations distinctes éclaire le mécanisme : à 25 % sur cinq actifs, $5 \times 0,25 = 1,25$, si bien que tout portefeuille admissible doit détenir au moins quatre actifs à *poids strictement positif*, aucun actif ne pouvant dépasser l'équipondération de plus de cinq points de pourcentage. L'arithmétique seule n'impose **pas** de solution de coin : l'équipondération (20 % chacun) demeure admissible, sans aucun actif au plafond. Ce qui est *mesuré*, en revanche, c'est que la contrainte domine empiriquement l'objectif : la variance minimale n'émet qu'**une seule** allocation sur 248 rééquilibrages ; à 30 %, elle en émet 171. Sur cet univers, la contrainte — et non le modèle — détermine en pratique l'essentiel de l'allocation.

À présenter comme un résultat, non comme une limite : le contrôle du risque le plus efficace de ce système s'est révélé être la limite de position qu'un mandat réel imposerait de toute façon. C'est précisément ce que le cadrage « contraintes réalistes de gestion » du cahier des charges invitait à découvrir.

5.6 Ce qui ne fonctionne pas : cinq pistes fermées

La couche de prédiction de rendement — des modèles d'apprentissage supervisé prédisant le rendement de chaque actif — n'a jamais dépassé la ligne de base. Plutôt que de l'accepter, cinq explications possibles ont été testées indépendamment, chacune avec un protocole pré-enregistré.

TAB. 5.5 : Cinq tentatives indépendantes de dépasser la ligne de base régime + covariance dynamique.

Piste testée	Verdict
Prédiction de rendement calibrée honnêtement 5 fois plus d'historique de prix (univers marocain profond, 56 184 lignes)	aucune surperformance incrémentale établie coefficient d'information $\times 2$ à $\times 4$, aucun avan- tage de portefeuille établi — voir chapitre 6
Données fondamentales point-in-time (P/E, P/B, P/S, D/E)	coefficient d'information $\times 2$, ratio de Sharpe en baisse
Ré-sélection par pli, 74 % de données hors échan- tillon en plus	intervalles $-28,6$ %, classement instable
Contrainte conditionnée au régime	réfutée par son propre contrôle

La deuxième de ces pistes — l'extension de l'historique marocain — est la plus directement liée au terrain du projet, et son verdict est plus nuancé qu'une ligne de tableau ne peut le montrer : le chapitre 6 lui est entièrement consacré. Deux autres méritent d'être détaillées ici, car elles établissent un point de méthode qui dépasse ce projet.

Précision de prédiction $\neq$ performance de portefeuille. L'ajout de données fondamentales a presque *doublé* la capacité prédictive mesurée du modèle (coefficient d'information de 0,028 à 0,058) — et a fait *baisser* le ratio de Sharpe du portefeuille correspondant. Le même phénomène est apparu avec cinq fois plus d'historique de prix. Améliorer un modèle et améliorer un portefeuille sont deux objectifs distincts ; le second ne découle pas automatiquement du premier.

L'importance d'un contrôle destiné à réfuter. L'étude sur la contrainte conditionnée au régime incluait une variante **inversée**, délibérément construite dans la mauvaise direction. Sur le portefeuille EURAFRIC, cette variante inversée est bien la pire — ce qui semblait confirmer l'existence d'un effet de régime. Mais sur l'univers ETF, elle *dépasse* la meilleure variante « correcte ». Un effet qui change de signe selon l'univers n'est pas un effet. Sans ce contrôle, la conclusion aurait été inverse.

Ce que la convergence de ces cinq études indique

Les cinq études ne justifient pas une valeur incrémentale de la couche de prédiction sur les univers et protocoles évalués. Elles montrent aussi que des écarts de l'ordre de grandeur observé restent trop instables pour être promus en surperformance. L'absence de preuve n'est pas une preuve d'absence ; c'est une limite mesurée, rendue visible par des tentatives comparables.

5.7 L'étiquette correspond-elle au modèle ? (P4)

Plusieurs estimateurs de ce système se dégradent au lieu d'échouer : DCC-GARCH retombe sur le rétrécissement de Ledoit-Wolf en cas de non-convergence, les signaux ML retombent sur la moyenne empirique si le panel est trop mince ou si l'ajustement échoue, et la stratégie à régimes résout une postérieure incertaine vers sa branche défensive. Chacun de ces replis est délibéré — une boucle walk-forward ne doit pas mourir sur une fenêtre difficile — mais chacun signifie aussi qu'un résultat peut porter une étiquette qui n'est pas toute la vérité. Un « DCC-GARCH » ayant replié une fois sur quatre est, sur ces dates, un résultat Ledoit-Wolf sous une étiquette DCC-GARCH.

Jusqu'ici ces replis n'étaient tracés qu'en journal applicatif, au niveau **WARNING** : un message que personne ne lit sur une exécution non surveillée, et absent de tout artefact publié. Une instrumentation par rééquilibrage enregistre désormais, pour chaque ajustement, le modèle demandé, le modèle effectif, le statut, la raison du repli et la taille de la fenêtre d'entraînement. Ces enregistrements sont persistés en couche Gold (`fit_reports.parquet`), versionnés et intégrés au manifeste de release avant qu'aucun tableau n'en soit tiré.

TAB. 5.6 : Repli des estimateurs sur l'instantané publié. Un repli signifie que le résultat a été produit par un estimateur de substitution, non par le modèle nommé.

Univers	Stratégie	Replis / rééquilibrages	Replis / jours
etf_2017	dcc_garch	0 / 248	0 / 5387
etf_2017	regime_conditional	3 / 248	63 / 5387
etf_2017	rf_signal	0 / 248	0 / 5387
etf_2017	xgb_signal	0 / 248	0 / 5387
full_2021	dcc_garch	1 / 48	21 / 1040
full_2021	regime_conditional	3 / 48	65 / 1040
full_2021	rf_signal	0 / 48	0 / 1040
full_2021	xgb_signal	0 / 48	0 / 1040

Intégrité des modèles : 7 ajustements sur 1 184 ont emprunté un repli d'estimateur (4 stratégies évaluées, 296 dates de rééquilibrage). Sur ces rééquilibrages, le résultat a été produit par un estimateur de substitution et non par le modèle que son étiquette désigne : les séries concernées sont des HYBRIDES. La portée de cette mesure est exactement l'ensemble compté ci-dessus : elle n'affirme pas qu'aucun repli n'est possible sur un autre instantané.

Ce que cette mesure établit, et ce qu'elle n'établit pas

Elle établit combien de replis ont été empruntés sur l'instantané publié, pour les stratégies et les dates comptées ci-dessus, et lesquels : les 7 replis mesurés relèvent tous du démarrage à froid de la chaîne de régimes, où la fenêtre est trop courte pour ajuster le HMM. Sur ces rééquilibrages l'allocation provient entièrement de la sous-stratégie défensive, sans signal de régime. La valeur est une *mesure reproductible et versionnée*, non une hypothèse — c'est là l'apport, davantage que le décompte lui-même.

Elle n'établit pas qu'aucun modèle ne replie jamais, ni qu'un repli soit une défaillance : la non-convergence réelle de l'estimateur EM n'a, elle, jamais été observée sur cet instantané. Les chemins de repli sont du code vivant et testé, et un autre instantané peut les emprunter autrement. L'instrumentation existe précisément pour rendre cette question *vérifiable*, pas pour trancher d'avance.

Le contrôle qui rend le résultat crédible n'est pas le décompte mais le test d'équivalence du runner : celui-ci doit reproduire chaque ratio de Sharpe publié à *travers* le moteur instrumenté. Sans lui, l'instrumentation pourrait auditer une stratégie différemment

configurée portant le même nom — ce qui s’est effectivement produit lors d’une première rédaction, où une configuration incomplète produisait un `rf_signal` à 0,146 contre 1,123 publié.

5.7.1 Sensibilité aux coûts de transaction

Un ratio de Sharpe net énonce autant une hypothèse de coûts qu’une propriété de stratégie ; les hypothèses retenues ici (10 pb ETF, 30 pb BVC) sont des jugements. Le tableau 5.7 reprice le *même* chemin d’allocation sous $0,5\times$, $1\times$, $1,5\times$ et $2\times$ ces coûts.

TAB. 5.7 : Sharpe net du *même* chemin d’allocation, repricé sous des coûts de transaction multipliés. Il ne s’agit pas d’une ré-optimisation : les pondérations sont identiques dans chaque colonne. « Seuil » est le multiplicateur annulant le rendement net.

Univers	Stratégie	$0,5\times$	$1\times$	$1,5\times$	$2\times$	Seuil	Rotation
etf_2017	dcc_garch	0,909	0,903	0,897	0,891	$> 20\times$	0,112
etf_2017	regime_conditional	0,940	0,937	0,934	0,931	$> 20\times$	0,056
etf_2017	rf_signal	0,909	0,903	0,897	0,890	$> 20\times$	0,128
etf_2017	xgb_signal	0,825	0,811	0,798	0,784	$> 20\times$	0,293
full_2021	dcc_garch	1,032	0,994	0,956	0,917	$13,3\times$	0,289
full_2021	regime_conditional	0,997	0,957	0,917	0,877	$12,5\times$	0,321
full_2021	rf_signal	0,769	0,679	0,588	0,498	$4,5\times$	0,948
full_2021	xgb_signal	0,962	0,867	0,772	0,676	$5,3\times$	0,973

Portée de ce calcul. Il s’agit d’un *repricing d’un chemin d’allocation figé sous un modèle de coûts linéaire*, et non d’une analyse de sensibilité avec ré-optimisation. Il répond à « combien ces mêmes transactions auraient-elles coûté », jamais à « qu’aurait fait la stratégie si elle avait su les coûts plus élevés ». Trois conditions le bornent : le chemin de pondérations est figé (aucune stratégie évaluée ici ne lit les coûts) ; les coûts sont linéaires en notionnel échangé, sans terme d’impact de marché ni de capacité ; et le calcul ne s’applique *pas* à une stratégie pénalisée en rotation (phase 4C), où le coût atteint la fonction objectif et modifierait les pondérations — ces scénarios-là devraient être re-simulés, non repricés.

Toutes les estimations ponctuelles de Sharpe net rapportées restent positives à $2\times$ les coûts. Ce constat est descriptif : il ne vaut ni démonstration de robustesse ni validation économique. L’ordre de fragilité est en revanche informatif et recoupe le diagnostic des phases 4B/4C : les modèles de signal à forte rotation sont les plus sensibles aux coûts.

5.8 Gouvernance, explicabilité et monitoring

Trois *model cards* sont générées à partir des artefacts Gold : une carte pour la stratégie de référence `regime_conditional`, et une carte pour chacun des challengers `rf_signal` et `xgb_signal`. La première est la référence non parce qu’une supériorité a été démontrée, mais parce qu’aucun challenger ne l’a déplacée selon le protocole retenu et que sa décision est reconstituée. Les deux autres restent explicitement exploratoires.

L’explication est adaptée à la nature de chaque modèle. La stratégie de référence produit une trace de décision par rééquilibrage (régime, sous-optimiseur, contraintes, poids et éventuel repli). Les challengers à arbres produisent des attributions additives exactes : TreeSHAP natif pour XGBoost et décomposition de chemin pour la forêt aléatoire. Les contrôles vérifient la reconstruction de la prédiction ; une explication ne peut donc pas provenir de poids différents

de ceux de l’instantané publié.

Le monitoring est **prêt mais non actif**. L’ordonnanceur demeure arrêté après l’incident d’artefacts déchirés : avant toute reprise, publication atomique, vérification du manifeste avant lecture, répertoires de release versionnés avec verrou, et procédure de rollback exercée sont requis. Cette réserve est intentionnelle : documenté n’est pas validé indépendamment, et prêt au monitoring n’est pas monitoring en production.

5.9 Le produit livré

Le projet livre un **prototype de recherche** composé d’une application web à deux pages et d’une interface REST en lecture seule. Elles partagent une couche de données unique, afin que deux surfaces ne puissent pas afficher des chiffres divergents pour la même stratégie. Elles ne fournissent ni conseil d’investissement, ni ordre, ni service de production.

5.9.1 Page « Résultats de recherche » — destinée aux décideurs

Quatre contraintes d’intégrité sont imposées *par le code* de cette page, plutôt que laissées à la discipline de rédaction :

1. aucun chiffre n’est saisi en dur — tout est calculé à partir des artefacts versionnés, ce qu’un test vérifie en inspectant le code source ;
2. chaque performance affichée est accompagnée de son intervalle de confiance, et le texte indique explicitement que les intervalles se chevauchent ;
3. le cas défavorable — l’univers ETF, où le système perd — est affiché, non dissimulé ;
4. la couche de prédiction de rendement n’est jamais présentée comme l’apport du projet, puisque cinq études n’ont pas établi d’avantage incrémental de portefeuille.

5.9.2 Page « Explorateur de stratégies » — destinée à l’analyse

Cette page ajoute un **explorateur de plafond** : un curseur permettant de faire varier la contrainte de position et d’observer immédiatement son effet sur la performance. C’est le résultat le plus marquant du projet rendu manipulable plutôt que consigné dans un tableau.

5.9.3 L’interface REST

Une API expose les mêmes artefacts pour un usage externe (`/strategies`, `/metrics`, `/equity`, `/weights`, `/compare`, `/crisis`). Elle est délibérément *mince* : elle sert des artefacts versionnés et ne réentraîne jamais de modèle à la demande.

Deux points de conception méritent d’être signalés. D’une part, le point d’entrée `/compare` renvoie toujours l’intervalle de confiance *avec* l’écart de performance : un client ne peut pas récupérer le gain sans son incertitude. D’autre part, `/crisis` expose l’analyse exploratoire avec sa réserve d’attribution et ses limites d’inférence.

streamlit app

Resultats recherche

Explorateur strategies

Deploy

Résultats de recherche — allocation assistée par ML

Prototype de recherche, pas un outil d'investissement. Cette application présente des résultats historiques de backtesting ; elle ne fournit ni conseil d'investissement, ni recommandation client, ni exécution d'ordres.

full_2021 est libellé en MAD, converti au taux de référence officiel de Bank Al-Maghrib (USDMAD, MAD par USD). Le portefeuille reste non couvert : la variation de change réalisée est incluse dans la performance, aucun contrat à terme ni coût de roulement n'est modélisé.

etf_2017 est libellé en USD : cet univers ne contient que des ETF mono-devises, n'a donc jamais présenté de défaut de numéraire, et est inchangé par la correction.

Les niveaux de Sharpe ne sont pas comparables d'un univers à l'autre : les deux univers sont libellés dans des devises différentes, sur des fenêtres différentes et avec un nombre d'actifs différent.

Le problème. Répartir un capital entre 9 actifs — actions de la Bourse de Casablanca et ETF internationaux — de façon à maximiser le rendement tout en maîtrisant le risque. L'outil standard du secteur est l'optimisation moyenne-variance de Markowitz. Les questions auxquelles répond ce projet : ce que les données suggèrent sur le Machine Learning, ce qu'elles permettent d'établir, et — tout aussi important — ce qu'elles ne permettent pas d'affirmer.

Meilleure approche classique

1.069

Stratégie à régimes

0.957

↓ -10.5%

Écart observé

-0.112 Sharpe

Sur le portefeuille EURAFRIC (2022-08-01 → 2026-07-24, simulation walk-forward nette de coûts, libellée en MAD), la stratégie à régimes obtient un ratio de Sharpe de 0.957 contre 1.069 pour la meilleure approche classique (Markowitz — Sharpe maximal).

Sur full_2021, l'écart ponctuel entre regime_conditional et max_sharpe est de -10,47 % (0,9571 contre 1,0690 de Sharpe net). L'écart est également défavorable sur etf_2017 : -1,6 %.

Ces écarts ne démontrent pas une supériorité de l'approche classique : aucun test païré de cette différence n'est présenté.

Évolution du portefeuille, net de coûts (base 100)

Équipondéré (1/N)

Markowitz — variance minimale (Ledoit-Wolf)

Markowitz — Sharpe maximal

Stratégie à régimes (HMM + covariance)

> Qu'est-ce que le système fait différemment ?

Et quand les marchés s'effondrent ?

streamlit app

Resultats recherche

Explorateur strategies

Deploy

> Qu'est-ce que le système fait différemment ?

Et quand les marchés s'effondrent ?

C'est la question qui décide d'un mandat. La diversification est censée protéger en crise — et c'est précisément là qu'elle cesse de fonctionner, les corrélations entre actifs se resserrant brutalement (problème P3 du projet). Nous avons donc mesuré le comportement du portefeuille sur cinq crises, délimitées par les dates de sommet-à-craux publiées du S&P 500 — fixées avant tout examen des résultats, pour ne pas choisir après coup les périodes qui nous arrangent.

Crise	Optimiseurs sous contrainte	Équipondéré (1/N)	Perte évitée	Récupération
Crise financière de 2008	-21.2 %	-30.2 %	+9.0 pts	186 j vs 219 j
Crise de la dette européenne (2011)	+1.6 %	-5.4 %	+7.0 pts	1 j vs 11 j
Repli du 4e trimestre 2018	-7.6 %	-7.9 %	+0.2 pts	53 j vs 105 j
Krach COVID-19 (2020)	-13.5 %	-16.9 %	+3.4 pts	37 j vs 71 j

streamlit app

Resultats recherche

Explorateur strategies

Deploy

Le détecteur est **non supervisé** : aucune date de crise, aucun label de récession ne lui a jamais été fourni. Il n'observe que rendement, volatilité et corrélation moyenne, et décide en **temps réel**, à partir du passé uniquement. Il a néanmoins signalé 5/5 crises au-dessus de son taux de base.

C'est une **association exploratoire**, non une preuve confirmatoire : cinq fenêtres ne suffisent pas à établir une généralisation, et « baisser » est **défini** comme l'état au rendement moyen le plus faible. Le test des signes disponible dans l'artefact ($p = 0.031$) est donc un diagnostic, pas une revendication de significativité. Cette analyse ne démontre pas qu'agir sur le signal améliore la performance économique.

Et le ratio de Sharpe, alors ?

L'écart de ratio de Sharpe présenté plus haut a aussi été examiné sur une **fenêtre de test gelée** (2024-10-28 → 2026-07-24) que la procédure de calibration n'a jamais vue, avec des **intervalles de confiance à 90 %** obtenus par bootstrap par blocs. Le verdict y est plus nuancé que pour le comportement en crise — et nous le présentons tel quel.

Test hors échantillon gelé (2024-10-28 → 2026-07-24) — Sharpe net et intervalle de confiance à 90 %

Stratégie à régimes (HMM + covariance)

0.980

Équipondéré (1/N)

0.858

Ratio de Sharpe net (annualisé)

Lecture honnête de ce graphique. Sur cette fenêtre de test, la stratégie à régimes devance la diversification naïve (1/N) en estimation ponctuelle. Les intervalles affichés sont toutefois **marginiaux** : ils décrivent l'incertitude de chaque stratégie prise isolément, et leur chevauchement ne constitue pas un test de la différence.

Ce test a désormais été mené. Sous sélection strictement antérieure, les huit **comparaisons paires** (bootstrap par blocs sur les mêmes dates, net de coûts) ont toutes un intervalle contenant zéro : **aucune surperformance n'est établie**, ni contre la stratégie à régimes ni contre l'équipondéré, sur aucun des deux univers. Ce n'est pas non plus une preuve d'équivalence.

Comment le système prend ses décisions


Les zones colorées montrent le régime détecté par le modèle à chaque rééquilibrage — sans qu'aucune date de crise ne lui ait jamais été fournie.

Régimes détectés et performance du système

Stratégie à régimes (HMM + covariance)

Régime haussier détecté

Régime baissier détecté



streamlit app

Resultats recherche


Explorateur strategies

Deploy

Stratégie à régimes (HMM + covariance)



Régime haussier détecté

Régime baissier détecté



Limites — ce que ce résultat ne dit pas

- **L'écart observé n'est pas universel.** Sur l'univers ETF internationaux seuls (ETF internationaux (5 actifs, 2004→)), la stratégie à régimes fait -1.6 % face au Markowitz classique — c'est-à-dire qu'il **perd**. Ces deux univers ne permettent donc pas de revendiquer une valeur généralisable du ML.
- **Ce cas défavorable est en partie un artefact de contrainte, pas seulement un verdict sur le ML.** Avec 5 actifs et un plafond de 25 %, tout portefeuille admissible doit placer au moins 4 actifs *au plafond* ($5 \times 0,25 = 1,25$) : la contrainte, et non le modèle, détermine l'essentiel de l'allocation. À 25 % la variance minimale ne produit qu'une **seule** allocation sur 248 rééquilibrages ; à 30 %, elle en produit 169. L'univers à 9 actifs n'est pas concerné.
- **Le test pairé a été mené, et n'établit aucune supériorité.** Les huit comparaisons sur la fenêtre gelée ont un intervalle contenant zéro (p de 0,066






FIG. 5.9 : Page « Explorateur de stratégies » — vue déroulée complète (écran 3 sur 3).

Synthèse du chapitre

- **Exploré** — le détecteur de régime est plus souvent dans l'état « baissier » durant les cinq fenêtres étudiées. Le diagnostic $p = 0,031$ est rapporté comme exploratoire, non confirmatoire.
- **Observé, non démontré** — sur le portefeuille EURAFRIC, libellé en dirhams et non couvert, la stratégie à régimes est en retrait du Markowitz classique de 10,47 %, et lui est également inférieure de 1,6 % sur l'univers ETF, mono-devise en dollars. Le classement est sensible au protocole d'évaluation et à la fenêtre hors échantillon associée ; aucun test pairé de cette différence n'est présenté.
- **Testé, non établi** — sous validation strictement antérieure, les **huit** comparaisons paires sur la fenêtre gelée ont un intervalle contenant zéro (p de 0,066 à 0,939). Aucun modèle de signal n'établit de surperformance, ni contre la stratégie à régimes ni contre l'équipondéré, sur aucun des deux univers. La correction White/SPA sur 240 configurations n'établit pas non plus de surperformance contre la référence primaire.
- **Observé** — l'optimisation sous contrainte protège mieux que la diversification naïve sur les cinq fenêtres de crise étudiées, avec un délai de récupération environ deux fois plus court. Cette lecture reste descriptive et ce gain revient à la contrainte et à la covariance, non à la couche de régime.
- **Découvert** — le plafond de position, choisi comme règle métier, est le régulariseur le plus efficace du système : 10,1 % de Sharpe, plus que tout modèle testé.
- **Réfuté / non établi** — cinq pistes indépendantes visant à dépasser la ligne de base n'ont pas établi d'avantage incrémental ; deux montrent que précision de prédiction et performance de portefeuille sont des objectifs distincts.

Le chapitre suivant conclut en dressant le bilan de ce que le système apporte, des limites qui subsistent, et des directions qu'un prolongement devrait privilégier.

Chapitre 6

Le marché marocain : ce que vingt ans de données changent

Le chapitre précédent se termine sur un constat négatif : sur les univers publiés, aucune couche d'apprentissage n'établit d'avantage face à son comparateur. Ce constat admet deux lectures, et elles n'ont pas les mêmes conséquences. Ce chapitre construit le dispositif qui permet de les départager, sur le terrain qui intéresse le plus l'entreprise d'accueil : la Bourse de Casablanca.

6.1 Deux lectures d'un même résultat

La première lecture est que le signal est *absent* : le marché est suffisamment efficient pour qu'une prédiction de rendement par apprentissage n'apporte rien d'exploitable. La seconde est que le signal a été *affamé* : l'univers `full_2021` ne compte que neuf actifs et environ 11 700 lignes de panel, et la fenêtre de test gelée couvre moins de deux ans. Avec si peu d'observations, un effet réel mais modeste ne peut tout simplement pas être détecté.

Ces deux lectures produisent le même verdict statistique et appellent des décisions opposées. La première clôt le sujet. La seconde désigne un remède précis : davantage de données. Elle a l'avantage d'être testable, et c'est ce test que décrit ce chapitre.

La question posée n'est donc pas « le modèle est-il bon ? » mais « le dispositif d'évaluation avait-il les moyens de le dire ? ». C'est une question sur la puissance du protocole, pas sur la qualité du modèle.

6.2 Constituer vingt ans de Bourse de Casablanca

6.2.1 Ce que les sources permettent réellement

La contrainte qui fixe le début de l'univers canonique à juillet 2021 n'est pas un choix : c'est la profondeur de la source gratuite utilisée pour la BVC. La recherche de données plus anciennes a établi deux faits.

Aucune **interface programmatique gratuite** ne dessert l'historique antérieur à 2021 des valeurs de Casablanca : les identifiants `.CS` sont absents des fournisseurs usuels — seul Maroc Telecom est accessible, et seulement via sa cotation croisée à Euronext Paris — et le candidat payant abordable examiné ne couvre pas la place de Casablanca. En revanche, un fournisseur de

données de marché grand public propose le **téléchargement manuel** de l'historique quotidien de chaque valeur depuis son introduction, avec un plafond de 5 000 lignes par fichier.

Le 22 juillet 2026, les historiques quotidiens de **17 valeurs cotées à Casablanca**, ainsi que l'indice MASI, ont été téléchargés par cette voie. Les fichiers bruts sont conservés dans la couche Bronze, hors dépôt Git comme l'ensemble des données.

6.2.2 L'univers retenu

Des 17 valeurs, l'univers PROFOND retient les **12 titres à historique continu depuis 2005**, choisis sur ce seul critère et non sur leur performance. Ils couvrent la banque (ATW, BCP, CIH, BOA), les télécommunications (IAM), le ciment (LHM, CMA), les mines (MNG), la sidérurgie (SID), la consommation (CSR), l'énergie (GAZ) et l'assurance (WAA) : la structure sectorielle réelle de la cote casablancaise.

TAB. 6.1 : Ce que l'extension change, en volume de données et en couverture historique.

	Univers canonique full_2021	Panel profond DEEP
Actifs	9	12
Historique	2021-07 → 2026	2005-01 → 2024-05
Séances	—	4 682
Lignes de panel	≈ 11 700	56 184 (≈ ×5)
Fenêtre de test hors échantillon	≈ 1,7 an	6,75 ans
Contient la crise de 2008	non	oui

6.2.3 Ce que ces données ne sont pas

Trois réserves sont consignées ici plutôt que laissées à découvrir, car elles déterminent le statut du résultat.

Les prix sont des **cours de clôture non ajustés** en dirhams : ni les dividendes ni les divisions d'actions n'y sont réintégrés. C'est une limite réelle pour une mise en production — le chapitre 3 montre combien le traitement du dividende pèse sur une performance mesurée — mais elle n'affecte pas la question posée ici, qui porte sur la *capacité prédictive* d'un classement transversal et non sur un rendement total.

Le plafond de 5 000 lignes **tronque les historiques les plus anciens** : la fenêtre assemblée s'arrête en mai 2024. Le raccordement avec la source récente, dont les périodes se recouvrent entre 2021 et 2024, est un travail d'industrialisation, non nécessaire pour répondre à la question.

Enfin, les **calendriers de cotation** diffèrent légèrement d'un fichier à l'autre ; ils sont alignés sur un calendrier de jours ouvrés de référence avec report avant borné, exactement comme la chaîne traite déjà les données BVC canoniques.

6.3 Le protocole : celui du chapitre 4, sans adaptation

Pour que la comparaison ait un sens, la machinerie d'évaluation honnête décrite au chapitre 4 est réutilisée *sans modification* : changer à la fois les données et la règle du jeu n'aurait rien établi.

Étape A — la mesure directe, sans portefeuille. Validation croisée par blocs purgés avec embargo, les hyperparamètres des forêts aléatoires et du gradient boosting étant choisis sur

le *coefficient d'information*. Cette étape ne suppose aucun coût de transaction et ne construit aucune allocation : elle mesure la compétence prédictive seule, ce qui est exactement ce qu'il faut pour savoir si le modèle était sous-alimenté.

Définition — Coefficient d'information (IC)

Le *coefficient d'information* est la corrélation de rang entre les rendements prédits et les rendements effectivement réalisés à la période suivante. Il vaut 0 quand le classement prédit n'a aucun rapport avec le classement réalisé, et 1 pour un classement parfait. En gestion quantitative d'actions, un IC de l'ordre de 0,05 est déjà considéré comme exploitable : les valeurs utiles sont petites, et c'est leur stabilité qui compte.

Étape B — le test gelé. Les 35 % finaux de la période sont réservés et ne sont ouverts qu'une fois. Les modèles calibrés y sont évalués aux côtés du système à régimes, de l'équipondéré et des références classiques, chacun accompagné d'un intervalle de confiance à 90 % obtenu par bootstrap par blocs. Les leviers d'allocation sont **fixés et non sélectionnés** — rétrécissement à 0,5, pénalité de rotation à 1,0 — précisément pour que cette expérience réponde à la question des *données* et non à celle du réglage.

6.4 Étape A — le modèle s'aiguise réellement

Le résultat de l'étape A est net, et il est positif.




FIG. 6.1 : Le coefficient d'information mesuré sur le panel marocain profond, comparé à la plage obtenue sur l'univers canonique. Les deux familles de modèles progressent dans les mêmes proportions.

Le coefficient d'information passe de la plage 0,015–0,036 observée sur l'univers canonique à 0,0684 **pour la forêt aléatoire** et 0,0751 **pour le gradient boosting** : une multiplication par un facteur 2 à 4, obtenue *indépendamment par les deux familles de modèles*. Cette concordance compte autant que le niveau : deux algorithmes de nature différente, entraînés séparément, se déplacent dans les mêmes proportions.

Un IC voisin de 0,07 sort du bruit et entre dans la plage considérée comme exploitable en gestion transversale d'actions. Sur ce point, la réponse est donc sans ambiguïté : **le signal était, pour partie, affamé**. Davantage d'historique marocain rend le modèle mesurablement plus fin.

6.5 Étape B — le portefeuille, lui, ne suit pas

L'étape B évalue ce que cette finesse devient une fois transformée en allocation, sur la fenêtre gelée 2017–2024 et nette des coûts de transaction.

TAB. 6.2 : Ratios de Sharpe nets sur la fenêtre de test gelée, avec intervalle de confiance à 90 % par bootstrap par blocs. Tous les intervalles contiennent zéro.

Stratégie	Sharpe net	IC 90 %
Forêt aléatoire calibrée	0,3376	[−0,4117 ; +1,1399]
Équipondéré (1/N)	0,2525	[−0,5570 ; +1,1469]
Gradient boosting calibré	0,2238	[−0,5053 ; +0,9944]
Markowitz (Sharpe maximal)	0,1782	[−0,5251 ; +0,9290]
Variance minimale (LW)	0,1269	[−0,5991 ; +0,9528]
Système à régimes	0,0669	[−0,6467 ; +0,8193]

Trois observations s’imposent, et une seule d’entre elles est une conclusion.

D’abord, **la forêt aléatoire calibrée obtient la meilleure estimation ponctuelle**, devant l’équipondéré et devant Markowitz. C’est un renversement par rapport à l’univers canonique, où le système à régimes menait et les challengers suivaient.

Ensuite, **tous les intervalles contiennent zéro**, et ils sont larges : de l’ordre d’une unité et demie de Sharpe. Aucun écart de ce tableau n’est établi.

Enfin, et c’est le point le plus instructif, **le classement s’inverse** entre les deux univers. Un avantage qui change d’ordre selon l’échantillon est la signature du bruit, non celle d’un avantage durable. La correction pour le nombre d’essais confirme cette lecture : le ratio de Sharpe dégonflé du meilleur challenger vaut 0,6792 sur les six configurations explorées.

Une procédure de comparaison multiple appliquée à l’ensemble des hypothèses de cette expérience — 60 hypothèses appariées sur 1 638 observations — ne retient **aucun** survivant au seuil de 5 %. Aucune stratégie n’est déclarée supérieure à l’équipondéré.

6.6 Ce que « pas de gain » signifie exactement

Il serait commode de s’arrêter là et de conclure que davantage de données ne sert à rien. Ce serait une erreur, et le projet l’a commise avant de la corriger.

*La note de recherche initiale affirmait que cette expérience « écarte, preuves à l’appui, l’idée que davantage d’historique de prix soit le remède ». Cette affirmation a été **retirée** lors du réexamen du 15 septembre 2026. Elle reposait sur des intervalles contenant zéro, ce qui ne dit rien de la capacité du dispositif à détecter l’effet qu’il cherchait.*

La grandeur qui manquait est l’**effet minimal détectable** : le plus petit écart que le protocole repère huit fois sur dix, au seuil retenu. Comparer l’écart observé à cet effet minimal indique si le dispositif avait, ou non, les moyens de conclure.

Sur l’univers canonique, ce rapport se situe entre 0,01 et 0,26 : le verdict négatif y était **inscrit dans le dispositif** avant qu’aucun modèle ne soit ajusté. Sur la fenêtre gelée, l’écart détectable atteint 0,765, soit environ sept fois le plus grand écart réellement observé ; à effet constant, il faudrait de l’ordre de 12 000 séances — près de quarante-huit ans — pour que ce protocole puisse départager les deux stratégies.

Cinq fois plus de données doublent le pouvoir de résolution — sans franchir le seuil




FIG. 6.2 : Écart observé rapporté à l'effet minimal détectable. Une barre atteignant 1,0 correspond à un dispositif tout juste capable de trancher ; en deçà, le verdict négatif est déterminé par la taille de l'échantillon avant tout ajustement de modèle.

Sur le panel marocain profond, le même rapport atteint 0,57 pour la comparaison entre la forêt aléatoire calibrée et le système à régimes. Autrement dit, cinq fois plus de données n'ont pas « échoué à aider » : elles ont **plus que doublé le pouvoir de résolution** du dispositif. Elles ne l'ont simplement pas porté jusqu'au seuil. À effet observé constant, franchir ce seuil demanderait environ 3,1 fois plus d'observations hors échantillon, soit de l'ordre de 5 045 séances — une vingtaine d'années supplémentaires.

La distinction qui porte tout ce chapitre

« N'a pas franchi le seuil » et « est écarté » sont deux énoncés différents, et seul le premier est soutenu par cette expérience. Le résultat n'autorise pas à conclure que davantage de données marocaines serait inutile ; il quantifie, au contraire, ce qu'il en faudrait.

6.7 Ce qui ne s'est pas reproduit

Le réexamen du 15 septembre 2026 a rejoué l'expérience depuis les fichiers bruts, avec le même script. L'univers se reconstruit à l'identique : 12 valeurs $\times$ 4 682 séances, du 6 janvier 2005 au 31 mai 2024, sans valeur manquante. Les coefficients d'information se reproduisent, de même que les ratios de Sharpe de l'équipondéré, de Markowitz et du système à régimes.

Celui du gradient boosting ne se reproduit pas. Il ressort à 0,2238 contre 0,28 lors de la campagne initiale. L'écart suffit à renverser un énoncé qualitatif : à 0,2238, le gradient boosting calibré passe *sous* l'équipondéré, et l'affirmation « les stratégies d'apprentissage obtiennent les meilleures estimations ponctuelles » ne vaut plus que pour la forêt aléatoire. La cause la plus probable est une dérive de version de la bibliothèque de gradient boosting entre les deux exécutions.

Cette hypothèse ne peut pas être confirmée, et c'est en soi un enseignement : ni les fichiers bruts ni le panel assemblé ne sont empreintés par une somme de contrôle. Un artefact d'entrée haché aurait permis de trancher entre dérive de bibliothèque et dérive de données. C'est une lacune de traçabilité, nommée ici au même titre que les autres, et la première chose à corriger si ce panel doit être industrialisé.

6.8 Ce qu'il faudrait pour intégrer ce panel à la release

Ce panel reste une **expérience de recherche**. Il n'alimente ni l'API, ni le tableau de bord, ni aucun résultat publié au chapitre 5. Cinq chantiers le séparent d'un statut de release, et ils sont d'ingénierie de données bien plus que de modélisation :

- **Réconcilier les sources** — raccorder l'historique profond à la source récente sur leur période de recouvrement 2021–2024, et vérifier que le raccord ne crée ni saut de prix ni doublon.
- **Réintégrer les dividendes** à leur date de détachement, et traiter les opérations sur titres (divisions, attributions).
- **Contractualiser la source** — les droits de redistribution d'un téléchargement manuel ne sont pas ceux d'un flux sous contrat.
- **Empreinter les entrées** par une somme de contrôle, pour que la non-reproductibilité observée plus haut devienne diagnosticable.
- **Tenir compte des défauts de mesure propres à la place** — prix fréquemment figés et non-synchronicité des séances avec les places américaines, dont le chapitre 9 mesure l'ampleur.

Ce que ce chapitre établit

Multiplier par cinq l'historique marocain rend le modèle mesurablement plus fin : le coefficient d'information est multiplié par un facteur 2 à 4, et les deux familles de modèles le confirment séparément. Ce gain de précision ne se transforme pas en avantage de portefeuille établi : tous les intervalles contiennent zéro et aucune stratégie ne survit à la comparaison multiple. Mais le dispositif a plus que doublé son pouvoir de résolution, et l'on sait désormais chiffrer ce qui manque. La limite n'est donc pas la quantité de données : c'est la conversion d'une prédictibilité faible mais réelle en un avantage net de coûts, sur un marché étroit, peu liquide et coûteux à négocier.

Chapitre 7

Révisions, qualité de mesure et gouvernance de la preuve

Un projet quantitatif n'est pas crédible parce que son dernier chiffre est favorable. Il l'est lorsque ce chiffre peut être relié à une source, à une définition économique, à un protocole temporel et à une version précise du code. Cette exigence est particulièrement forte dans une banque ou une compagnie d'assurance : une décision peut être revue longtemps après son émission, par une seconde ligne de validation, un auditeur ou un régulateur. Il faut alors reconstituer non seulement le modèle, mais la donnée et les règles qui ont produit la décision.

Ce chapitre présente une partie moins visible, mais déterminante, du travail : les corrections qui ont changé le verdict et les contrôles ajoutés pour qu'une erreur analogue devienne détectable automatiquement. Il ne s'agit pas d'un journal d'incidents. C'est la démonstration que le prototype sait retirer une conclusion lorsque ses hypothèses ne tiennent plus.

7.1 Trois mesures du même système, trois verdicts

La figure 7.1 résume l'évolution du résultat principal sur `full_2021`. Les deux premiers nombres sont conservés comme **résultats historiques superseded**, et non comme performances actuelles.

Mesure initiale. Les ETF étaient fournis en rendement total, tandis que les actions de la Bourse de Casablanca étaient observées en prix seulement. La comparaison attribuait donc aux optimiseurs le mérite d'éviter des actifs dont une partie du rendement avait été supprimée par la préparation des données. La réintégration causale des dividendes aux dates de détachement a réduit l'écart observé de +14,3 % à +6,2 %.

Correction du numéraire. Cette seconde correction est plus fondamentale. Un rendement est un ratio sans unité, mais un portefeuille produit un profit ou une perte dans une devise. Additionner quatre rendements en MAD et cinq rendements en USD sans conversion revient à agréger des montants qui ne sont pas réalisables par un même investisseur. Après conversion causale des niveaux de prix ETF au taux de référence USD/MAD de Bank Al-Maghrib, l'écart ponctuel devient -10,47 % : 0,9571 de Sharpe net pour `regime_conditional`, contre 1,0690 pour `max_sharpe`.




FIG. 7.1 : Évolution du résultat après correction successive de la définition du rendement et du numéraire. Les deux valeurs positives sont historiques et remplacées par la mesure en MAD. Source : artefacts Gold versionnés.

La contribution n'est pas le changement de signe

Le point important n'est pas que le résultat soit devenu défavorable au ML. Il est que l'architecture ait permis de localiser l'hypothèse économique erronée, de reconstruire toute la chaîne avec la source officielle, puis de retirer le message antérieur sur chaque surface publiée. Un résultat qui résiste à une tentative de réfutation vaut davantage qu'un résultat favorable obtenu une fois.

7.2 Le numéraire : une notion simple aux conséquences matérielles

Le *numéraire* est la monnaie dans laquelle le patrimoine et sa performance sont mesurés. Pour un investisseur marocain, acheter un ETF américain crée deux sources de variation : celle de l'ETF en dollars et celle du dollar face au dirham. En l'absence de couverture, les deux appartiennent au rendement réalisé.

La politique finale est donc définie *par univers*, sans valeur globale par défaut :

- **full_2021** contient quatre actions BVC et cinq ETF. Il est entièrement exprimé en **MAD**, au taux officiel BAM, et reste **non couvert** contre le risque USD/MAD ;
- **etf_2017** contient uniquement cinq ETF en USD. Il reste un univers **USD mono-devise**, indépendant de la série BAM ;
- les deux univers répondent à des questions différentes. Leurs niveaux de Sharpe ne doivent pas être comparés entre eux comme s'ils partageaient le même investisseur de référence.

La source Yahoo initialement envisagée a été refusée par un contrôle de qualité : sur les dates communes, elle suivait le niveau du taux de change, mais ses variations quotidiennes étaient presque décorrélées de celles de BAM et sa volatilité était environ six fois plus élevée. La série

Correction du numeraire : rendre la performance réalisable par un investisseur marocain
Avant : addition de deux devises **Après : portefeuille en MAD**




FIG. 7.2 : Avant et après correction du numéraire sur l'univers mixte. La conversion est appliquée aux niveaux de prix avec uniquement l'information disponible à la date considérée; aucune position de couverture n'est simulée.

officielle couvre entièrement la période exploitable de `full_2021`. Une lacune initiale de dix-sept jours ouvrés a conduit à déplacer le début de l'univers au 29 juillet 2021; la fenêtre hors échantillon publiée n'est pas affectée.

7.3 Le protocole fait partie du résultat

Deux expériences honnêtes peuvent aboutir à un classement différent si elles n'interrogent pas la même période. La figure 7.3 distingue le découpage unique de la phase 5 du *walk-forward* imbriqué. Dans les deux cas, l'entraînement reste strictement antérieur à l'évaluation. Dans le second, la sélection est répétée à chaque frontière externe, ce qui change aussi la fenêtre hors échantillon concaténée.




FIG. 7.3 : Protocoles temporels comparés. Une purge retire les observations dont l'horizon de cible chevauche la validation; l'embargo impose un espace supplémentaire à la frontière.

Sur la fenêtre imbriquée du 28 juillet 2023 au 24 juillet 2026, six re-sélections produisent 781

observations hors échantillon. Le ratio de Sharpe déflaté est 0,7370 sur 198 configurations. Aucun adjectif n'est accolé à cette valeur : aucun seuil d'interprétation n'a été fixé avant l'expérience. La conclusion défendable est plus sobre : **le classement est sensible au protocole et à la fenêtre hors échantillon associée**. Il serait incorrect d'attribuer la différence au seul caractère imbriqué du protocole.

7.4 Du data snooping à une conclusion corrigée

Choisir le meilleur résultat parmi de nombreuses configurations augmente mécaniquement la probabilité de trouver une performance apparente. Ce phénomène, appelé *data snooping*, est l'équivalent quantitatif de poser 240 questions au même échantillon puis de ne rapporter que la réponse la plus favorable.




FIG. 7.4 : White Reality Check et Hansen SPA face au comparateur primaire `regime_conditional`. Aucun des quatre tests primaires ne franchit le seuil descriptif de 5 %. Les deux procédures sont toujours publiées ensemble.

Le comparateur primaire `regime_conditional` a été fixé avant lecture des valeurs corrigées et n'a pas été remplacé après le changement de signe. Sur 240 configurations atteignables, aucun candidat n'établit une surperformance contre ce comparateur, sur aucun univers et pour aucune des deux statistiques évaluées. Les comparaisons à l'équipondéré sont conservées comme exploratoires : franchir ce plancher ne prouve pas que la couche ML apporte une valeur incrémentale.

Cette correction ne se substitue pas au bootstrap paillé. Les deux répondent à des questions différentes : le bootstrap teste la différence entre deux séries alignées sur les mêmes jours ; White/SPA corrige le fait que de nombreux candidats ont été essayés. Par ailleurs, l'absence de rejet ne démontre jamais l'équivalence. Un test d'équivalence exigerait une marge économique définie à l'avance.

7.5 Une chaîne de preuve exécutable

La succession des corrections a conduit à une règle de conception : une affirmation critique ne doit pas dépendre de la mémoire de l'équipe. Elle doit être liée à un contrôle qui échoue si

l'affirmation devient fausse.




FIG. 7.5 : Sept couches de contrôle entre la donnée et la phrase publiée. Chaque garde-fou est né d'une classe d'erreur effectivement observée dans le projet.

Les contrats Pandera bloquent les valeurs impossibles et les trous trop longs. DVC relie chaque produit à ses dépendances et rend le graphe reconstruisible. Le moteur causal tronque toutes les données à la date de décision. Le manifeste de snapshot enregistre les empreintes, le numéraire, les dates et la révision productrice; il refuse de certifier un arbre Git non propre. Les tests statistiques conservent les séries pairées et le nombre de candidats. Enfin, les faits publiés sont générés depuis Gold puis vérifiés jusque dans le texte extrait du PDF. Ce dernier contrôle a détecté des valeurs historiques que les recherches dans le code source avaient manquées à cause de la syntaxe LaTeX.

L'auditabilité n'est pas synonyme d'immuabilité du résultat. Au contraire, un système gouverné doit pouvoir changer de conclusion lorsque la donnée ou le protocole change, tout en expliquant exactement pourquoi et à partir de quelle version.

7.6 Intégrité des modèles sous défaillance

Les estimateurs DCC–GARCH et les modèles de rendement possèdent des chemins de repli sûrs. Sans télémétrie, un résultat intitulé « DCC–GARCH » pourrait en réalité être produit par Ledoit–Wolf après une non-convergence. Chaque rééquilibrage enregistre donc le modèle demandé, le modèle effectif, le statut, la raison du repli, le nombre de lignes d'entraînement et les avertissements de convergence.

Le décompte publié figure dans l'énoncé « Intégrité des modèles » du chapitre *Faits publiés* et dans le tableau 5.6 : il est produit à partir de `data/gold/fit_report_summary.json` et n'est jamais saisi ici. Cette mesure ne signifie pas qu'un modèle ne peut jamais échouer : les chemins

de repli sont du code vivant et testé, et un autre snapshot peut les emprunter. Sa portée est exactement l'ensemble compté.

Un décompte que seul l'artefact concerné peut observer ne vaut rien : le 2026-08-10, le résumé de télémétrie annonçait zéro repli alors que `dashboard_regime.parquet` enregistrait six rééquilibres sans convergence, parce qu'aucun point d'instrumentation n'existait sur les chemins SLS-QP et HMM. Le compte est désormais confronté à ce second artefact par `TestFallbackCountsAgree`. Les caches réémettent par ailleurs la télémétrie à chaque lecture, afin qu'un cache chaud ne fasse pas artificiellement diminuer le taux de repli.

7.7 Lecture pour une organisation financière régulée

Dans un environnement bancaire ou assurantiel, cette architecture prépare trois niveaux de contrôle usuels. La première ligne — l'équipe qui construit — produit les artefacts, tests et cartes de modèle. Une seconde ligne indépendante devrait challenger les données, hypothèses de coûts, décisions de modèle et seuils. Une troisième ligne d'audit doit pouvoir rejouer ou retracer la release sans dépendre des auteurs. Le projet livre la matière technique des trois niveaux, mais ne prétend pas avoir réalisé la validation indépendante : cette case reste explicitement ouverte dans la gouvernance.

Le prototype est donc **documenté et reproductible**, pas « validé pour la production ». Cette distinction est importante : elle évite qu'une qualité d'ingénierie réelle soit transformée en autorisation d'usage que le projet n'a ni le mandat ni les données pour accorder.

Chapitre 8

Démonstrateur, explicabilité et préparation industrielle

Le résultat scientifique n'est qu'une partie du livrable. EURAFRIC Information conçoit des systèmes pour des institutions où une analyse doit être comprise, versionnée, contrôlée et exposée à plusieurs publics sans divergence. Le projet a donc été mené comme un petit produit de recherche : un même ensemble d'artefacts alimente le rapport, le tableau de bord, l'interface REST, les cartes de modèle et les contrôles de monitoring.




FIG. 8.1 : Architecture fonctionnelle du prototype. Les flèches représentent une direction de preuve : toute information publiée doit remonter à un artefact validé, puis à une transformation et à une source.

8.1 Deux interfaces, un seul contrat de vérité

La première page du tableau de bord, « Résultats de recherche », s'adresse au décideur. Elle commence par le numéraire et les limites d'usage, puis présente le verdict principal, les fenêtres de crise et la force de preuve. Elle ne présente plus une promesse de valeur ML : les écarts observés sont négatifs sur les deux univers et aucune surperformance des challengers n'est établie après correction de la recherche.

La seconde page, « Explorateur de stratégies », s'adresse à l'analyste. Elle permet de filtrer l'univers, la stratégie et les métriques, d'observer la trajectoire de richesse, les pertes maximales, les allocations et la rotation. Les deux pages utilisent la même couche de lecture. Un test interdit les ratios de Sharpe écrits en dur dans le code d'interface : une nouvelle release change les deux vues ensemble ou échoue.

L'interface REST offre la même information à un consommateur machine. Elle est volontairement en lecture seule : elle sert des allocations historiques et des explications déjà produites par la chaîne, mais n'accepte ni données de marché, ni ordre, ni recalibrage à la demande. Chaque réponse liée à un univers rend obligatoires la devise de base et le statut de couverture. L'absence de ces champs serait une erreur de contrat, non une information facultative.

8.2 Expliquer des objets différents de manière différente

Une explication n'est pertinente que si elle porte sur la décision réellement prise. Le système principal `regime_conditional` ne contient ni Random Forest ni XGBoost : lui appliquer SHAP aurait expliqué un modèle qui n'existe pas. Deux mécanismes complémentaires ont donc été construits.


Système à régimes. La trace enregistre les probabilités du HMM, le régime retenu, le sous-optimiseur choisi, la covariance utilisée, les contraintes et les poids finaux. Sur la décision illustrée, le régime est baissier et `min_variance_lw` est appelé. Quatre actifs atteignent le plafond de 25 % et QQQ reçoit un poids nul. L'explication révèle ainsi une réalité métier : la contrainte peut déterminer davantage l'allocation que le classement issu du modèle.

Challengers arbres. XGBoost fournit nativement les contributions TreeSHAP ; pour Random Forest, une décomposition exacte des chemins d'arbres a été implémentée. L'additivité est vérifiée numériquement : la somme du biais et des contributions reconstruit chaque prédiction. Une permutation d'importance complète cette explication locale. Ce choix évite d'ajouter une pile native `numba/llvmlite` dans un environnement qui avait déjà rencontré un conflit de bibliothèques natives.

L'explication va jusqu'au lien entre prédiction et portefeuille. Sur `etf_2017`, le classement RF et les poids présentent une concordance de $-1,000$: l'actif prédit premier reçoit zéro, parce que la covariance et le plafond dominant l'optimisation. Ce résultat explique pourquoi une meilleure prédiction n'implique pas automatiquement une meilleure stratégie.

8.3 Performance économique : regarder aussi l'intensité de trading

Le ratio de Sharpe net n'est pas seulement une propriété du signal. Il dépend de la fréquence à laquelle le portefeuille est modifié et du coût appliqué à cette rotation. La figure 8.7 replace






FIG. 8.3 : Tableau de bord — attribution des résultats et comportement dans les fenêtres de crise. Les diagnostics exploratoires sont séparés des preuves confirmatoires.




FIG. 8.4 : Tableau de bord — page « Explorateur de stratégies ». Cette vue expose la performance, le risque, les coûts et l'allocation au lieu de réduire la décision à un seul ratio.

Portfolio ML API

1.1.0

OAS 3.1

openapi.json

Interface REST de recherche pour l'optimisation de portefeuille (EURAFRIC / INPT). Sert les artefacts Gold versionnés produits par `src/run_dashboard_data.py`. Ni conseil d'investissement, ni exécution.

meta

GET

/health

Health

GET

/version

Version

catalogue

GET

/strategies

List Strategies

résultats

GET

/metrics

Metrics

GET

/equity

Equity

GET

/weights

Weights

GET

/crisis

Crisis

GET

/compare

Compare

publication

GET

/published-allocation

Published Allocation

GET

/explanations/{universe}

Explanation

GET

/model-card/{system}

Model Card

Schemas

ApiVersionResponse >

Expand all

object

ExplanationResponse >

Expand all

object

HTTPValidationError >

Expand all

object

ModelCardResponse >

Expand all

object

PublishedAllocationResponse >

Expand all

object

SnapshotProvenance >

Expand all

object

ValidationError >

Expand all

object

FIG. 8.5 : Contrat OpenAPI du service de recherche en lecture seule. Les routes de publication exposent l'allocation historisée, son explication, sa carte de modèle et la provenance du snapshot ; aucune route d'ordre n'existe.




FIG. 8.6 : Explicabilité adaptée au rôle du modèle. À gauche, importances globales des challengers ; à droite, trace reconstituable de la décision finale du système à régimes sur `full_2021`.

donc les modèles sur deux axes : performance et intensité de trading.




FIG. 8.7 : Sharpe net et rotation moyenne par rééquilibrage sur `full_2021` en MAD. Les modèles de signal occupent généralement la zone la plus coûteuse sans compensation robuste en performance.

Une sensibilité à $0,5\times$, $1\times$, $1,5\times$ et $2\times$ les coûts de référence a été calculée par revalorisation du même chemin de poids sous un coût linéaire. Elle ne constitue pas une ré-optimisation et ne modélise ni impact de marché ni capacité. Tous les Sharpes nets ponctuels reportés restent positifs à $2\times$ les coûts, fait descriptif qui ne démontre ni robustesse économique ni possibilité d'exécution. L'information utile est relative : les modèles de signal, plus actifs, sont les plus fragiles au coût.

8.4 Artefacts de gouvernance

Trois cartes de modèle sont générées depuis Gold : une carte du comparateur primaire à régimes et une carte pour chacun des challengers RF et XGB. Elles ne leur attribuent pas le même statut. Le premier reste le comparateur primaire pré-spécifié pour White/SPA ; il n'est ni recommandé ni présenté comme système de référence après observation du résultat. Les challengers sont exploratoires et leurs attributions ne reçoivent aucune interprétation causale.

Chaque carte contient l'identité de la release, les données et fenêtres, les contraintes, les métriques, les résultats pairés, les limites, les usages interdits et les exigences de monitoring. Le document de gouvernance fixe en outre les responsabilités, le processus challenger, le versionnement, le recalibrage, le rollback et la protection des données. La ligne de validation indépendante reste vide volontairement : l'équipe qui construit ne peut pas s'auto-déclarer validateur indépendant.

8.5 Reproductibilité et exploitation contrôlée

Lecture industrielle : ce qui est livre, prêt, ou volontairement hors perimetre

Reproductibilite	DVC + lock 284 dependances + R2	LIVRE
Tests	781 tests hors ligne + CI	LIVRE
Explicabilite	trace HMM + attributions arbres exactes	LIVRE
Gouvernance	3 cartes modele + politique challenger	LIVRE
Service	API REST read-only + dashboard	PROTOTYPE
Conteneurisation	Docker Compose, volumes read-only	LIVRE
Monitoring	PSI et baseline offline	PRET, NON ACTIF
Execution marche	ordres, capacite, impact	HORS PERIMETRE
Validation independante	revue par une seconde ligne	A REALISER

FIG. 8.8 : État industriel du livrable. « Prêt » signifie que les artefacts et contrôles existent ; cela ne signifie pas qu'un service est actif ou autorisé en production.

La release fige les dépendances Python dans un fichier de 284 versions, les données et résultats avec DVC, et leur stockage distant sur un bucket R2 compatible S3. Une installation propre peut matérialiser le snapshot puis vérifier ses empreintes. Le dépôt comprend une image Docker et une composition de services en lecture seule. L'intégration continue exécute les contrôles qui ne nécessitent pas les données privées de la télécommande ; les portes de release dépendantes de Gold restent exécutées localement avant publication.

Au moment de ce rapport, **plus de 780 tests** couvrent notamment les contrats de données, l'absence de regard vers le futur, les solveurs, les chemins de repli, les caches, les statistiques pairées, la correction de multiplicité, les cartes de modèle, les faits publiés et le texte du PDF

rendu. Le nombre brut n'est pas une preuve de correction ; l'intérêt est que plusieurs tests rejouent des incidents réels et échouent si la classe d'erreur réapparaît.

8.6 Monitoring prêt, mais non actif

Le projet fournit une baseline hors ligne et des fonctions de mesure pour le PSI des variables, la dérive des prédictions, la fréquence de régime, la rotation, la concentration et les replis. Sans flux live, ces mesures ne doivent pas être présentées comme un monitoring actif. L'ordonnanceur Dagster a été arrêté après un incident où une exécution avait publié des artefacts de versions différentes ; une relance automatique sur une release d'évaluation figée ferait également bouger les données sous des résultats déjà publiés.

Quatre conditions précèdent toute activation : publication atomique des artefacts, vérification du manifeste avant lecture, répertoires de release versionnés avec verrouillage, et rollback exercé au moins une fois. La position actuelle — **prêt, non actif** — est donc un choix de maîtrise du risque, pas un oubli opérationnel.

8.7 Notebooks : exploration sans contaminer la release

Les notebooks historiques ont été conservés comme supports pédagogiques, mais sécurisés : ils lisent les artefacts Gold publiés et ne reconstruisent pas la chaîne d'évaluation lors d'une exécution interactive. Quatre notebooks de synthèse ont été ajoutés pour la soutenance : histoire du résultat, preuve statistique, explicabilité et risque, reproductibilité et gouvernance. Ils servent à explorer et raconter le projet, non à fabriquer une seconde source de vérité parallèle au pipeline.

Cette séparation répond à un risque classique des projets académiques : un notebook permet facilement d'exécuter des cellules hors ordre, d'écraser un résultat ou de charger un fichier local non versionné. Ici, les expériences canoniques vivent dans des scripts, des étapes DVC et des artefacts contrôlés ; le notebook devient une fenêtre de lecture. L'étude exploratoire sur l'historique marocain profond (2005–2024, 12 actions) est explicitement hors release : elle a accru le coefficient d'information des signaux sans établir d'avantage de portefeuille. Son intégration exigerait une source contractualisée, un rapprochement avec la période récente, et des ajustements de dividendes et d'opérations sur titres. Elle sert donc de résultat de recherche, pas d'entrée silencieuse dans la chaîne canonique.


8.8 Ce qui est livré, et ce qui ne l'est pas

Le prototype offre une chaîne de recherche reproductible, des décisions historiques expliquées, des interfaces de consultation, un packaging, une gouvernance et des contrôles de dérive hors ligne. Il n'offre pas l'exécution d'ordres, la gestion de liquidité en temps réel, l'impact de marché, la capacité, une couverture de change, une haute disponibilité ou une validation indépendante.

Cette frontière est volontairement visible dans le code, les contrats API, les cartes de modèle et les interfaces. Elle protège le lecteur contre une confusion fréquente : un prototype techniquement soigné n'est pas, pour autant, un modèle autorisé à prendre une décision financière réelle.

Ce qui fait ressortir le projet

La valeur professionnelle du livrable tient à la combinaison rarement réunie dans un PFA : données multi-sources contractualisées, moteur temporel causal, comparaison statistique corrigée de la recherche, explicabilité adaptée à la décision, traçabilité des replis, faits publiés générés, packaging et limites opérationnelles explicites. Le résultat ML est négatif ; la démonstration de ce résultat est, elle, substantielle.



The screenshot shows the Dagster web interface. On the left is a navigation sidebar with links for Overview, Runs, Catalog (selected), Jobs, Automation, Lineage, and Deployment. The main area is titled 'Assets' and contains a table of asset definitions. Each row represents an asset with its name, description, code location, status, and materialization time. All assets shown are in a 'Materialized' state.

Asset name	Code location / Asset group	Status
bvc_dividends BVC per-share dividend history (amounts + ex-dates) scraped from casa...	definitions.py bronze	Materialized Jul 29, 11:00 PM
gold_layer Stationarity report + lagged macro features — Phase 2 input.	definitions.py gold	Materialized Jul 29, 11:02 PM
log_returns Calendar-aligned, Pandera-validated log-returns (9-asset universe), on a...	definitions.py silver	Materialized Jul 29, 11:02 PM
log_returns_etf ETF-only log-returns (2017+, includes COVID + the 2022 rate shock) — L...	definitions.py silver	Materialized Jul 29, 11:02 PM
ml_features_layer Phase 3 causal ML features (both universes) + reproducibility manifest ...	definitions.py gold	Materialized Jul 29, 11:02 PM
raw_bam_macro Bank Al-Maghrib indicators (FX + policy rate).	definitions.py bronze	Materialized Jul 29, 11:00 PM
raw_bvc_prices BVC (Bourse de Casablanca) equity prices.	definitions.py bronze	Materialized Jul 29, 11:00 PM
raw_etf_prices ETF-adjusted-close prices via yfinance.	definitions.py bronze	Materialized Jul 29, 11:02 PM
raw_fred_macro Global macro indicators via FRED.	definitions.py bronze	Materialized Jul 29, 11:00 PM

FIG. 8.9 : Graphe d'actifs Dagster : orchestration locale et lignage des couches du pipeline. L'ordonnanceur reste arrêté sur la release de soutenance.

Chapitre 9

L'univers global_2004 : un test enfin équitable

Les chapitres précédents concluent qu'aucun avantage n'a été établi pour la couche de régimes ni pour les modèles challengers. Cette conclusion souffrait toutefois d'une faiblesse d'*identification* : sur les deux univers publiés, il n'était pas possible de distinguer « le modèle n'apporte rien » de « le dispositif ne permet pas au modèle de s'exprimer ». Ce chapitre décrit la construction d'un troisième univers destiné à lever cette ambiguïté, et le résultat obtenu.

9.1 Deux défauts d'identification, mesurés et non supposés

etf_2017 — la contrainte domine l'objectif. Avec cinq actifs et un plafond de 25 %, la variance minimale à rétrécissement n'émet qu'**une seule allocation distincte sur 248 ré-équilibrages**. L'arithmétique seule n'impose pas cette solution de coin — l'équipondération demeure admissible, sans aucun actif au plafond — mais empiriquement c'est la contrainte, et non le modèle de covariance, qui choisit le portefeuille. Une meilleure estimation de covariance n'a alors nulle part où se manifester.

full_2021 — l'entrée de covariance est biaisée. Les séances de Casablanca et de New York ne se recouvrent qu'à peine et les prix de la BVC sont fréquemment figés : corrélation contemporaine de 0,0041 avec le SPY contre 0,0779 au décalage d'un jour, et 17,1 % de journées à rendement exactement nul. La matrice de covariance quotidienne sous-estime donc systématiquement la dépendance entre marchés.

Aucun de ces deux défauts n'est un échec de modélisation. Ce sont des propriétés de l'ensemble d'opportunités, ce qui explique qu'aucun changement de modèle n'ait pu les corriger.

9.2 Un protocole gelé avant toute donnée

L'univers a été spécifié dans un document de pré-enregistrement (`GLOBAL_UNIVERSE_PREREGISTRATION.md`) validé et *horodaté par un commit isolé* avant toute ingestion. Il fixe dix instruments cotés aux États-Unis et libellés en dollars — SPY, QQQ, IWM, EFA, EEM, IEF, TLT, LQD, IYR, GLD — retenus par six règles d'éligibilité formulées uniquement en attributs *ex ante* : place de cotation, date de création, catégorie de prospectus, composition déclarée. Aucune règle ne consulte un rendement, si bien que la liste est entièrement déterminée avant qu'une seule observation ne soit lue.

Le protocole fixe également les deux questions, leurs comparateurs, le seuil de matérialité économique et, par amendement daté, la hiérarchie des critères statistiques. Chaque amendement a été committé *avant* le code qu'il gouverne.

Le document reconnaît lui-même ne pas être un pré-enregistrement immaculé : des diagnostics d'allocation avaient été inspectés avant sa rédaction et ont motivé l'exclusion de deux instruments. Cette inspection est divulguée intégralement, avec la précision qu'aucune grandeur de performance n'en faisait partie.

9.3 Le défaut d'expressivité est levé

Avant tout calcul de performance, un point de contrôle de *préparation des données* a vérifié dix critères pré-enregistrés : fenêtre de 21,7 ans effectivement préservée, aucune cellule reportée par remplissage avant, absence de signature de prix figés (dominance de décalage $-0,0248$, exigence ≤ 0), et les deux garde-fous d'absence d'anticipation. Verdict : **READY, 10/10**.




FIG. 9.1 : À contrainte strictement identique (plafond de 25 %, mêmes coûts, même moteur), l'optimiseur passe d'une allocation unique sur 248 rééquilibrages à une allocation distincte à *chaque* rééquilibrage. C'est la condition nécessaire pour qu'un test de modèle ait un sens.

9.4 Q1 — la couche de régimes face au comparateur classique

Une seule comparaison, spécifiée à l'avance, sur le segment de test gelé (2019-01-04 à 2026-08-14, 1913 jours) : `regime_conditional` contre `max_sharpe`, nette de coûts. Aucune correction de tests multiples n'est appliquée, car une hypothèse unique fixée d'avance n'en requiert pas.

Le Sharpe net observé est de **0,8923** pour la stratégie à régimes contre **0,9785** pour le comparateur, soit un écart de $-0,0862$ avec un intervalle à 90 % de $[-0,2133; +0,0414]$ et une valeur p unilatérale de 0,8596. Les deux verdicts pré-enregistrés sont négatifs.

Trois lectures que le seul ratio de Sharpe masquerait :

- **Les coûts n'ont pas créé le résultat.** Le Sharpe *brut* était déjà inférieur (0,9080 contre 0,9820) : il ne s'agit pas d'un signal informatif annulé par les frictions de transaction.
- **La rotation est 4,3 fois supérieure** (0,1224 contre 0,0285).

- **La stratégie à régimes ne perd pas sur toutes les dimensions** : sa perte maximale est *moindre* ($-24,22\%$ contre $-25,27\%$).

En résultat secondaire, l'intervalle apparié pour la différence de rendement moyen annualisé est entièrement négatif. Il serait donc inexact de résumer Q1 par « aucune différence établie » sans qualification : c'est vrai de la comparaison en Sharpe, qui est la question enregistrée, et faux de cet intervalle.

9.5 Q2 — la famille des challengers, et la correction

Q2 est une *recherche* et non une comparaison unique : les **240 configurations atteignables** (grilles d'hyperparamètres RF/XGBoost croisées avec les leviers de construction de portefeuille) ont toutes été évaluées, sans qu'aucune ne soit écartée sur la base de sa performance observée. L'hypothèse nulle testée est composite : *aucun* candidat de la famille ne surperforme la référence.




FIG. 9.2 : Distribution des 240 différentiels de Sharpe face à `regime_conditional`. Le meilleur candidat brut dépasse la référence de $+0,093$ — davantage, en valeur absolue, que l'écart de Q1 et en sens inverse. Les tests de White et de Hansen refusent cette valeur : elle est le maximum d'une recherche de 240 configurations, et c'est précisément ce que la correction facture.

Sur le critère **primaire** (différentiel de Sharpe), le Reality Check de White donne $p = 0,905$ et le SPA de Hansen $p = 0,866$; sur le critère secondaire, $0,457$ et $0,358$. Aucun test ne rejette sur aucun critère : **concordant_evidence_of_family_outperformance** vaut **faux**. Seules 17 des 240 configurations dépassent la référence en Sharpe.

9.6 Les challengers honnêtement sélectionnés

La valeur p de la famille répond à la question « le meilleur des 240 est-il crédible ? ». Une question différente, et plus proche de la pratique, est « qu'aurait obtenu un praticien discipliné ? ». Les configurations retenues par une sélection *strictement antérieure* — validation croisée à fenêtre glissante avant, puis choix des leviers sur le segment de validation, le segment de test n'étant jamais montré à un sélecteur — donnent :




FIG. 9.3 : Sharpe net *observé* sur le segment de test gelé. Les deux challengers honnêtement sélectionnés y affichent une valeur inférieure à celle de la stratégie à régimes, elle-même inférieure à celle du comparateur classique. Aucun test païré individuel n'a été pré-spécifié pour ces écarts : ce sont des grandeurs descriptives.

Les challengers RF et XGBoost honnêtement sélectionnés affichent un Sharpe net observé inférieur de respectivement 0,0657 et 0,0898 à celui de `regime_conditional`. Ce constat descriptif est pertinent pour la sélection opérationnelle, mais ne constitue pas une preuve statistique de sous-performance : **aucun test païré individuel de ces écarts n'a été pré-spécifié**.

C'est donc un *diagnostic opérationnel complémentaire* du verdict de famille, et non une version plus forte de celui-ci : le test de famille demande si le meilleur de 240 est crédible, tandis que ce constat décrit ce qu'un praticien discipliné aurait effectivement détenu.

Ce résultat n'est pas un artefact de repli. La télémétrie enregistre *un* repli sur 59 760 ajustements de la famille, trois sur 249 pour la référence — tous antérieurs au segment de test — et **zéro** pour les deux challengers sélectionnés. Chaque chiffre provient donc du modèle que son étiquette désigne.

9.7 Limites

Ces évaluations ne sont pas indépendantes. `etf_2017` et `global_2004` partagent cinq instruments (SPY, QQQ, EEM, GLD, TLT) et des périodes d'évaluation qui se recouvrent largement ; elles subissent donc les mêmes chocs de marché. Il faut les décrire comme **deux évaluations distinctes mais statistiquement recouvrantes**, jamais comme des confirmations indépendantes.

Attribution. Q2 modifie deux choses à la fois par rapport aux univers publiés : la coupe transversale d'actifs *et* la politique de variables macroéconomiques (le bloc Bank Al-Maghrib est exclu, l'univers étant en dollars). Les challengers consommant des variables macro, leurs résultats ne peuvent pas être attribués au seul élargissement de l'univers. Q1 échappe à ce biais, aucune de ses deux stratégies ne lisant de colonne macro.

Sélection externe résiduelle. Les corrections de White et de Hansen portent sur la recherche de *stratégies*. Rien ne corrige la décision, en amont, de *construire* `global_2004` après avoir constaté que les deux univers publiés étaient chacun défectueux.

Conclusion autorisée. *Le plafond de 25 % rendait `etf_2017` faible pour l'attribution de modèle. Une fois l'expressivité de l'allocation rétablie dans `global_2004`, aucun avantage de la couche de régimes ni des challengers n'a davantage été établi. La domination du plafond n'était donc pas la seule explication du résultat négatif antérieur.*

`global_2004` demeure une **expérience de recherche** : il n'est raccordé ni à l'interface REST, ni au tableau de bord, ni à aucune allocation destinée à la production, et aucun résultat publié n'en dépend.

Conclusion générale

Ce qui était demandé, ce qui a été livré

L'énoncé d'EURAFRIC Information demandait un système d'optimisation de portefeuille piloté par apprentissage automatique, capable d'apprendre les corrélations dynamiques entre actifs, opérant sous des contraintes réalistes de gestion, et évalué dans un cadre rigoureux de *backtesting* hors échantillon.

Le livrable est une chaîne complète et reproductible : collecte et validation de données provenant de cinq sources hétérogènes ; une couche de préparation en trois niveaux, validée à l'écriture ; un moteur de simulation temporelle dont l'absence de vision du futur est vérifiée par des tests plutôt qu'affirmée ; quatre familles de modèles ajoutées une à une, du rétrécissement de covariance à la détection de régime, de la prédiction de rendement à l'optimisation sensible aux coûts ; un protocole d'évaluation comportant une sélection strictement antérieure, un segment de test gelé, des **comparaisons paires** et une correction pour le nombre d'essais ; trois cartes de modèle, une couche d'explicabilité et une instrumentation des replis ; et deux surfaces de consultation — une application web à deux pages et une interface REST en lecture seule — partageant une couche de données unique. L'ensemble est couvert par **plus de 780 tests** exécutés hors ligne et par un contrôle du PDF rendu.

Ce que le projet établit

Les résultats sont classés selon leur force probante, et cette distinction est elle-même un résultat de la démarche.

Exploré. Le détecteur de régime, non supervisé et n'ayant jamais reçu de liste de crises, est plus souvent dans son état étiqueté « baissier » à l'intérieur des cinq fenêtres de crise étudiées (91,7 %) qu'en dehors (29,2 %), soit un rapport de **3,13**. Le diagnostic par test des signes ($p = 0,031$) est conservé pour transparence, mais ne constitue pas une preuve confirmatoire : l'échantillon ne comporte que cinq événements et l'état « baissier » est défini par son rendement moyen plus faible. La portée défendable est plus étroite : le modèle produit une lecture causale de l'état de marché associée à ces fenêtres ; il ne démontre pas qu'agir sur cette lecture améliore la performance économique.

Observé, non démontré. Sur le portefeuille visé, libellé en dirhams au taux de référence officiel de Bank Al-Maghrib et non couvert contre le risque de change, l'écart ponctuel entre la stratégie à régimes et la meilleure approche classique est de $-10,47$ % de ratio de Sharpe net ; il est également défavorable sur l'univers ETF, à $-1,6$ %. Ces écarts ne démontrent pas une supériorité de l'approche classique : aucun test paillé de cette différence n'est présenté. Le classement est par ailleurs sensible au protocole d'évaluation et à la fenêtre hors échantillon

associée.

Testé, non établi. La réserve précédente n'est plus une réserve : le test manquant a été mené. Sous sélection strictement antérieure — l'entraînement ne pouvant plus consulter des dates postérieures à sa fenêtre de validation — les **huit** comparaisons paires effectuées sur la fenêtre de test gelée ont un intervalle contenant zéro (p compris entre 0,066 et 0,939). **Aucune surperformance n'est établie**, ni pour les modèles de signal contre la stratégie à régimes, ni contre l'équipondéré, sur aucun des deux univers.

Un cas résume l'intérêt de la démarche. Sur `etf_2017`, le signal RF calibré obtient 1,102 contre 1,093 pour la stratégie à régimes : en estimation ponctuelle il « bat » la référence. Le test pairé donne pourtant $p = 0,326$. Le classement ponctuel, celui qu'on aurait rapporté sans ce test, n'est pas soutenu par les données.

Ce n'est pas pour autant une preuve d'équivalence : ne pas rejeter n'est pas accepter l'hypothèse nulle. L'établir demanderait un test d'équivalence contre une marge fixée à l'avance, qui n'a pas été mené. Ces réserves sont affichées dans le rapport, le tableau de bord et l'interface de programmation.

Observé sur cinq fenêtres. Pendant les cinq crises, l'optimisation sous contrainte a systématiquement mieux protégé le capital que la diversification naïve, avec un délai de retour au sommet environ deux fois plus court. L'attribution est faite honnêtement : ce gain revient à la contrainte de position et au modèle de covariance, non à la couche de régime, qui dans trois de ces cinq fenêtres produit exactement la même allocation qu'une stratégie classique.

Découvert. Le plafond de 25 % par actif, retenu comme règle métier et non comme dispositif de modélisation, s'est révélé le régulariseur le plus efficace du système : le relâcher coûte 10,1 % de ratio de Sharpe, davantage que l'écart entre deux modèles quelconques testés sur cet univers. Ce résultat est la reproduction, sur nos propres données, d'un théorème connu — une contrainte de position active équivaut mathématiquement à un rétrécissement de la matrice de covariance.

Réfuté. Cinq pistes indépendantes visant à dépasser la ligne de base ont été explorées et fermées : la prédiction de rendement calibrée honnêtement, un historique cinq fois plus long, l'ajout de données fondamentales, la re-sélection à chaque repli temporel, et le conditionnement de la contrainte au régime. Le constat qui émerge de leur convergence est plus intéressant que chaque échec pris isolément : **aucune de ces pistes n'établit un avantage incrémental de portefeuille dans les protocoles évalués**. Deux de ces études montrent en outre, séparément, que *précision de prédiction et performance de portefeuille sont deux objectifs distincts* : le coefficient d'information a doublé sans que le ratio de Sharpe suive, et il a même reculé dans un cas.

Ce que le projet apporte au-delà des chiffres

La contribution la plus durable de ce travail n'est probablement pas une performance, mais un *dispositif*.

Deux incidents l'illustrent mieux qu'un discours. La découverte que les dividendes marocains manquaient a réduit de plus de moitié le gain historique. Puis la correction du numéraire, au taux officiel Bank Al-Maghrib, a renversé son signe. Les chiffres corrigés ont remplacé les anciens sur chaque surface et les affirmations antérieures ont été retirées. Ces corrections n'ont été possibles

que parce que la chaîne était restructurable de bout en bout ; elles auraient probablement été masquées dans un projet où les résultats sont produits à la main.

De là vient le principe qui structure l'ingénierie du projet : **une règle importante n'est pas documentée, elle est rendue exécutable**. L'impossibilité de consulter le futur, l'interdiction d'écrire un chiffre de performance en dur dans une interface, la cohérence entre documents publiés, la traçabilité de chaque fonction vers le problème qu'elle traite, l'hermétisme réseau de la suite de tests : chacune de ces règles est un test qui échoue si on l'enfreint. Les trois incidents les plus coûteux du projet ont tous consisté en une règle respectée par discipline jusqu'au jour où elle ne l'a plus été, sans que rien ne le signale. Chacun a donné lieu à un garde-fou automatique, validé en rejouant l'incident réel. Les cartes de modèle et les traces d'explication complètent ce dispositif : la stratégie de référence est expliquée par ses décisions, les challengers par des attributions additives vérifiées, et le monitoring est explicitement prêt mais non actif tant que ses préconditions de publication atomique et de rollback ne sont pas satisfaites.

Limites

Elles sont énoncées ici plutôt que laissées à découvrir.

- **La taille et la composition de l'échantillon limitent la puissance, non toute conclusion.** `full_2021` couvre environ cinq années : cela ne permet pas de départager solidement de petits écarts entre stratégies. Le projet conclut toutefois, sur les protocoles évalués, qu'aucun avantage ML robuste n'est établi.
- **L'univers BVC canonique commence en 2021.** Un historique marocain profond 2005–2024 a bien été testé séparément (chapitre 6) : il a amélioré la qualité de prédiction sans établir de gain de portefeuille. Cette absence de gain ne vaut pas réfutation : elle traduit d'abord un pouvoir de résolution insuffisant, que ces données ont plus que doublé sans le porter jusqu'au seuil. Le panel n'est pas intégré à la release parce que source, raccordement récent, dividendes et opérations sur titres doivent encore être contractualisés et reproduits. L'univers ETF, lui, remonte à novembre 2004 et couvre 2008, 2020 et 2022, sans se substituer à un historique BVC canonique long.
- **Un rendement de dividende sur quatre a dû être estimé,** la source publique ne le publiant pas. L'analyse de sensibilité correspondante est documentée, mais la donnée reste une estimation.
- **La correction pour le nombre d'essais est établie** sur les 240 configurations atteignables de la recherche contre la référence primaire. Huit comparaisons externes demeurent non corrigées à ce niveau, et les résultats contre l'équipondéré restent exploratoires : cette frontière borne explicitement les affirmations autorisées.
- **Le système n'a pas été exposé à des conditions d'exploitation réelles** : ni exécution d'ordres, ni flux temps réel, ni couverture du risque de change dirham/dollar. Le monitoring est instrumenté hors ligne mais reste volontairement non actif derrière ses portes de release.

Perspectives

Quatre suites se dégagent, classées par rapport valeur/effort.

Industrialiser l'historique marocain profond. L'expérience a déjà écarté l'idée qu'ajouter du seul historique de prix promette mécaniquement un avantage de portefeuille. Elle reste néanmoins précieuse pour la puissance statistique, la couverture de 2008 et la représentativité de l'univers BVC. La suite est un travail de gouvernance et de validation des données : contrat de source, rapprochement sur le recouvrement, dividendes et opérations sur titres, puis réévaluation complète. Ce n'est pas une promesse de performance.

Faire valider le modèle indépendamment et activer le monitoring. Une validation extérieure doit challenger le protocole, les hypothèses de coûts et les artefacts de release. Ensuite seulement, le monitoring pourra être activé après publication atomique, vérification de manifeste, verrouillage des releases et exercice de rollback.

Calibrer la pénalité de rotation par modèle. Les mesures ont établi qu'une valeur globale unique dégrade le bon modèle tout en corrigeant le mauvais. La rendre spécifique à chaque modèle est un travail de calibration circonscrit, au protocole déjà disponible.

Adoucir le basculement de régime. Le basculement franc actuel produit un pic de transactions à chaque frontière de régime. Un mélange continu, pondéré par la probabilité de régime, est une alternative documentée dès la conception et non encore mesurée.

Trois résultats à ne pas confondre

L'expérience `global_2004` (chapitre 9) permet de séparer trois choses que le mot « résultat » confond habituellement, et qu'un lecteur pressé traduirait à tort par « l'apprentissage automatique a échoué ».

- **Une réussite d'ingénierie.** Un univers a été pré-enregistré et horodaté avant toute donnée, contrôlé par dix critères de préparation, raccordé à DVC et à Dagster, puis *gelé* comme preuve à usage unique. Les artefacts se reconstituent, se vérifient et se réfutent.
- **Une réussite méthodologique.** La correction pour tests multiples a fait exactement ce pour quoi elle existe : un écart sélectionné de +0,093 de Sharpe — plus grand, en valeur absolue, que celui de Q1 et de sens opposé — a été empêché de devenir un titre. C'est la contribution la plus transportable du projet.
- **L'absence d'avantage établi.** Ni la couche de régimes (Q1) ni la famille des challengers (Q2) n'ont établi de supériorité sur des règles de portefeuille plus simples, sur cet univers.

Le message n'est pas que « l'apprentissage automatique échoue ». Il est qu'une fois les deux défauts d'identification levés, les modèles complexes ont enfin reçu un test équitable — et n'ont toujours pas établi d'avantage. La contribution du projet est la preuve auditable montrant pourquoi le gagnant brut, pourtant séduisant, ne doit pas être cru.

Bilan

Ce projet aura moins appris à l'équipe comment faire gagner un modèle qu'à *savoir si un modèle gagne*. C'est un apprentissage inconfortable : il consiste, l'essentiel du temps, à construire les instruments qui feront tomber les résultats auxquels on tenait — un test qui interdit de voir le futur, un intervalle de confiance qui absorbe l'écart qu'on voulait annoncer, une donnée corrigée qui divise un gain par deux à trois semaines de la remise.

C'est pourtant, dans un domaine où les performances publiées sont notoirement difficiles à reproduire, la seule compétence qui se transporte d'un sujet à l'autre. Le prototype livré à EURAFRIC Information ne prétend pas battre les méthodes classiques, ni recommander ou exécuter une allocation : il expose les écarts historiques observés, leurs limites et les conditions de leur reproduction. Il constitue un socle de recherche et d'analyse, pas un outil de gestion en production.