

Optimisation de portefeuille pilotée par Machine Learning

Peut-on améliorer la répartition d'un capital grâce à l'apprentissage automatique —
et savoir, de façon vérifiable, si l'amélioration est réelle ?

Souhail BOURHIM · Zakarya EL WALI · Yasmine BOUAJINE

Étudiants ingénieurs · INPT

Encadré par M. Abdelmoultalib MAQIL

EURAFRIC Information

Quatre temps, une seule question

1

Le vocabulaire

Portefeuille, risque, Sharpe, backtest : tout ce qu'il faut pour suivre la suite.

2

Le problème

Pourquoi répartir un capital est difficile — et pourquoi un bon backtest peut mentir.

3

Notre réponse

Une chaîne complète : données, modèles, épreuve temporelle, tests statistiques.

4

Les résultats


Ce que le système détecte, ce qui améliore vraiment, et ce qui est livré.

Le fil conducteur : une décision d'investissement n'a de valeur que si l'on peut prouver qu'elle n'est pas le fruit du hasard.

Un portefeuille, une allocation, un rééquilibrage


Le système ne choisit pas « quand acheter » : il choisit des pourcentages, tous les mois.

1 · Un portefeuille




un capital réparti entre plusieurs actifs

2 · L'allocation




3 · Le rééquilibrage



À retenir : la sortie du modèle est un vecteur de poids. Tout le reste — performance, risque, frais — en découle mécaniquement.

Le ratio de Sharpe : la note qui compte

Gagner beaucoup en dormant mal ne vaut pas gagner autant tranquillement.



Rendement

Ce que le portefeuille rapporte, en pourcentage, sur une année.


Risque (volatilité)

L'amplitude des secousses : plus la courbe tremble, plus le risque est élevé.

Dans toute la présentation, les Sharpe sont nets de frais de transaction et calculés hors échantillon — sur des données que le modèle n'a jamais vues.

Markowitz — et les quatre mots qui décident du reste

Prix Nobel 1990 : combiner des actifs qui ne bougent pas ensemble réduit le risque sans sacrifier le rendement.



Chaque point gris est un portefeuille possible ; la courbe bleue rassemble les meilleurs.
Le modèle a besoin de deux entrées — rendements attendus et covariances — toutes deux estimées, donc incertaines.

LES QUATRE MOTS

Backtest

rejouer la stratégie sur le passé

Fuite de données

utiliser sans le vouloir une information du futur

Surapprentissage

apprendre le bruit du passé au lieu de la règle

Data snooping

à force d'essayer, trouver un gagnant dû au hasard

Ces quatre notions structurent tout notre protocole.

La question posée par le projet

« Répartir un capital entre des actions de la Bourse de Casablanca et des ETF internationaux.
Le Machine Learning fait-il mieux que la méthode classique — une fois payés les frais et vérifiée la statistique ? »

LES CONTRAINTES IMPOSÉES AU SYSTÈME

Long-only

aucune vente à découvert :
une contrainte de gestion réelle

Plafond 25 %

aucun actif ne peut dépasser
un quart du portefeuille

Frais réels

chaque rebalancement coûte,
et le coût est déduit

Mensuel

la décision est reprise
à chaque fin de mois

TROIS TERRAINS D'ÉTUDE, ÉVALUÉS SÉPARÉMENT

full_2021

4 actions BVC + 5 ETF · en dirhams · 2021–2026

etf_2017


5 ETF internationaux · en dollars · 2004–2026

global_2004

10 ETF multi-classes · en dollars · 2004–2026

Quatre façons dont l'optimisation classique échoue


Chaque échec appelle une réponse technique précise — c'est le plan de construction du système.



Traduction : l'optimiseur classique prend des estimations incertaines pour des certitudes, suppose que demain ressemble à hier, et s'effondre exactement au moment où la diversification devrait protéger.

En crise, la diversification disparaît quand on en a besoin

Les actions se mettent à tomber ensemble ; seuls l'or et les obligations s'en détachent.



0,79 → 0,94


corrélation entre actions
en mars 2020 : le portefeuille
se comporte comme un seul actif

Conséquence

Un modèle qui suppose
une structure de risque fixe
se trompe précisément
les jours qui coûtent cher.

Le meilleur backtest d'une longue recherche est presque toujours une illusion

240 stratégies testées — et le champion est refusé



240

stratégies entièrement
évaluées, liste figée
avant tout calcul

+0,093

l'écart du « champion » :
séduisant sur le papier

$p = 0,90$

le test de sélection multiple
ne retient pas ce résultat

C'est le biais qui explique une grande partie des stratégies publiées qui ne fonctionnent jamais en réel. Le projet le traite comme un adversaire, pas comme un détail.

Huit phases, chacune livrée et vérifiable

Rien n'a été construit d'un bloc : chaque phase produit un livrable écrit et des artefacts versionnés avant que la suivante commence.



L'équipe


Trois élèves ingénieurs de l'INPT, encadrés par M. Abdelmoultalib Maqil chez EURAFRIC Information. Le travail est partagé par phase, avec revue croisée avant chaque livrable.

La règle de travail

Une phase n'est close que si son résultat est reproductible : données versionnées, tests au vert, et documents régénérés depuis les artefacts, jamais retapés.

Une chaîne complète, de la donnée brute à la décision publiée

Une seule direction : de la donnée brute à la décision publiée



Aucun chiffre publié n'est saisi à la main : chaque surface est régénérée depuis les artefacts.

Rien n'est saisi à la main

Chaque chiffre affiché est régénéré depuis un artefact versé.

Rien ne regarde l'avenir

Une décision n'utilise que l'information antérieure.

Rien n'est publié sans test

Une amélioration doit survivre à la correction statistique.

Une donnée n'entre dans le système que si elle est traçable

Bronze

La donnée brute, conservée telle quelle. On ne réécrit jamais la source.

Silver

Calendriers alignés, conversion en dirhams au taux officiel Bank Al-Maghrib, contrôles de cohérence.

Gold

Rendements, indicateurs et preuves : la seule couche que les modèles et le rapport ont le droit de lire.

CE QUE CELA ÉVITE CONCRÈTEMENT

Le biais de dividende

Les dividendes des actions BVC sont réintégrés à leur date de détachement : ignorer cela sous-estime la performance réelle.

Le piège de la devise


Un ETF coté en dollars n'est pas comparable à une action cotée en dirhams. Tout est ramené à une seule monnaie, au taux officiel.

Ces deux corrections ont changé les résultats publiés. Elles ont été appliquées malgré cela — c'est le prix d'un chiffre auquel on peut se fier.

La complexité est ajoutée par paliers, jamais d'un bloc

Chaque étage doit prouver qu'il améliore l'étage précédent, sinon il reste expérimental.

La complexité est ajoutée par paliers — chacun doit justifier son coût




Chaque palier est comparé au précédent hors échantillon, net de frais.

Le cœur du système : un modèle de régimes (HMM) qui reconnaît, sans supervision, si le marché est calme ou sous tension — et change de posture.

Rejouer l'histoire sans jamais connaître la suite

Le modèle est réentraîné à chaque décision, avec les seules données disponibles ce jour-là.

Backtest à fenêtre glissante : le modèle est réentraîné à chaque décision



Purge et embargo

On écarte les jours à cheval sur la frontière pour qu'aucune information ne fuite.

Test final gelé

La dernière période reste intouchée jusqu'à la comparaison finale.

Frais déduits

Chaque mouvement de portefeuille est facturé avant d'être compté.

Trois verrous entre un bon chiffre et une affirmation

1 · Comparaison appariée

Les deux stratégies sont comparées jour par jour, sur exactement les mêmes dates. Un intervalle de confiance accompagne chaque écart.

2 · Correction du data snooping

White Reality Check et Hansen SPA corrigent le fait d'avoir essayé 240 configurations. La liste a été figée avant le premier calcul.

3 · Comparateur pré-spécifié

La référence à battre est choisie à l'avance et jamais réécrite après avoir vu les résultats.

Pourquoi cela compte pour un jury

Sans ces trois verrous, n'importe quelle équipe peut produire une courbe qui monte. Avec eux, un résultat annoncé devient vérifiable — et réfutable.

L'ensemble est rejouable : les données sont versionnées, le pipeline est décrit étape par étape, et 891 tests automatisés gardent les invariants.

Hors échantillon et net de frais, le système tient la distance

Deux terrains évalués séparément : quatre ans au Maroc, vingt ans à l'international — 2008, 2020 et 2022 compris.

Univers mixte marocain — 9 actifs, en dirhams



ETF internationaux — 5 actifs, en dollars




— Système ML à régimes Références classiques ($1/N \cdot$ variance minimale · Markowitz)

La bande couvre les trois références classiques, du moins au mieux. Le système ML reste dedans d'un bout à l'autre, crises comprises : la question n'est donc pas « est-ce que ça marche », mais « l'écart est-il réel ou dans le bruit » — et c'est ce que la chaîne sait trancher.

Le modèle repère les crises — sans qu'on les lui apprenne

Les cinq fenêtres de crise sont des dates externes, fixées avant d'examiner les résultats.

Le modèle, jamais informé des crises, les a toutes reconnues



5 / 5

crises détectées
par un modèle non supervisé

91,7 %

de rééquilibrages classés
« tension » pendant les crises
contre 29,2 % hors crise


$p = 0,031$

test des signes, lecture prudente

Un diagnostic exploitable : le système sait dire dans quel état de marché il pense se trouver, et cette information est lisible par un gérant.

La contrainte de gestion vaut plus que la sophistication

Même moteur, mêmes données, mêmes frais : seule la règle « aucun actif au-delà de 25 % » change.



0,9525

Sharpe net avec le plafond de 25 %

0,8650

Sharpe net sans plafond

+10,1 %

d'écart : plus que tout modèle testé

Lecture métier : une règle de gouvernance simple absorbe l'erreur d'estimation mieux qu'un modèle complexe. C'est un résultat directement actionnable.

La chaîne sait refuser un résultat flatteur

CE QU'UN BACKTEST AURAIT PERMIS D'ÉCRIRE

« Notre modèle XGBoost améliore le Sharpe de +0,093 »

Vrai au sens arithmétique : c'est bien le meilleur des 240 candidats évalués.

CE QUE LA CHAÎNE RÉPOND

**« C'est le maximum d'une recherche.
Les tests ne le retiennent pas. »**

White Reality Check $p = 0,905$ · Hansen SPA $p = 0,866$ · 17 candidats devançaient la référence en apparence.

POURQUOI C'EST LA CONTRIBUTION LA PLUS UTILE


Un prototype qui produit des résultats a peu de valeur s'il ne sait pas les invalider. Celui-ci a été conçu pour que la déception soit détectable — c'est exactement ce qu'une direction des risques exige d'un modèle.

Même logique appliquée à nos propres corrections : dividendes, historique et conversion en dirhams ont été corrigés même lorsque cela dégradait le résultat affiché.

Davantage de données marocaines : le modèle s'aiguise vraiment

Un panel de recherche reconstitué sur vingt ans de Bourse de Casablanca, pour répondre à « et si le problème, c'était simplement le manque d'historique ? ».

Cinq fois plus de données marocaines rendent le modèle 2 à 4 fois plus net



56 184 observations contre 11 700 aujourd'hui. Le signal s'améliore ; le gain de portefeuille, lui, n'est pas établi.

12

actions de la Bourse de Casablanca, de 2005 à 2024

×5

plus d'observations que l'univers actuel

×2 à ×4

de pouvoir prédictif en plus, confirmé par les deux algorithmes

La limite n'est donc pas seulement la quantité de données : c'est la transformation du signal en allocation. C'est exactement ce que la première perspective propose d'industrialiser.

Ce que nous établissons — et ce que nous n'établissons pas

ÉTABLI

- ✓ Détection non supervisée des cinq crises de la période.
- ✓ Le plafond de 25 % améliore le Sharpe net de +10,1 % sur les ETF.
- ✓ Une chaîne reproductible de bout en bout, versionnée et testée.
- ✓ Un dispositif capable de refuser un faux positif de sélection.
- ✓ Une explicabilité exacte : chaque poids se remonte jusqu'à sa cause.

NON ÉTABLI

Sur nos univers et nos fenêtres, aucune couche ML n'établit de surperformance statistiquement significative face à son comparateur pré-spécifié.

C'est une réponse, pas un échec : la question posée était « peut-on le savoir ».

Une équipe qui aurait annoncé l'inverse n'aurait pas pu le démontrer.

Les deux colonnes viennent du même dispositif. C'est ce qui rend la première crédible.

Pourquoi ce poids-là ? Une décision réelle, tracée de bout en bout

Aucune boîte noire : le système ne se contente pas de sortir des pourcentages, il expose la chaîne de raisonnement qui les produit.

Décision du 24/07/2026

1 • Ce que le système lit

rendement du marché : $-0,07\%$
volatilité courte : $10,7\%$
corrélation moyenne : $0,23$

2 • Le régime qu'il en déduit

« marché sous tension »
(modèle de régimes, non supervisé)


3 • La posture qui en découle

variance minimale (Ledoit-Wolf)
la sous-stratégie défensive

4 • Ce que les contraintes imposent

TLT bloqué au plafond de 25%
QQQ écarté du portefeuille

5 • Les poids publiés



Système principal

Trace déterministe :
rien n'est approché,
tout est relu.

Challengers

Attributions additives
exactes pour RF et
XGBoost.

C'est ce qu'exige une gouvernance de modèles : pouvoir remonter d'un poids publié jusqu'à la donnée qui l'a causé — et le montrer à un auditeur.

Un prototype réellement utilisable, pas un notebook

streamlit app

Resultats recherche

Explorateur strategies

Deploy

Résultats de recherche — allocation assistée par ML

Prototype de recherche, pas un outil d'investissement. Cette application présente des résultats historiques de backtesting ; elle ne fournit ni conseil d'investissement, ni recommandation client, ni exécution d'ordres.

full_2021 est libellé en MAD, converti au taux de référence officiel de Bank Al-Maghrib (USDMAD, MAD par USD). Le portefeuille reste non couvert : la variation de change réalisée est incluse dans la performance, aucun contrat à terme ni coût de roulement n'est modélisé.

etf_2017 est libellé en USD : cet univers ne contient que des ETF mono-devises, n'a donc jamais présenté de défaut de numéraire, et est inchangé par la correction.

Les niveaux de Sharpe ne sont pas comparables d'un univers à l'autre : les deux univers sont libellés dans des devises différentes, sur des fenêtres différentes et avec un nombre d'actifs différent.

Le problème. Répartir un capital entre 9 actifs — actions de la Bourse de Casablanca et ETF internationaux — de façon à maximiser le rendement tout en maîtrisant le risque. L'outil standard du secteur est l'optimisation moyenne-variance de Markowitz. Les questions auxquelles répond ce projet : ce que les données suggèrent sur le Machine Learning, ce qu'elles permettent d'établir, et — tout aussi important — ce qu'elles ne permettent pas d'affirmer.

Les deux approches, comparées

Meilleure approche classique

Stratégie à régimes

Écart observé

Tableau de bord Streamlit

Deux vues : résultats de recherche et explorateur de stratégies

891

tests automatisés

1 184

ajustements de modèles tracés

Portfolio ML API 1.1.0 OAS 3.1

Interface REST de recherche pour l'optimisation de portefeuille (EURAFRIC / INPT). Sert les artefacts Gold versionnés produits par src/run_dashboard_data.py . Ni conseil d'investissement, ni exécution.

meta

GET

/health

Health

GET

/version

Version

catalogue

GET

/strategies

List Strategies

résultats

GET

/metrics

Metrics

GET

/equity

Equity

GET

/weights

Weights

GET

/crisis

Crisis

GET

/compare

Compare

publication

API REST FastAPI, en lecture seule

Contrat de devise explicite, documentation générée

DVC + CI

données versionnées,
portes de release

Docker

environnement reproductible

Ce qui transformerait le prototype en dispositif validé

01 Élargir l'univers marocain

Industrialiser le panel profond 2005–2024 : réconciliation des sources, dividendes, opérations sur titres, licence de redistribution.

02 Validation indépendante

Séparer l'équipe qui développe de celle qui valide, comme l'exige une gouvernance de modèles bancaire.

03 Couverture du risque de change

Modéliser un contrat de couverture USD/MAD et son coût de roulement, aujourd'hui absents.

04 Passage à l'échelle

Plus d'actifs, plus de classes : c'est là qu'un optimiseur a le plus de marge pour exprimer une vue.

CONCLUSION

Nous avons construit la chaîne qui permet de savoir.

Un système complet d'allocation, évalué sans tricher, capable de reconnaître les crises,
de montrer ce qui améliore réellement un portefeuille — et de refuser ce qui n'est que du hasard.

Rigueur

évaluation temporelle stricte,
correction de la sélection multiple

Traçabilité

données versionnées,
surfaces régénérées

Transparence

limites explicites,
explicabilité exacte

Merci de votre attention — questions bienvenues.

Les chiffres exacts, par univers

UNIVERS	COMPARATEUR CLASSIQUE	SYSTÈME À RÉGIMES	ÉCART OBSERVÉ
full_2021 · MAD	max_sharpe — 1,0690	0,9571	−10,47 %
etf_2017 · USD	min_variance_lw — 0,9525	0,9371	−1,62 %

EXTENSION DE RECHERCHE · global_2004 (10 ETF, 2004–2026)

Univers pré-enregistré et horodaté avant toute ingestion de données, construit pour que l’optimiseur puisse réellement exprimer une vue (249 allocations distinctes sur 249 rééquilibrages, contre 1 sur etf_2017).

Résultat Q1 : 0,8923 pour le système à régimes contre 0,9785 pour le comparateur classique.

Les niveaux de Sharpe ne sont pas comparables d'un univers à l'autre : les deux univers sont libellés dans des devises différentes, sur des fenêtres différentes et avec un nombre d'actifs différent.

Intégrité des modèles et traçabilité

7 / 1 184

ajustements ayant utilisé un estimateur de repli —
tracés, comptés et publiés

4

stratégies évaluées sur 296 dates de rééquilibrage

891

tests automatisés, dont des tests de cohérence entre
artefacts

CE QUE CELA SIGNIFIE

Lorsqu'un estimateur ne converge pas, le système bascule sur une solution de repli — et le dit. Les séries concernées sont signalées comme hybrides plutôt que présentées sous l'étiquette du modèle qu'elles ne sont pas.

Aucune stratégie n'est recommandée, déployée, ni présentée comme une valeur ajoutée établie. Ce livrable est un prototype de recherche académique : ni conseil financier, ni recommandation client, ni exécution d'ordres.

Les places ne ferment pas à la même heure — et ça se mesure

Casablanca clôture avant Wall Street. La corrélation du jour même sous-estime alors le lien réel entre les deux marchés.

×19,1

la corrélation BVC/SPY décalée d'un jour, rapportée à celle du jour même (actifs américains : effet absent)

17,1 %

des séances BVC sans aucune variation de prix

100 %

des rééquilibrages changent d'allocation selon l'estimateur de covariance retenu

CE QUE NOUS EN CONCLUONS — ET CE QUE NOUS N'EN CONCLUONS PAS

La mesure de covariance est une sensibilité de premier ordre : elle déplace l'allocation à chaque rééquilibrage.

En revanche, aucun test apparié n'établit qu'un estimateur bat l'autre en Sharpe ($p = 0,30$) — l'écart observé ne doit pas être lu comme une supériorité.

Détecté sur l'univers mixte et absent de l'univers témoin entièrement américain : la signature vient bien du décalage horaire, pas du hasard.

Et si notre protocole d'évaluation était lui-même sur-ajusté ?

Un second protocole, imbriqué, refait la sélection à l'intérieur de chaque repli et dégonfle le Sharpe du nombre d'essais.

0,737

ratio de Sharpe dégonflé (DSR) après correction
du nombre d'essais

198

configurations dans la famille de recherche
corrigée

781

séances hors échantillon, du 28/07/2023 au
24/07/2026

CE QU'IL FAUT EN RETENIR

Le classement des stratégies dépend du protocole d'évaluation retenu et de la fenêtre hors échantillon associée.

Nous le disons plutôt que de choisir le protocole qui nous arrange — c'est précisément le genre de choix qu'une correction de data snooping est censée neutraliser.

Univers full_2021, libellé en MAD · meilleure configuration : regime_conditional.

La pile technique

Tout est conteneurisé et rejouable : un dépôt cloné reproduit les mêmes chiffres, sans intervention manuelle.

Données

DVC + stockage objet
contrats de schéma

Expériences

MLflow
télémétrie par ajustement

Orchestration

Dagster
dépendances explicites


Diffusion

FastAPI + Streamlit
lecture seule

Industrialisation

Docker · CI GitHub
portes de release

Suivi des expériences (MLflow)



Graphe d'actifs de données (Dagster)

